

Instituto de Pesquisas Tecnológicas do Estado de São Paulo

Daniel Reghin

Previsão de Value-at-Risk para o mercado brasileiro: Um estudo comparativo entre o método paramétrico, redes neurais artificiais Feedforward e Long Short-Term Memory

**São Paulo
2019**

Daniel Reghin

Previsão de Value-at-Risk para o mercado brasileiro: Um estudo comparativo entre o método paramétrico, redes neurais artificiais Feedforward e Long Short-Term Memory

Dissertação de Mestrado apresentada ao Instituto de Pesquisas Tecnológicas do Estado de São Paulo - IPT, como parte dos requisitos para a obtenção do Título de Mestre em Engenharia de Computação

Data da aprovação ____ / ____ / ____

Prof. Dr. Fábio S. Lopes (Orientador)
Mestrado Engenharia de Computação

Membros da Banca Examinadora:

Prof. Dr. Fábio S. Lopes (Orientador)
Mestrado Engenharia de Computação

Prof. Dr. Marcelo Novaes de Rezende (Membro)
Mestrado Engenharia de Computação

Prof. Dr. Mario Olímpio de Menezes (Membro)
Universidade Presbiteriana Mackenzie

Daniel Reghin

Previsão de Value-at-Risk para o mercado brasileiro: Um estudo comparativo entre o método paramétrico, redes neurais artificiais *Feedforward* e *Long Short-Term Memory*

Dissertação de Mestrado apresentada ao Instituto de Pesquisas Tecnológicas do Estado de São Paulo - IPT, como parte dos requisitos para a obtenção do Título de Mestre em Engenharia de Computação.

Área de Concentração: Engenharia de Software

Orientador: Profº Dr. Fábio Lopes

São Paulo
Junho/2019

Ficha Catalográfica
Elaborada pelo Departamento de Acervo e Informação Tecnológica – DAIT
do Instituto de Pesquisas Tecnológicas do Estado de São Paulo - IPT

R334p **Reghin, Daniel**

Previsão de Value-at-Risk para o mercado brasileiro: um estudo comparativo entre o método paramétrico, redes neurais artificiais Feedforward e Long Short-Term Memory. /Daniel Reghin. São Paulo, 2019.
122p.

Dissertação (Mestrado em Engenharia de Computação) - Instituto de Pesquisas Tecnológicas do Estado de São Paulo. Área de concentração: Engenharia de Software.

Orientador: Profo Dr. Fábio Lopes

1. Valor em risco 2. Value-at-Risk 3. Mercado financeiro 4. Brasil 5. Redes neurais artificiais 6. LSTM - Long Short-Term Memory 7. Tese I. Lopes, Fábio Lopes, orient. II. IPT. Coordenadoria de Ensino Tecnológico III. Título

19-46

CDU 004.032.26(043)

AGRADECIMENTOS

Agradeço em primeiro lugar a Deus pela oportunidade do aprendizado diário nas lutas da vida.

Aos meus pais, Sebastião e Elfrida, pelo incentivo a educação e pelo suporte dado ao longo de todos esses anos.

A minha esposa Luciene pela paciência e apoio durante a longa jornada de finais de semana focados nos estudos e pesquisas.

Ao meu orientador Prof. Dr. Fábio Lopes pelo apoio, direcionamento e incentivo. Aos membros da banca Prof. Dr. Marcelo Rezende e Prof. Dr. Mario Menezes pelas importantes sugestões e correções sugeridas durante a apresentação.

À todos os colegas e amigos que de uma forma ou de outra me apoiaram e auxiliaram durante todo esse processo.

RESUMO

O mercado financeiro pode ser arriscado para os que não o conhecem ou para aqueles que negociam grandes quantidades de recursos. Empresas e indivíduos procuram encontrar ferramentas que os permitam mitigar os riscos associados à negociação de ativos nesse mercado. Um mecanismo de quantificação de risco no mercado financeiro é o VaR (*Value-at-Risk*). Possui mais de uma forma de cálculo, sendo uma delas o método paramétrico, modelo que não é efetivo para todos os cenários de mercado. Através de uma revisão sistemática de literatura, nota-se a ineficiência do cálculo em cenários de crise ou mudanças abruptas de comportamento de ações. Para validar alternativas, este estudo comparou o cálculo de Value-At-Risk com o método paramétrico para duas séries financeiras VALE3 e IBOVESPA com redes neurais *Feedforward* e recorrentes com *Long Short-Term Memory*. Para o paramétrico foram experimentados modelos de volatilidade como Desvio Padrão, EWMA (*Exponentially Weighted Moving Average*) e GARCH (*Generalized Autoregressive Conditional Heteroskedasticity*). Para redes neurais foram exploradas diferentes camadas e quantidades de neurônios, funções de ativação, utilização de diferentes previsores/*features* e incorporação de dados macroeconômicos. As redes neurais não se mostraram mais eficientes na previsão do VaR para épocas de crise e mudanças abruptas de comportamento, mesmo após os ajustes na série paramétrica utilizada como previsão e/ou através da variação dos atributos previsores. O modelo paramétrico ainda se mostrou mais atrativo tanto por sua previsão mais eficiente bem como pela simplicidade de seu cálculo. De todo modo, o comportamento de redes *feedforward* e LSTM mostraram-se diferentes para as duas séries, sendo que para o IBOVESPA foi mais eficiente do que para a VALE3. Isso demonstra que modelos alternativos podem ser explorados em estudos futuros com base na estratégia utilizada por esse estudo e pela observação do comportamento nas configurações de modelos experimentados para as duas séries estudadas.

Palavras-chaves: Redes Neurais Artificiais; Rede Neurais Feedforward; Rede Neural Recorrente; LSTM; Valor em Risco; Value-at-Risk; GARCH; EWMA

VALUE-AT-RISK PREDICTION FOR THE BRAZILIAN STOCK MARKET: A COMPARATIVE STUDY BETWEEN THE PARAMETRIC METHOD, FEEDFORWARD NEURAL NETWORK AND LONG SHORT-TERM MEMORY

The financial market can be risky for those who do not have the necessary knowledge or for those who trade large amounts of resources. Companies and individuals seek to find tools to mitigate the risks associated with asset trading in this market. A mechanism of risk quantification in the financial market is VaR (Value-at-Risk). It has more than one way of calculating it, one of which is the parametric method, a model that is not effective for all market scenarios. Through a systematic review, we have noticed the inefficiency in crisis scenarios or abrupt changes in stock behavior. To validate alternatives, this study compares the Value-At-Risk calculation with the parametric method, for two financial series in Brazil Stock Market VALE3 and IBOVESPA, with Feedforward Neural Networks and Recurrent Neural Networks through LSTM (Long Short-Term Memory). For the parametric model, volatility models such as Standard Deviation, EWMA (Exponentially Weighted Moving Average) and GARCH (Generalized Autoregressive Conditional Heteroskedasticity) were tested. For neural networks, different layers and quantities of neurons, activation functions, different features and uses of macroeconomic data were explored. Neural networks have not shown to be more efficient in forecasting VaR for times of crisis and abrupt changes in behavior, even after adjustments in the parametric series used as prediction and / or by variation of predictive attributes. The parametric model was still more attractive because of its more efficient prediction as well as the simplicity of its calculation. The behavior of feedforward and LSTM networks were different for the two series. For IBOVESPA it was more efficient than for VALE3. This demonstrates that alternative models can be explored in future studies based on the strategy used by this study and the observation of behavior in the configurations of models tested for the two series studied.

Key-words: Artificial Neural Networks; Feedforward Neural Network; Recurrent Neural Network; LSTM; Value-at-Risk; GARCH; EWMA

LISTA DE ILUSTRAÇÕES

Figura 1 – Organização do trabalho.	20
Figura 2 – Etapas executadas na revisão sistemática	22
Figura 3 – Revisão da Literatura	23
Figura 4 – Resultado da revisão sistemática, apresentado temporalmente.	25
Figura 5 – Cálculo Diário para o VaR	29
Figura 6 – Rede Neural Artificial	33
Figura 7 – Neurônio matemático	34
Figura 8 – Rede Neural <i>Feedforward</i>	36
Figura 9 – Rede Neural LSTM	38
Figura 10 – Validações do Modelo	39
Figura 11 – Preços de fechamento em R\$ da Vale no período	40
Figura 12 – Valor de fechamento do índice Bovespa no período	41
Figura 13 – Janelas do cálculo de volatilidade	44
Figura 14 – Janelas do cálculo de volatilidade	44
Figura 15 – Etapas do Experimento	47
Figura 16 – Value-at-Risk para OMXS30	53
Figura 17 – IBOVESPA de 2004 à 2018 com seleção de crise	66
Figura 18 – VALE3 de 2004 à 2018 com seleção de crise	66
Figura 19 – Cotação Dólar e Real no período.	77
Figura 20 – Desvalorização SADIA.	77
Figura 21 – OMXS30 de 1990 à 2016	78
Figura 22 – Value-at-Risk para OMXS30	79
Figura 23 – Parâmetros GARCH para VaR da OMXS30	80
Figura 24 – IBOVESPA de 2004 à 2018	81
Figura 25 – VALE3 de 2004 à 2018	82
Figura 26 – PTAX Dólar e PTAX Euro de 2004 à 2018	83
Figura 27 – SELIC e IPAC de 2004 à 2018	84
Figura 28 – IBOVESPA paramétrico modelos P4 e P5	85
Figura 29 – IBOVESPA paramétrico modelos P7 e P10	86
Figura 30 – VALE3 paramétrico modelos P4 e P5	87
Figura 31 – VALE3 paramétrico modelos P7 e P10	88
Figura 32 – IBOVESPA Feedforward FF-5	89
Figura 33 – IBOVESPA Feedforward modelos FF-2, FF-15 e FF-18	90
Figura 34 – VALE Feedforward FF-9	92
Figura 35 – VALE Feedforward modelos FF-21	93
Figura 36 – IBOVESPA LSTM-5	94

Figura 37 – IBOVESPA LSTM-11	95
Figura 38 – IBOVESPA LSTM-15	96
Figura 39 – IBOVESPA LSTM-28	97
Figura 40 – IBOVESPA LSTM-20	98
Figura 41 – VALE LSTM-3	100
Figura 42 – VALE LSTM-11	101
Figura 43 – VALE LSTM-15	102
Figura 44 – VALE LSTM-25	103
Figura 45 – Gráfico com a quantidade de estudos encontrados.	110
Figura 46 – Resultado da seleção dos artigos.	112

LISTA DE TABELAS

Tabela 1 – Modelos do Experimento Paramétrico	48
Tabela 2 – Modelos do Experimento Feedforward	49
Tabela 3 – Modelos do Experimento LSTM	50
Tabela 4 – Componentes do ambiente do experimento	52
Tabela 5 – Resultado Experimento OMXS30	53
Tabela 6 – Resultado Experimento Paramétrico IBOVESPA	54
Tabela 7 – Resultado Experimento Paramétrico VALE3	54
Tabela 8 – Modelos <i>Feedforward</i> - IBOVESPA	56
Tabela 9 – Experimento <i>Feedforward</i> - IBOVESPA	57
Tabela 10 – Modelos <i>Feedforward</i> - VALE3	58
Tabela 11 – Experimento <i>Feedforward</i> - VALE3	59
Tabela 12 – Modelos do Experimento LSTM - IBOVESPA (1/2)	60
Tabela 13 – Modelos do Experimento LSTM - IBOVESPA (2/2)	61
Tabela 14 – Resultado Experimento LSTM - IBOVESPA 1/2	62
Tabela 15 – Resultado Experimento LSTM - IBOVESPA 2/2	63
Tabela 16 – Modelos do Experimento LSTM - VALE	64
Tabela 17 – Resultado Experimento LSTM - VALE	65
Tabela 18 – Comparação momentos de crise - IBOVESPA	67
Tabela 19 – Comparação momentos de crise - VALE	67
Tabela 20 – Comparação final dos modelos	69
Tabela 21 – OMXS30 de 1990 à 2016	78
Tabela 22 – VaR paramétrico de OMXS30 de 1990 à 2016	80
Tabela 23 – Tabela de parâmetros GARCH para VaR da OMXS30	80
Tabela 24 – IBOVESPA 2004 à 2018	81
Tabela 25 – VALE3 de 2004 à 2018	82
Tabela 26 – Média compra e venda do PTAX Dólar e PTAX Euro	83
Tabela 27 – Taxa de Juros e Inflação do período de 2004 à 2018 Euro	84
Tabela 28 – VaR paramétrico do IBOVESPA de 2008 à 2018	86
Tabela 29 – VaR paramétrico do VALE3 de 2008 à 2018	88
Tabela 30 – VaR FFNN, FF-5 do IBOVESPA de 2008 à 2018	91
Tabela 31 – VaR FFNN, FF-5 do VALE de 2008 à 2018	93
Tabela 32 – VaR LSTM-28 de IBOVESPA de 2008 à 2018	99
Tabela 33 – VaR LSTM-15 do VALE de 2008 à 2018	104
Tabela 34 – Fontes de pesquisa da revisão sistemática	106
Tabela 35 – Critérios de inclusão e exclusão da revisão sistemática	107
Tabela 36 – Dados extraídos na revisão sistemática	108

Tabela 37 – Quantidade de dados extraídos dos portais de pesquisa em inglês.	110
Tabela 38 – <i>Iterações da seleção de artigos da revisão sistemática</i>	111
Tabela 39 – <i>Revisão Sistemática: Critérios de Inclusão e Exclusão aplicados</i>	112
Tabela 40 – <i>Estudos primários selecionados</i>	113
Tabela 41 – Distribuição do tipo de previsão nos estudos primários.	114
Tabela 42 – Ativos utilizados nos estudos primários.	114
Tabela 43 – Algoritmos utilizados nos estudos primários.	114
Tabela 44 – Métricas utilizadas nos estudos primários	115
Tabela 45 – Modelos estatísticos comparados nos estudos primários.	115
Tabela 46 – Modelo mais vantajoso.	116
Tabela 47 – <i>Resultado bruto da pesquisa sistemática no portal Scopus</i>	118
Tabela 48 – <i>Resultado bruto da pesquisa sistemática no portal ScienceDirect</i>	120
Tabela 49 – <i>Resultado bruto da pesquisa sistemática no portal ACM</i>	121
Tabela 50 – <i>Resultado bruto da pesquisa sistemática no portal IEEE</i>	122
Tabela 51 – <i>Resultado bruto da pesquisa sistemática no portal Web of Science</i>	122
Tabela 52 – <i>Resultado bruto da pesquisa sistemática no portal oasisbr</i>	123

LISTA DE ABREVIATURAS E SIGLAS

ARCH	Autoregressive Conditional Heteroskedasticity ou Heteroscedasticidade Condicionada Auto-Regressiva
BPNN	Backpropagation Neural Network
DNN	Deep Neural Network ou Rede Neural Profunda
EGARCH	Exponencial ARCH ou ARCH Exponencial
EWMA	Exponentially Weighted Moving Average ou Média Móvel Exponencial Ponderada
GARCH	Generalized ARCH ou ARCH Generalizada
HMAE	Heteroscedasticity adjusted MAE ou Erro Médio Absoluto Ajustado pela Heterocedasticidade
HMSE	Heteroscedasticity adjusted MSE ou Erro Médio Quadrático Ajustado pela Heterocedasticidade
IPO	Initial Public Offering ou Oferta Pública Inicial
LSTM	Long Short-Term Memory
MAD	Mean Absolute Deviation ou Desvio Médio Absoluto
MAE	Mean Absolute Error ou Erro Médio Absoluto
MAPE	Mean Absolute Percentage Error ou Erro Médio Percentual Absoluto
MFE	Mean Forecast Error ou Erro Médio de Previsão
MLP	Multilayer Perceptron
MSE	Mean Squared Error ou Erro Médio Quadrático
OMXS30	OMX Stockholm 30, índice da bolsa de Estocolmo com as 30 ações mais negociadas
PICO	Population, Intervention, Control e Outcome ou População, Intervenção, Controle e Resultados
RMSE	Root Mean Absolute Error ou Raiz do Erro Médio Quadrático
RNN	Recurrent Neural Network ou Rede Neural Recorrente

SGD Stochastict Gradient Descent

VaR Value at Risk

SUMÁRIO

1	INTRODUÇÃO	16
1.1	Contexto e Motivação	16
1.2	Problema	17
1.3	Objetivo	18
1.4	Contribuições	18
1.5	Método de Pesquisa	19
1.6	Organização do Trabalho	20
2	REVISÃO DA LITERATURA	21
2.1	Revisão Sistemática da Literatura	21
2.2	Estado da Arte	23
2.3	Value-at-Risk	27
2.3.1	Distribuição de Probabilidades	30
2.3.2	Volatilidade	30
2.3.2.1	EWMA	31
2.3.2.2	GARCH	32
2.4	Redes Neurais Artificiais	32
2.4.1	Neurônio Matemático	34
2.4.2	Função de Ativação	35
2.4.3	Topologia da Rede	36
2.4.4	Redes LSTM	37
2.4.5	Overfitting e Underfitting	38
3	PREPARAÇÃO PARA O EXPERIMENTO	40
3.1	Dados para o Experimento	40
3.2	Métricas de Avaliação	42
3.3	Janelas de volatilidade e previsão	43
3.3.1	Janela para modelo paramétrico	43
3.3.2	Janela rede neural	44
3.4	Montagem da rede neural	45
3.5	Estratégia do Experimento	46
3.5.0.1	Etapa 1 - Modelo Paramétrico	48
3.5.1	Etapa 2 - Modelo com Rede Neural Feedforward	49
3.5.2	Etapa 3 - Modelo com Rede Neural LSTM	50
3.5.3	Análise e Apresentação dos dados	51

4	EXPERIMENTO	52	
4.1	Ambiente de trabalho	52	
4.2	Etapa 1 - Comparação com estudo preliminar	53	
4.3	Etapa 1 - Previsão paramétrica para IBOVESPA e VALE3	54	
4.4	Etapa 2 - Previsão com rede Feedforward para IBOVESPA e VALE3	56	
4.5	Etapa 3 - Previsão com rede LSTM para IBOVESPA e VALE3	60	
4.6	Avaliação em períodos de crise	66	
5	CONCLUSÃO	68	
5.1	Estudos Futuros e Ameaças à validade	70	
6	REFERÊNCIAS	72	
APÊNDICES		76	
APÊNDICE A	-	DESVALORIZAÇÃO SADIA CONTRA COTAÇÃO DO DÓLAR	77
APÊNDICE B	-	DADOS PARA EXPERIMENTO - OMXS30	78
APÊNDICE C	-	RESULTADO - ETAPA 1 COM OMXS30	79
APÊNDICE D	-	DADOS PARA EXPERIMENTO	81
APÊNDICE E	-	RESULTADO - ETAPA 1 COM IBOVESPA	85
APÊNDICE F	-	RESULTADO - ETAPA 1 COM VALE3	87
APÊNDICE G	-	RESULTADO - ETAPA 2 COM IBOVESPA	89
APÊNDICE H	-	RESULTADO - ETAPA 2 COM VALE	92
APÊNDICE I	-	RESULTADO - ETAPA 3 COM IBOVESPA	94
APÊNDICE J	-	RESULTADO - ETAPA 3 COM VALE	100
APÊNDICE K	-	REVISÃO SISTEMÁTICA DA LITERATURA	105
K.1	Protocolo de Pesquisa	105	
K.1.1	Objetivo	105	
K.1.2	Questões de Pesquisa	105	
K.1.3	Palavras-chave	106	
K.1.4	Fontes de Pesquisa	106	
K.1.5	Critérios de Seleção	107	

K.1.6	Procedimento de Pesquisa	107
K.1.7	Extração de dados	107
K.1.8	Sumarização	108
K.2	Execução do Protocolo de Pesquisa	109
K.2.1	Confecção de Strings de Consulta	109
K.2.2	Seleção de Estudos Primários	110
K.2.3	Extração dos Dados	112
K.3	Apresentação da Revisão	113
K.3.1	Tabulação dos Dados	113
APÊNDICE L – ARTIGOS DA REVISÃO SISTEMÁTICA	117	

1 INTRODUÇÃO

1.1 Contexto e Motivação

Empresas e indivíduos, em busca de ganhos ou proteção, negociam ativos como: ações, títulos públicos ou privados, opções financeiras, contratos futuros, commodities, moedas físicas ou virtuais nos diversos mercados mundiais. As variáveis que influenciam o preço dos ativos são inúmeras, tais como: oscilações de preços de outros papéis, definições governamentais e resultados de empresas. Portanto, a negociação de ativos, está exposta a riscos que se previstos e quantificados, ajudam o participante do mercado a tomar decisões para mitigá-los.

O dicionário Merriam-Webster (2018) define risco como, a probabilidade de perda ou dano. Em Jorion (2003), risco é definido como a volatilidade de resultados inesperados, normalmente relacionada ao valor de ativos ou passivos de interesse. Já Damodaran (2007) apresenta o risco como a probabilidade de obtermos um retorno de investimento que seja diferente do previsto. Brigman e C. (2010, pg. 207) citam que "quanto mais estreita a distribuição de probabilidade dos retornos esperados no futuro, menor será o risco de um investimento". Para Wolke (2017), o conceito de risco é baseado na probabilidade de conhecer um evento futuro desconhecido.

Um exemplo de perda financeira por conta da oscilação do preço de uma moeda no Brasil é o caso da SADIA (BARRETO, 2011). Para Barreto (2011, p. 17) "O prejuízo foi causado por operações de hedge que apostavam na valorização do real em comparação ao dólar". A empresa assumiu o risco de perder dinheiro apostando em um cenário diferente do apresentado posteriormente pelo mercado, culminando em grandes prejuízos e em sua reestruturação administrativa e acionária. O apêndice A, apresenta um gráfico com a desvalorização do real frente ao dólar e o impacto da cotação da ação, quando o mercado tomou conhecimento da operação de derivativo altamente exposta ao dólar.

Um outro exemplo de perda decorrente de uma má gestão de risco, foi o do Banco Inglês Barings, na qual culminou em sua falência. A alta exposição ao mercado de ações japonês por um contrato de futuros levou a perda de US\$ 1,3 bilhão (JORION, 2003).

A quebra de grandes empresas ou instituições bancárias pode levar o mercado a um colapso, gerando um risco sistêmico de perdas maiores. É por isso que entidades governamentais e instituições buscam formas de regular o mercado impondo restrição à exposição de riscos. Uma dessas instituições é o Comitê de Supervisão Bancária de Basileia. Em sua proposta de regulamentação bancária, chamada Basileia II BASEL COMMITTEE ON BANKING SUPERVISION (2006), estipula a reserva mínima de seu capital para que bancos estejam preparados para crises. Um dos pilares de avaliação de capital, proposta pela Basileia II, é a reserva para riscos de mercado.

Existem algumas formas de medir o risco de mercado (BAIDYA; COSTA, 2003). Uma delas é avaliar a volatilidade dos ativos ao longo do tempo. Ativos com alta volatilidade possuem uma grande variação de seus preços, com isso, um maior risco de perdas. Outra forma de medir o risco é calcular o Value-at-Risk ou Valor no Risco. O Value-at-Risk, é um número que representa a pior ou máxima perda esperada para um ativo ou grupos de ativos em análise.

1.2 Problema

O Value-at-Risk, como medida de risco, precisa ser calculado com uma eficácia que permita que o gestor dos ativos tenha segurança ao avaliar o seu número e fazer sua gestão. O risco calculado pelo modelo tem que ser muito próximo do risco efetivamente realizado. Um modelo mais eficiente gera uma previsão de perda ou risco próxima à perda real capturada pelo ativo. A seção 3.2 detalha quais métricas foram utilizadas para comparação entre os modelos que foram estudados.

Por isso, modelos matemáticos, estatísticos e computacionais são experimentados a fim de gerar melhor previsão desse número. Uma linha de estudo para gerar esse número é a que usa algoritmos de redes neurais artificiais.

Através da revisão sistemática realizada nessa dissertação, foi identificado estudos que utilizaram redes neurais para o cálculo do *Value-at-Risk* ou Volatilidade como alternativa aos modelos tradicionalmente utilizados. Houve estudos que buscaram algumas alternativas como: a experimentação de topologias de redes distintas, como *Feedforward Neural Network* e *Recurrent Neural Network*; a geração da previsão de parâmetros utilizados para o cálculo do VaR como média e desvio padrão; a incorporação de dados macro econômicos na rede como taxas de juros e de previsões de modelos estatísticos.

Independente do método utilizado, notou-se, em mais de um estudo, que há prejuízo da previsão para Value-at-Risk e volatilidade em momentos de crise ou mudanças abruptas de comportamento. A eficácia do modelo, portanto, é prejudicada em tempos de crise.

Dessa forma, temos o seguinte problema:

- Baixa eficiência de modelos de redes neurais artificiais para previsão de volatilidade e Value-at-Risk em momentos de crise ou mudança abrupta de comportamento.

1.3 Objetivo

Por conta da baixa eficiência de previsão de VaR em momentos de crise, através do modelo paramétrico e de redes neurais *Feedforward* utilizados nos estudos encontrados na revisão sistemática, esse estudo tem como objetivo:

- Avaliar a eficiência de previsão do Value-at-Risk no mercado brasileiro para momentos de crise e/ou mudança abrupta de comportamento através de redes neurais artificiais com LSTM.

Para avaliar a eficiência do cálculo do VaR com redes LSTM é necessário compará-lo com modelos já conhecidos. Na pesquisa realizada para fundamentar a dissertação, notou-se que muitos estudos buscaram calcular o VaR com redes *Feedforward*. Há também, o uso de métodos estatísticos que utilizam modelos de cálculo de volatilidade como Médias Móveis Exponencialmente Ponderadas (EWMA) e Heteroscedasticidade Condicional Auto-Regressiva Generalizada (GARCH), vide seção 2.3.2.

É por essa razão que foi tomada a decisão de comparar a rede LSTM com modelos paramétricos e com redes *Feedforward*. Redes LSTM tendem a se mostrar mais eficientes para prever comportamentos de séries temporais, dado o alto volume de dados nas séries e a sua dependência temporal, vide seção 2.4.4.

Dois dos estudos identificados na revisão bibliográfica utilizaram dados macroeconômicos para melhorar a previsão gerada pela rede neural. Por entender que esses dados pudessem trazer informações que beneficiem a previsão, incorporamo-os em um dos modelos utilizados para comparação.

Temos, portanto, duas hipóteses que são validadas ao final do estudo para corroborarem a percepção inicial.

- Considerar dados macroeconômicos como taxa de juros e cotação de moedas, podem gerar uma melhor previsão do Value-at-Risk com redes neurais LSTM.
- O uso de *Recurrent Neural Network* através da LSTM pode ser mais eficiente do que o uso de *Feedforward Neural Network*.

1.4 Contribuições

São algumas contribuições feitas por essa dissertação. A primeira é a realização da revisão sistemática da literatura sobre o tema. Esse método de pesquisa foi utilizado para encontrar estudos que tenham explorado a previsão de volatilidade e Value-at-Risk através de redes neurais, podendo ser reproduzível e extensível por outros estudos.

Outra, diz respeito a avaliação da previsão do VaR, com topologias de redes distintas e a comparação de seu resultado com modelos estatísticos conhecidos pelo mercado financeiro. Esse contribuição dá um passo adiante nos estudos encontrados na revisão sistemática da

literatura ao estudar topologias e configurações de rede não exploradas, além de incorporar dados macro-econômicos nos dados previsores da rede neural. Isso utilizando como cenário a lacuna, encontrada nos estudos pesquisados, da baixa eficiência dos modelos em cenários de crise.

Por fim, a exploração desse tema fomenta o uso de redes neurais ao mercado financeiro para cálculos de risco de mercado.

Podemos listar as seguintes contribuições:

- Realizar uma revisão sistemática de literatura para previsão de Value-at-Risk e volatilidade com redes neurais artificiais.
- Avaliar a efetividade do uso de redes *Feedforward Neural Network* e *Recurrent Neural Network* na previsão do VaR em momentos de instabilidade de mercado.
- Comparar os resultados apresentados com modelos estatísticos.
- Fomentar o uso de técnicas de aprendizado de máquina para o mercado financeiro brasileiro.

1.5 Método de Pesquisa

Dois métodos são utilizados:

- Revisão Sistemática da Literatura
- Experimento

É utilizado o método de revisão sistemática da literatura para a pesquisa bibliográfica. Dessa forma, pesquisadores futuros podem se utilizar do trabalho aqui realizado, reproduzindo-o ou estendendo-o.

Também é utilizado o método experimental. De acordo com Gil (2002, p. 48): "A pesquisa experimental [...]. Consiste essencialmente em determinar um objeto de estudo, selecionar as variáveis que seriam capazes de influenciá-lo, definir as formas de controle e de observação dos efeitos que a variável produz no objeto".

Um experimento é feito através do controle pelo pesquisador das variáveis dependentes do estudo. Ao final, de sua execução, o resultado é observado e confrontado com as hipóteses inicialmente feitas. Detalhes de como o experimento foi realizado são explanados em seções subsequentes.

Para validar o resultado dos diferentes métodos de cálculo, foram utilizados três métricas de comparação: a quantidade de exceção, acurácia e o erro médio quadrático, ou seja, uma boa previsão é aquela que tenha baixa quantidade de exceções, reproduzindo isso em sua acurácia, e que tenha um baixo erro médio quadrático.

1.6 Organização do Trabalho

O trabalho foi organizado da seguinte forma: a primeira seção traz a contextualização do tema de pesquisa, o problema encontrado, o objetivo, o método utilizado pelo estudo e o detalhamento de como a dissertação foi organizada.

A segunda seção traz a revisão da literatura. O estado da arte, resultante da revisão sistemática da literatura, é apresentado em conjunto com os estudos encontrados na pesquisa. São também explanados conceitos que se mostram necessários para o entendimento deste estudo, como *Value-at-Risk* e redes neurais artificiais.

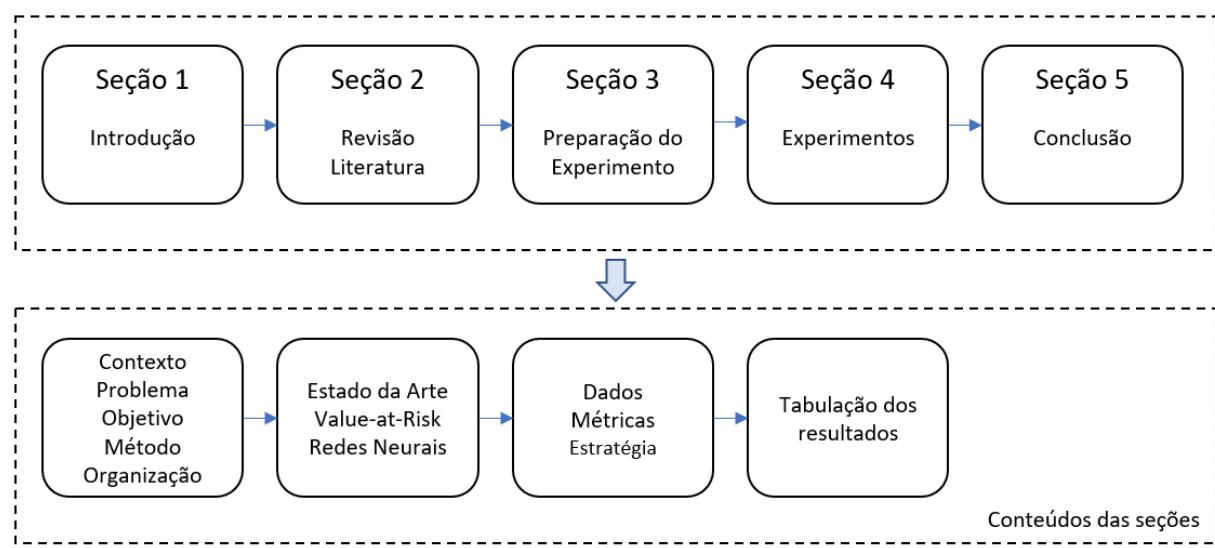
A terceira seção traz informações sobre o experimento a ser realizado. É nessa seção que é detalhado como foi feito o experimento. São apresentados os ativos que foram utilizados, bem como os dados macroeconômicos usados nas redes neurais. São apresentados as métricas utilizadas para comparação entre redes neurais e métodos estatísticos. Por fim, é apresentado a estratégia de montagem das redes neurais e os diferentes modelos de execuções dos experimentos realizados

A quarta seção apresenta a execução do experimento e o resultado encontrado.

A quinta seção contém a conclusão do estudo sobre os resultados encontrados. São avaliados e comentados cenários frente às hipóteses previamente levantadas. Proposições para novos estudos também são realizados.

O apêndice contém itens de apoio, como por exemplo, a integralidade da revisão sistemática da literatura. Nele, é possível analisar o protocolo de pesquisa com suas fontes, questões de pesquisa, fontes de pesquisa, procedimentos e etc.

Figura 1 – Organização do trabalho.



Fonte: Elaborado pelo autor

2 REVISÃO DA LITERATURA

2.1 Revisão Sistemática da Literatura

De acordo com Felizardo et al. (2017, p. 3), o objetivo da revisão sistemática é "[...] identificar, analisar e interpretar as evidências disponíveis relacionadas com um particular tópico de pesquisa ou fenômeno de interesse".

Kitchenham (2004) introduziu a revisão sistemática na engenharia de software e, por isso, serve de referência básica para a maioria de pesquisas desse tipo. De acordo com esse estudo, as razões para realizar uma pesquisa são para consolidar e evidenciar um determinado estudo, identificar lacunas em pesquisas, sugerir pesquisas futuras e por fim, apresentar materiais suficientes para posicionar atividades de pesquisa.

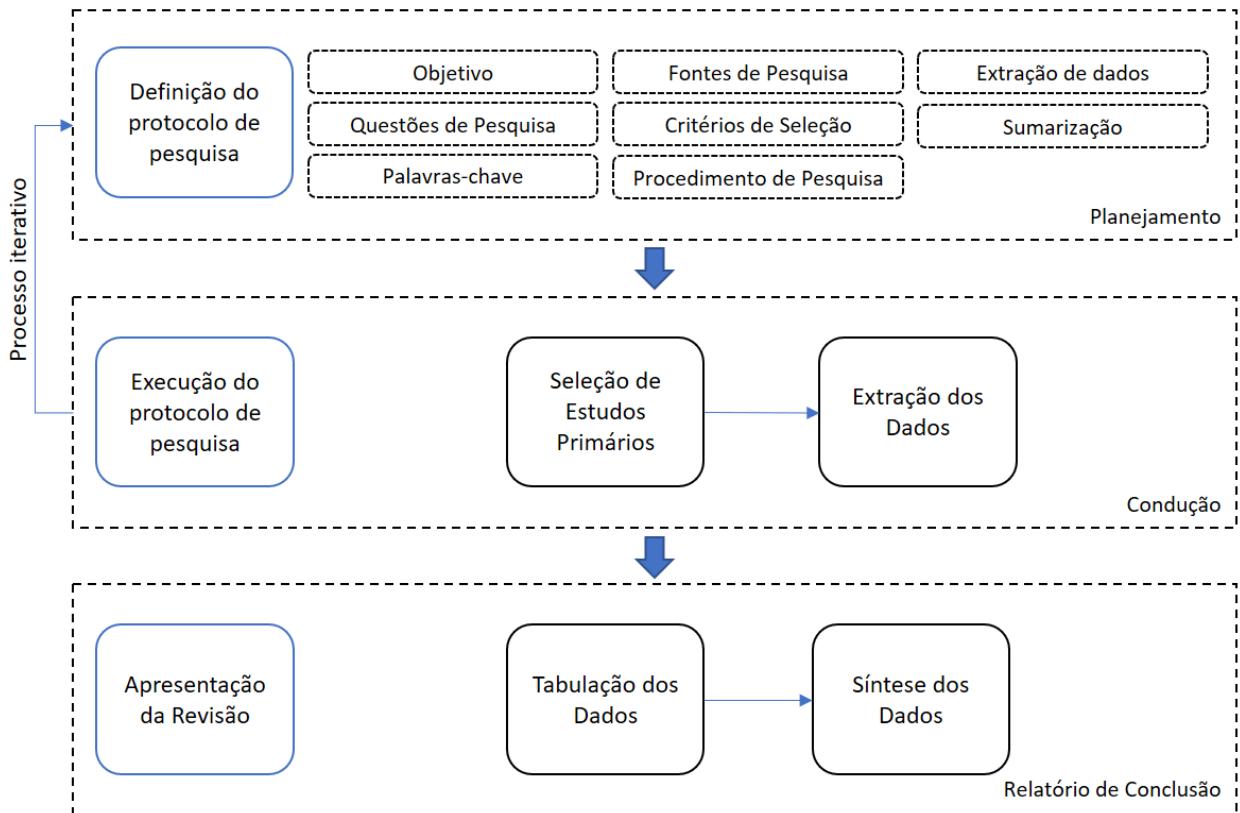
O modelo seguido nessa revisão sistemática foi baseado em ambos os trabalhos acima citados. Além disso, o aplicativo StArt (State of the Art through Systematic Review) LAPES (2017), também foi utilizado como ferramenta de apoio, na condução da revisão sistemática.

Ao documentar os procedimentos e etapas executadas é possível que haja uma avaliação da validade dos estudos encontrados, além de permitir a replicação do estudo no futuro. A execução da revisão contribuiu para compor a pesquisa bibliográfica, corroborando com o estudo realizado por essa dissertação.

A execução da revisão sistemática seguiu algumas etapas de trabalho. A Figura 2, demonstra visualmente essas etapas.

A documentação detalhada do protocolo de pesquisa, a sua execução e resultados podem ser encontrados no apêndice K.

Figura 2 – Etapas executadas na revisão sistemática



Fonte: Elaborado pelo autor

Em primeiro lugar foi definido um protocolo delimitando o escopo da pesquisa e direcionando, objetivamente, os passos a serem executados pelo pesquisador. Nele foram definidos: objetivo da pesquisa, questões a serem respondidas, palavras-chave pesquisadas, fontes de busca de informações, critérios para selecionar os estudos, procedimentos executados durante a pesquisa, extração dos dados e sumarização dos dados.

Em seguida a pesquisa foi executada utilizando o protocolo definido. Os estudos foram catalogados e selecionados conforme critérios estabelecidos. Ao final os dados foram extraídos a fim de atender às perguntas previamente estipuladas.

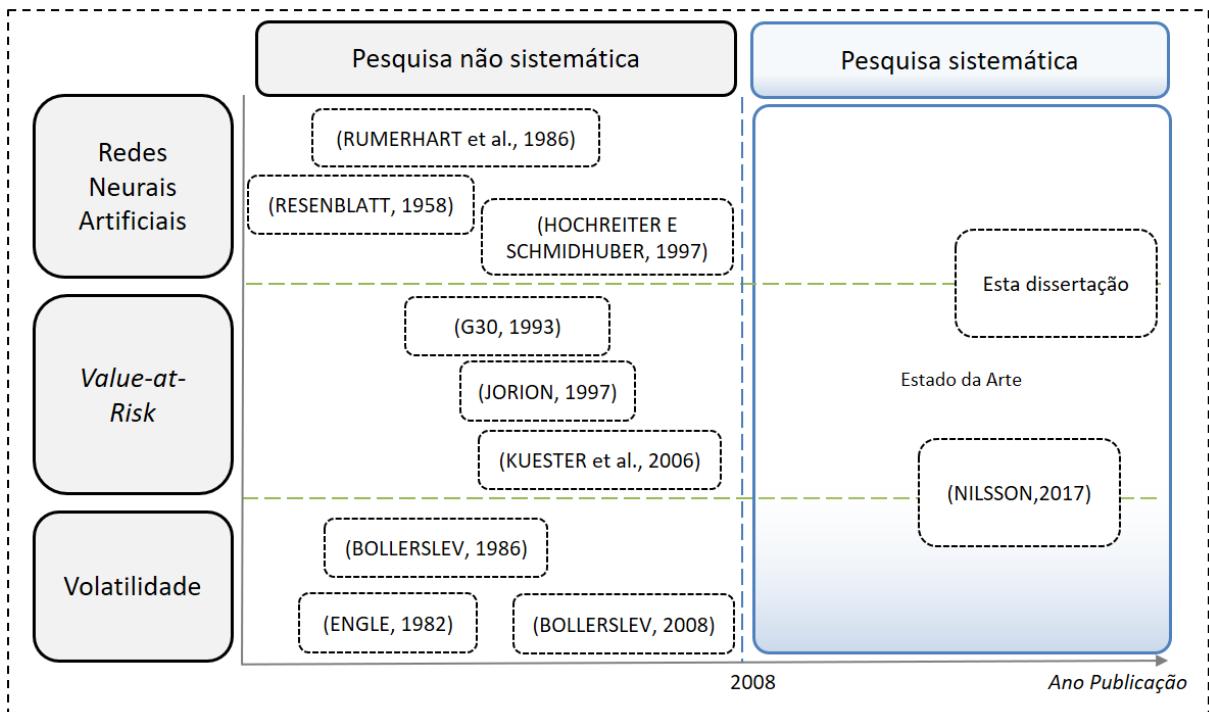
O processo de definição do protocolo e execução de pesquisa foi iterativo. A medida que o estudo avançou, foi necessário ajustar o protocolo para direcionar a pesquisa ao objetivo definido originalmente. Por fim, os dados foram tabulados e a síntese dos estudos foi demonstrada na seção 2.2.

2.2 Estado da Arte

A revisão sistemática da literatura permitiu a identificação das pesquisas já realizadas sobre previsão de *Value-at-Risk* e a lacunas deixadas por estudos anteriores. Nessa seção, os dados da pesquisa não sistemática e da pesquisa sistemática foram sintetizados a fim de embasar o estudo realizado nessa dissertação.

A Figura 3 demonstra graficamente estudos encontrados durante a pesquisa não sistemática e a partir de qual ano a pesquisa sistemática foi realizada.

Figura 3 – Revisão da Literatura



Fonte: Elaborado pelo autor.

A pesquisa não sistemática nos ajuda a compreender a linha do tempo de estudo de value-at-risk, redes neurais e volatilidade. Com isso, entendemos o contexto temporal na qual essa dissertação está inserida. A Figura 3 nos mostra, nas três divisões verticais, alguns dos estudos sobre os respectivos temas distribuídos (sem escala) ao longo dos anos. Assuntos esses que foram abordados em mais profundidade em seções posteriores.

O estudo de redes neurais remonta à metade do século XX. Uma época em que não havia capacidade computacional suficiente para a execução de redes neurais complexas. Pode-se citar o estudo de Rosenblatt (1958), sobre o neurônio matemático, a criação do algoritmo de backpropagation por Rumelhart, Hinton e Williams (1986) e os estudos de redes Long Short-Term Memory ou LSTM por Hochreiter e Schmidhuber (1997). São mais de 70 anos dedicados ao estudo de redes neurais.

Já o estudo de *Value-at-Risk* é mais recente. Iniciou-se através do relatório do G30 GROUP OF THIRTY (1993). A proposta apresentada logo se tornou popular e objeto de estudo, haja vista a publicação do livro de Jorion (1997). Vários métodos de cálculo surgiram e também foram objetos de estudo (KUESTER; MITTNIK; PAOLELLA, 2006).

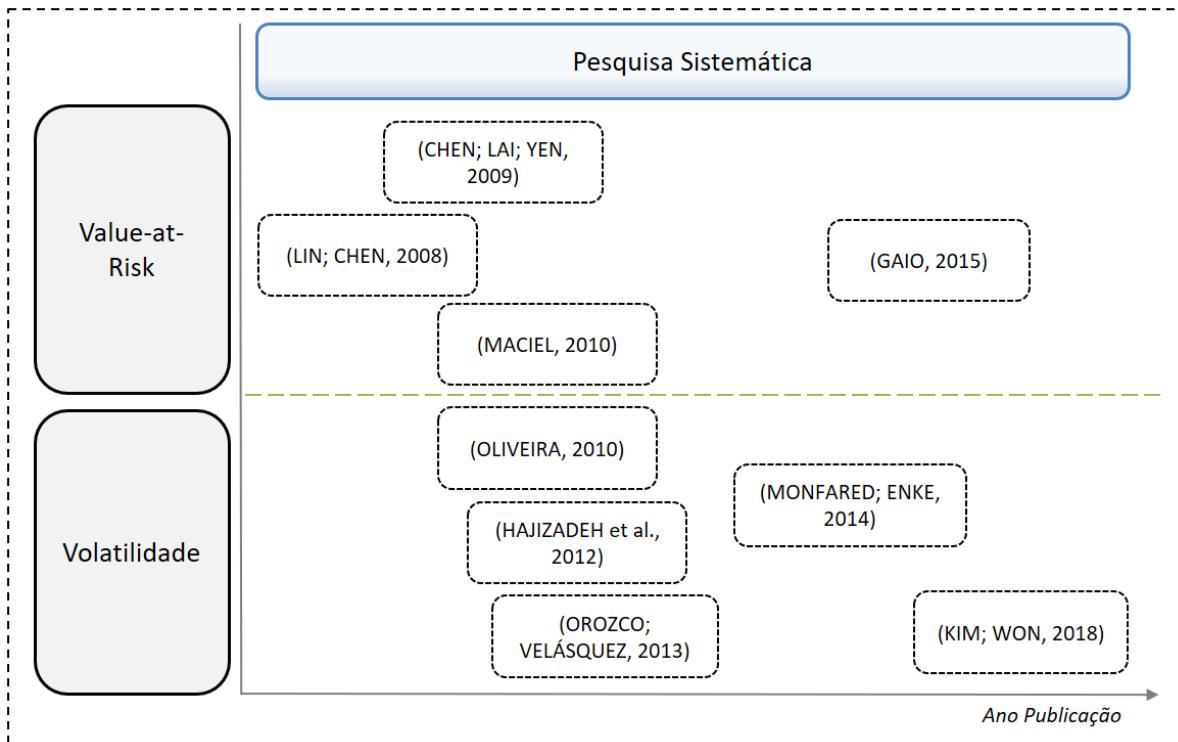
Como o *Value-at-Risk*, em seu método paramétrico, depende do modelo de volatilidade empregado, devemos citar dois estudos que inauguram a exploração de métodos para o seu cálculo. São os estudos de Engle (1982) e Bollerslev (1986). As suas contribuições foram tão importantes que diversas formas de cálculo de volatilidade foram criados após 1986. Bollerslev (2008) cria um catálogo com algumas dessas formas de cálculo. Ao abrirmos esse artigo nos deparamos com mais de 20 modelos de cálculo de volatilidade.

Dado a grande quantidade de modelos variantes, estudos procuraram testar o cálculo do *Value-at-Risk* com diversos desses modelos. Um desses estudos é o de Nilsson (2017). Em sua dissertação de mestrado, o pesquisador faz uma pesquisa experimental na qual compara o cálculo do *Value-at-Risk* com diversas variações de método de cálculo de volatilidade (EWMA, GARCH, GJR-GARCH entre outros) e distribuição de probabilidades (normal, t de student entre outros). Veja, que na Figura 3 esse estudo está na intersecção da seção *Value-at-Risk* e Volatilidade.

As pesquisas até agora mencionadas fizeram parte da revisão não sistematizada da literatura. O embasamento teórico do *Value-at-Risk* e redes neurais estão descritos a partir da seção 2.3. A revisão sistemática da literatura buscou estudos que correlacionassem value-at-risk, volatilidade e redes neurais. Isso é demonstrado pelo destaque azul com a intersecção de todas as seções demonstradas na Figura 3.

Os estudos encontrados da revisão sistemática estão demonstrados na Figura 4. O detalhe da revisão sistemática e seu protocolo podem ser encontrados, como já mencionado, no apêndice K.

Figura 4 – Resultado da revisão sistemática, apresentado temporalmente.



Fonte: Elaborado pelo autor.

Um dos estudos para a previsão de *Value-at-Risk* foi feito por Lin e Chen (2008), que utilizou redes neurais para prever a média e desvio padrão mais adequado. Ao invés de prever a perda esperada do VaR, o estudo buscou identificar alguns dos parâmetros, do cálculo paramétrico, que fossem mais indicados para a realização da previsão.

O estudo de Chen, Lai e Yen (2009) fez um estudo parecido com o anterior ao prever os componentes necessários para o cálculo do VaR ao invés do VaR em si. Valores como média e volatilidade foram os selecionados para a previsão.

Já Maciel (2010), diferente dos estudos anteriores, propôs prever o percentual de variação dos ativos estudados. Como dado de entrada do modelo, o retorno dos ativos através da fórmula logarítmica (log-retorno), foi utilizado. Também foi utilizada uma rede neural de múltiplas camadas treinadas com o algoritmo *Backpropagation*. Foram utilizadas quatro ações negociadas na IBOVESPA. O uso de redes neurais alcançou resultados satisfatórios para a previsão do VaR em momentos de estabilidade. Por sua vez, os modelos estatísticos se comportaram de forma melhor para momentos de crise, talvez pelo fato do estudo demonstrar que as previsões estatísticas são constantemente superestimadas, frente ao modelo feito através de rede neural.

Gaio (2015) considerou papéis brasileiros e negociados em outros países, um total de 20 papéis, em seu estudo de VaR. Assim como o estudo de Maciel (2010), o retorno dos ativos

foi considerado como a variável de entrada da rede neural. Porém, a rede neural foi treinada com o desvio padrão móvel dos ativos. O resultado de Gaio (2015) foi concordante com o de Maciel (2010), redes neurais se mostraram satisfatórias para momentos estabilidade frente a momentos de instabilidade mercado.

Interessante notar que Oliveira (2010), em seu estudo de previsão de volatilidade, notou que o uso de redes neurais gera comportamentos abruptos de previsão na ocorrência de eventos extremos. Já o modelo via GARCH gerou muita contaminação na previsão dos eventos. Nesse caso, há uma suavidade na transição de cenários o que pode gerar uma previsão inadequada e superestimada o que corrobora com a argumentação que estudos estatísticos superestimam as previsões. Além disso, corrobora com os estudos que dizem que redes neurais têm dificuldade prever cenários de crise. O estudo utilizou de 6 a 8 neurônios em sua *hidden layer*, um estudo com mais neurônios poderia ser útil para avaliar se traria um comportamento mais suave em sua previsão.

Hajizadeh et al. (2012), diferente dos estudos que utilizaram o GARCH, compararam o modelo de rede neural com o modelo estatístico EGARCH, para a previsão de volatilidade. O modelo EGARCH captura resposta diferentes em cenários de perdas e ganhos. Eles utilizaram dados macroeconômicos (taxa de juros e cotação de moedas) e também a volatilidade gerada por modelos estatísticos através do EGARCH, como variáveis de entrada, para a sua rede neural. O resultado desse modelo, de acordo com os autores, foi uma melhor previsão do que as previsões feitas pelos modelos estatísticos.

Orozco e Velásquez (2013) por sua vez, só utilizaram como dados de entrada em sua rede neural, previsões de métodos estatísticos. Ou seja, diversas combinações de métodos estatísticos foram submetidas à rede neural para gerar um modelo que utilize informações individuais de cada um dos modelos. O resultado da rede neural, com a combinação dos modelos, foi mais bem sucedida do que os modelos individuais.

Monfared e Enke (2014) utilizaram um modelo híbrido de previsão ao considerar como dado de entrada do modelo a própria previsão da volatilidade através dos métodos estatísticos. Além do algoritmo *Backpropagation*, foram utilizados as redes neurais de regressão generalizada e base radial. As redes foram testadas em diversos momentos de crise americana como 2000, 2003, 2008 e 2010. O modelo com rede neural teve comportamentos diferentes a cada crise, portanto, o estudo não indica uma arquitetura definitiva para tratar essas situações. Além disso, comenta que em momentos de estabilidade não há necessidade da utilização de redes neurais, dado a sua alta complexidade.

Por fim, Kim e Won (2018) utilizaram uma *Recurrent Neural Network* para resolver o problema de previsão de volatilidade que se comportam de maneira diferente a depender da data de sua execução. Também utilizaram dados macroeconômicos como taxa de juros e taxa de câmbio para compor os dados de entrada do modelo de rede. Além da comparação com métodos que utilizem dados estatísticos, fizeram a comparação da *Recorrente Neural Network*

com uma *Feedforward Neural Network* treinada pelo algoritmo *Backpropagation*.

Identificou-se que há uma lacuna de eficiência na previsão de *Value-at-Risk* em momentos de crise. A previsão em momento de estabilidade é bem resolvida frente aos modelos de mudanças abruptas de cenário. Além disso, a maioria dos estudos utilizou dados da própria série financeira para compor a sua previsão. Poucos estudos utilizaram dados externos, como dados macroeconômicos, para enriquecer o modelo e a capacidade de identificação de comportamentos da rede. Por fim, a maioria dos estudos utiliza redes neurais de topologia *Feedforward*. Apenas um estudo de previsão de volatilidade utilizou de topologia de redes neurais de topologia recorrente.

2.3 Value-at-Risk

O Value-at-Risk ou Valor em Risco é um número que representa uma potencial perda financeira para determinado ativo ou grupos de ativos. Jorion (2003, p. 19) o define como: "VaR sintetiza a maior (ou pior) perda esperada dentro de determinados período de tempo e intervalo de confiança".

A primeira vez que o termo Value at Risk apareceu foi em um relatório sobre estudo de derivativos em 1993. Nesse relatório, ele é definido como: "[...] é a perda esperada de um movimento de mercado adverso com uma probabilidade específica para um determinado tempo" (GROUP OF THIRTY, 1993, p. 10, tradução nossa).

A partir de então, o VaR começou a ganhar destaque na comunidade acadêmica e no mercado. A sua notoriedade é ratificada pela publicação de recomendação pelo Comitê de Supervisão Bancária de Basileia em utilizar o Value-at-Risk. Em BASEL COMMITTEE ON BANKING SUPERVISION (2006, p. 311, tradução nossa) há a referência: "Sobre o *framework value-at-risk*, o risco medido é uma estimativa do que se pode perder, em uma determinada quantidade de posições, decorrentes de movimentos de mercados durante um determinado período de tempo e usando um nível de confiança específico".

O objetivo do número gerado pelo seu cálculo é prever o quanto uma carteira ou ativo pode mudar com base em oscilações de preços de ativos no mercado. Portanto, o seu uso é associado aos chamados riscos de mercado. Mudança de comportamento de taxa de juros, taxa de câmbio ou cotações em bolsas de valores, podem gerar um grande impacto em posições de carteiras de bancos e é necessário conhecê-lo.

O comitê da basileia ao padronizar o cálculo de capital exigido para riscos de mercado através do VaR, abriu espaços para que bancos utilizassem-no com segurança para montarem posições de proteção. É por essa razão que o seu uso pode também ser o da operações de hedge diárias contra a exposição calculada pelo VaR.

Apesar de gerar um número de fácil interpretação, o seu cálculo pode ser feito através de mais um método. O comitê da basileia não restringe qual modelo utilizar para o cálculo.

No seu documento, são citados os modelos de variância-covariância, simulação histórica e simulação de Monte Carlo (BASEL COMMITTEE ON BANKING SUPERVISION, 2006). O Banco Central do Brasil em sua circular 3.361 de 2007 depois revogada pela circular 3.634 de 2013 dispõe sobre o cálculo de VaR para fins do capital mínimo exigido (BACEN, 2013).

Gaio (2015) cita, por exemplo, que não existe na literatura um melhor modelo. As instituições utilizam o modelo que mais se adapta ao seu objetivo. Pode ser tomada a decisão de uma simplificação do método do cálculo em detrimento da precisão de seu número. Além disso, exemplifica com modelos utilizados por alguns bancos brasileiros como a simulação histórica, utilizada pelo Santander e o modelo de médias móveis exponencialmente ponderadas (EWMA), utilizada pelo BNDES.

Visto que mais de um modelo poder ser utilizado, é necessário que haja um meio de aferir se o modelo foi bem sucedido. É nesse ponto que é recomendado que haja uma maneira padronizada de validação se a previsão foi adequada e consequentemente conseguir antecipar potenciais perdas.

O mercado utiliza mecanismos de testes chamados *backtests* para realizar a verificação da eficiência de um modelo. O valor previsto é comparado com o valor real de perda, gerando as taxas de exceções. Um modelo extremamente conservador pode não gerar nenhuma exceção e mesmo assim não ser adequado. Nesse cenário há grande demanda de capital para proteção, gerando ineficiência na administração dos recursos. Um dos métodos utilizados para a realização dos *backtests* é o teste de Kupiec (KUPIEC, 1995).

Neste estudo, foi utilizado o modelo de cálculo VaR para distribuições paramétricas ou simplesmente VaR paramétrico. Esse cálculo assume que a taxa de variação do ativo segue uma distribuição de probabilidades e que o comportamento passado dos ativos pode influenciar o seu comportamento futuro. Por isso, em sua composição, também se utiliza uma medida de volatilidade.

O VaR paramétrico é simples de ser calculado. A posição a ser estudada é marcada a mercado (identificação do preço atual do ativo). É medida a variabilidade dos fatores de risco, um horizonte de tempo e um nível de confiança são definidos e, por fim, o valor é calculado (JORION, 2003). O VaR paramétrico, para um único papel, pode ser definido pela seguinte fórmula, ao se utilizar uma distribuição normal e o cálculo da volatilidade através do desvio padrão.

$$\text{VaR}_{\alpha}^t = vm_0 \cdot \alpha \cdot \sigma \cdot \sqrt{t} \quad (2.1)$$

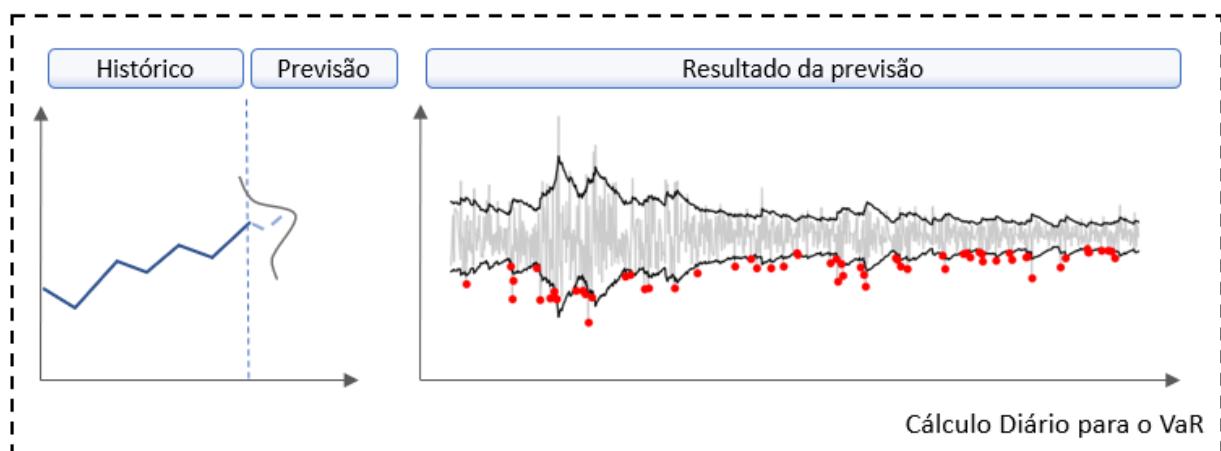
Esse modelo de cálculo pode ser encontrado em Jorion (2003) e Lin e Chen (2008), por exemplo. Basta saber o valor de mercado do papel vm_0 , o intervalo de confiança em uma distribuição de probabilidades α , a volatilidade histórica dos papéis, como por exemplo através do desvio padrão σ e por fim, a quantidade de dias futuros a serem previstos \sqrt{t} .

Para o modelo paramétrico, existem duas variáveis que afetam diretamente o valor previsto: a distribuição de probabilidades assumida e o cálculo de volatilidade utilizado. Os parâmetros utilizados, como intervalo de confiança e o tempo de previsão exigido também têm o seu peso.

A decisão da escolha do tempo pode estar relacionada ao prazo de liquidez do papel ou de sua carteira. O prazo de 1 dia é utilizado quando a carteira possui liquidez diária. O Banco Central do Brasil sugere o prazo de 10 dias para o cálculo do VaR para fins de exigência mínima de capital. Por outro lado, bancos podem também utilizar o prazo de 1 dia para calcular a perda potencial diária de suas carteiras. O intervalo de confiança utilizado também depende do nível de risco que o administrador deseja correr. O Banco Central do Brasil utiliza um intervalo de confiança de 99% (BACEN, 2013).

Independentemente do prazo e intervalo de confiança, o seu cálculo é feito diariamente para a próxima janela de tempo desejada. Dessa forma, os administradores de risco, sabem todos os dias, a exposição que a sua carteira terá para o prazo definido. Os dados passados são considerados e uma nova previsão é gerada. Se a previsão gerada não capturou a oscilação do preço, uma sinalização de exceção do VaR é computada. Veja na Figura 5 uma ilustração a respeito.

Figura 5 – Cálculo Diário para o VaR



Fonte: Elaborado pelo autor.

O lado direito da figura contém uma avaliação de VaR para um ativo financeiro. A oscilação de preços é apresentada com a cor cinza clara. O VaR calculado, pelo intervalo de confiança selecionado, é representado pelas bandas inferior e superior, em preto. Os pontos em vermelho são variações do preço do ativo que o modelo não conseguiu capturar, ou seja, o modelo foi ineficiente em identificar esses riscos. A soma, de todos os pontos em vermelho, representa a taxa de exceção do modelo para o período em estudo.

2.3.1 Distribuição de Probabilidades

Um dos componentes para o cálculo do VaR em seu método paramétrico é o uso de probabilidades. Os retornos diários dos ativos, para um período de tempo, são calculados e a distribuição desses retornos é avaliada. Com isso, a melhor distribuição de probabilidades pode ser encontrada para que esse componente do VaR, represente os dados a serem estudados.

Adcock e Meade (2017) propuseram um estudo para encontrar a melhor distribuição de probabilidades para a avaliação de risco de mercado utilizando árvores de decisão.

A distribuição normal é uma das distribuições utilizadas no cálculo do VaR. O seu uso é encorajado pela simplicidade do seu cálculo. O VaR passa a ser calculado considerando componentes como a média e variância dos dados em análise.

Outras distribuições podem ser utilizadas, visto que os dados podem não seguir uma distribuição normal. Jorion (2003, p. 82) sugere a avaliação de dois componentes de uma distribuição de probabilidades para a escolha de qual é a mais indicada. Um dos componentes é o coeficiente de assimetria. De acordo com o autor, "Um coeficiente de assimetria negativo indica que a distribuição possui uma longa cauda esquerda e, portanto, grandes valores negativos". Outro componente é o coeficiente de curtose. O autor comenta que sendo o coeficiente maior do que o da distribuição normal, há a probabilidade de ocorrência de valores extremos, negativos ou positivos.

Nilsson (2017), em seu estudo, comparou o cálculo do VaR através de seis distribuições de probabilidades distintas.

2.3.2 Volatilidade

Outra variável que pode interferir no cálculo do Value-at-Risk em seu método paramétrico é a volatilidade. Bussab e Morettin (2010, pg. 38) comentam sobre medidas de dispersão. Os autores descrevem que medidas de dispersão são utilizadas para representar a variabilidade de dados sob análise.

Em finanças o termo volatilidade é utilizado para identificar a medida de dispersão em torno de um título. A volatilidade de um papel, também pode ser utilizada como uma medida simplista de mensuração de risco. Quanto mais volátil é um título, mais propenso a riscos está o detentor desse título.

Hull (2009, p. 295) define: "A volatilidade de uma ação, σ , é a medida da incerteza sobre os retornos proporcionados pela ação". Portanto, um dos modelos de cálculo de volatilidade é o próprio desvio padrão de uma série financeira. Entendendo que a volatilidade reage de forma mais abrupta a altas oscilações de mercado e que há um declínio exponencial a medida que o choque do mercado fica no passado, o banco J.P. Morgan propôs uma média móvel ponderada de maneira exponencial ou EWMA (MORGAN; REUTERS, 1996).

O modelo de volatilidade ARCH ou Heterocedasticidade Condicional Auto-Regressiva (ENGLE, 1982), busca capturar o comportamento passado de forma temporal para refletí-lo na previsão de volatilidade. Bollerslev (1986), generalizou o modelo anterior através do modelo GARCH ou Heterocedasticidade Condicional Auto-Regressiva Generalizada. Outros estudos propuseram variações para o modelo ARCH (BOLLERSLEV, 2008).

Oliveira (2010) discorre sobre três comportamentos da volatilidade e as propriedades da não-linearidade de séries financeiras. A não linearidade: "a volatilidade responde de maneira diferente a retornos grandes e pequenos, tendendo a ser menor frente a variações das cotações pequenas e se torna mais pronunciada com alterações de cotações altas.". Efeito alavancagem: "a volatilidade tem comportamento distinto frente a retornos positivos e negativos de mesma magnitude. Variações das cotações para redução de seu valor são seguidas de maior volatilidade do que alterações de cotações no sentido de alta com mesmo valor em módulo.". Por fim, o agrupamento de volatilidade: "os mercados financeiros em alguns momentos são calmos e em outros instáveis [...] Nos momentos de alta volatilidade os retornos possuem maior variação, grande variância.".

Em Oliveira (2007) é possível identificar as fórmulas matemáticas envolvidas nos cálculos de volatilidade através dos modelos ARCH e GARCH, por exemplo.

Cada modelo de volatilidade gera um comportamento diferente. Kim e Won (2018) comentam que o modelo EWMA é melhor para capturar mudanças de curto prazo, enquanto que os modelos GARCH capturam bem o efeito de agrupamento e a não linearidade, porém, não capturam o efeito de alavancagem que o modelo EGARCH proposto por Nelson (1991) captura.

2.3.2.1 EWMA

Um dos cálculos de volatilidade empregados para o cálculo do VaR é da Média Móvel Exponencialmente Ponderada ou a sigla EWMA em Inglês. "A previsão para o instante t é a média ponderada da previsão anterior, à qual se atribui um peso λ , e a do quadrado da última inovação, à qual se atribui peso $(1 - \lambda)$ " (JORION, 2003, pg. 174).

Observe a fórmula abaixo:

$$h_t = \lambda h_{t-1} + (1 - \lambda)r_{t-1}^2 \quad (2.2)$$

O fator de decaimento λ proposto pela metodologia Morgan e REUTERS (1996) é de 0,94. O r representa o retorno no momento t para a série temporal.

2.3.2.2 GARCH

Outro modelo de cálculo de volatilidade é o modelo heterocedástico auto-regressivo generalizado ou GARCH. Esse modelo entende que a volatilidade atual depende da volatilidade anterior e também de uma fração do retorno anterior. "A variância condicional depende da inovação mais recente e, também, da variância condicional anterior. Define-se h_t como a variância condicional, usando-se as informações até o instante t-1, e r_{t-1} com o retorno do dia anterior" (JORION, 2003, p. 169).

Fórmula como descrito em (JORION, 2003)

$$h_t = \alpha_0 + \alpha_1 r_{t-1}^2 + \beta h_{t-1} \quad (2.3)$$

2.4 Redes Neurais Artificiais

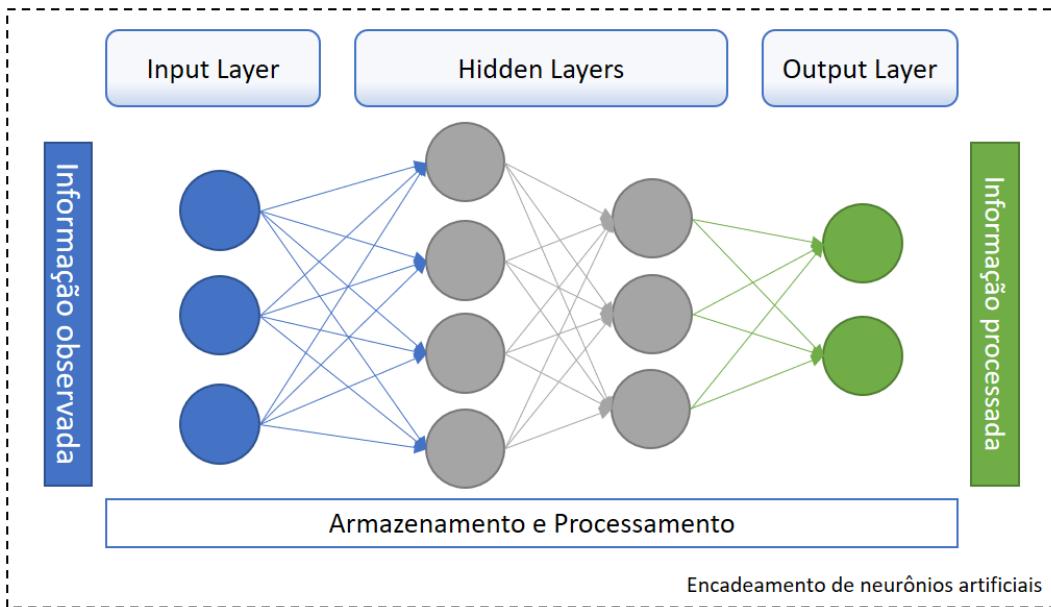
Redes neurais artificiais são modelos computacionais que procuram reproduzir o comportamento dos neurônios humanos e com isso, serem mais eficientes na execução de tarefas.

Neurônios humanos guardam informações e executam atividades através da formação de redes de conexão entre si. A rede é formada pelo encadeamento de neurônios. Um neurônio recebe informações de diversos neurônios através de terminações nervosas chamadas dendritos. Os impulsos elétricos são propagados através dos axônios e repassados adiante para outros neurônios através de um processo chamado sinapse. O cérebro humano possui mais de 100 milhões de neurônios organizados em redes (KREBS et al., 2012).

Redes neurais artificiais buscam atingir a capacidade de processamento do cérebro humano através da reprodução artificial de redes neurais naturais. Neurônios são transformados em modelos matemáticos e encadeados um a um para a formação de uma rede com topologia específica. Os neurônios são adicionados um após o outro e formam camadas de neurônios que propagam informações até que as informações recebidas sejam transformadas e compreendidas pela rede (BUDUMA; LOCASCIO, 2017).

A Figura 6 é um exemplo de uma Rede Neural Artificial. As informações observadas são recebidas na *input layer*, que as propaga para as *hidden layers* até atingir a *output layer*. Nesse processo, padrões previamente armazenados são confrontados contra os dados observados para gerar a informação resultante do modelo. Por exemplo, uma rede neural pode observar pixels de fotos e dizer se a foto é de um cachorro ou gato. Pode receber uma série de volume de chuvas históricas e prever a quantidade de milímetros previstos para chover no próximo dia.

Figura 6 – Rede Neural Artificial



Fonte: Elaborado pelo autor.

Uma rede neural, portanto, permite que o computador aprenda certos padrões, execute tarefas, reproduzindo um resultado esperado. Uma rede neural é dos modelos computacionais dos chamados "aprendizados de máquina".

Um modelo de aprendizado de máquina começa com a definição de um objetivo inicial, como determinar a fórmula de aprovação de crédito. Dados históricos são submetidos ao modelo, chamados de dados de treinamento. O modelo aprende como os dados se comportam, através de um algoritmo de aprendizado. O comportamento é armazenado, com isso, a hipótese final para a regra (aprovação de crédito) é definida. O modelo, portanto, aprendeu com os dados e poderá reproduzir o comportamento sempre que dados parecidos forem submetidos (ABU-MOSTAFA; MAGDON-ISMAIL; LIN, 2012).

Redes neurais podem ser utilizadas para resolver dois grupos de problemas :

- Problemas de Regressão
- Problemas de Classificação

Uma rede neural resolve um problema de regressão quando a sua saída gera valores contínuos, como a previsão do preço de uma ação. Ela resolve um problema de classificação quando a sua saída é um valor discreto que pode classificar algo, por exemplo, se uma foto é de um cachorro ou de um gato (GOODFELLOW; BENGIO; COURVILLE, 2016).

O método de aprendizagem através de redes neurais também, pode ser classificado de duas formas:

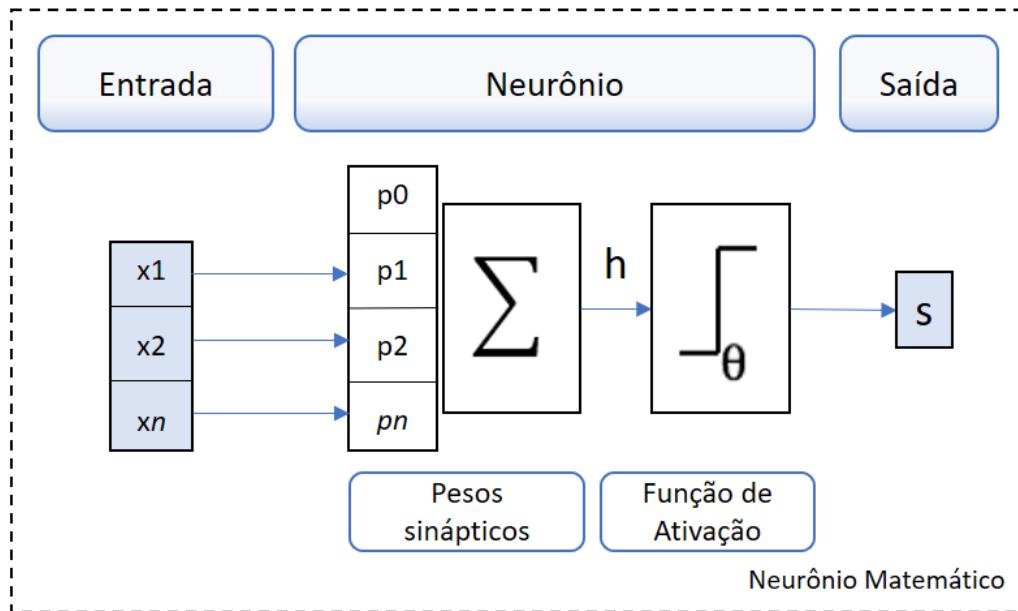
- Aprendizado Supervisionado
- Aprendizado Não Supervisionado

No aprendizado supervisionado o algoritmo de aprendizado é modelado com base nos dados de treinamento, assim, o modelo aprende o comportamento identificado durante essa fase. Ao submeter valores para serem previstos, o comportamento capturado durante o aprendizado será replicado. Os valores previsores e de previsão durante a fase de treinamento são conhecidos. O aprendizado não supervisionado acontece quando o valor esperado não é conhecido para um grupo de dados. O resultado do modelo pode ser: a probabilidade de determinado valor ou agrupamentos de dados para serem posteriormente analisados (GOODFELLOW; BENGIO; COURVILLE, 2016).

2.4.1 Neurônio Matemático

O neurônio biológico foi matematicamente modelado por McCulloch e Pitts (1943). Porém, o modelo computacional do neurônio utilizados nas redes neurais, ou perceptron, é nomeado através de Rosenblatt (1958). Seu estudo procura responder três questões: Como a informação é captada por um organismo biológico, como ela é armazenada e como o dado armazenado influencia o seu comportamento.

Figura 7 – Neurônio matemático



Fonte: Reproduzido, considerando p_0 como bias, de Marsland (2014)

Um perceptron, portanto, é capaz de captar, armazenar informações e influenciar um resultado. A captação é feita através de um vetor de números (x_1 , ..., x_n) que representam dados devidamente modelados. Os dados captados são chamados de características ou *features* (GOODFELLOW; BENGIO; COURVILLE, 2016). As características ou *features*, também, podem ser chamadas de dados previsores.

O armazenamento de seu comportamento é feito através dos pesos sinápticos (p_1 , à p_n). Cada peso (p_1 , à p_n) é multiplicado pelo dado original correspondente (x_1 , à x_n) e somado. O bias ou p_0 é adicionado para dar maior grau de liberdade ao modelo 2.4

$$h = p_0 + \sum_{i=1}^n x_i p_i \quad (2.4)$$

O resultado, h , é repassado para uma função, chamada função de ativação, que determinará qual é a influência desse perceptron para o próximo neurônio. Uma função de ativação, como em 2.5, excita ou ativa um neurônio, caso a somatória anterior supere um limite pré-determinado θ .

$$s = g(h) = \begin{cases} 1, & \text{se } h > \theta \\ 0, & \text{se } h \leq \theta \end{cases} \quad (2.5)$$

2.4.2 Função de Ativação

A função de ativação é a responsável por propagar o sinal resultante do perceptron para camadas posteriores da rede neural. A decisão de qual função de ativação utilizar determinará o comportamento da rede e o resultado apresentado.

Em um problema de classificação pode-se utilizar uma função sigmoide (fórmula 2.6) nas *hidden layers* e nas *output layers*. Essa função gerará uma saída entre 0 e 1. Para problemas de regressão, pode-se utilizar uma função sigmoide nas *hidden layers* e uma função somatória na *output layer* (MARSLAND, 2014).

$$s = g(h) = \frac{1}{1 + e^{-h}} \quad (2.6)$$

Outras funções de ativação podem ser utilizadas como: tangente hiperbólica, função linear retificadora e função de base radial (GOODFELLOW; BENGIO; COURVILLE, 2016).

Essa última dá nome a redes neurais que a utilizam dado o pioneirismo de seu estudo. O artigo que o apresentou utilizou uma topologia de três camadas, utilizando a função de base radial em sua *hidden layer* (BROOMHEAD; LOWE, 1988).

2.4.3 Topologia da Rede

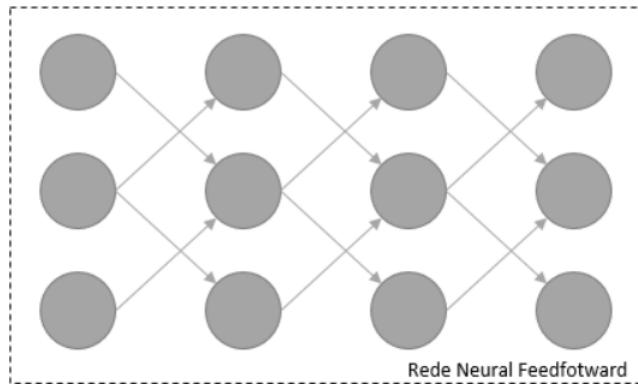
Outra característica de uma rede neural é a sua topologia. As redes podem ter múltiplas camadas, com diversos perceptrons e com distintas ligações para a propagação do sinal de dados. Uma rede neural pode ser classificada pela forma como seu sinal é propagado da *input layer* à *output layer*.

- *Feedforward Neural Network*
- Redes Neurais Recorrentes

Feedforward Neural Network ou Redes Neurais de Sentido Único são redes neurais que o sinal é propagado em uma única direção. Ou seja, o sinal entra pela primeira camada e é propagado até a última camada em uma única direção. Essas redes podem ter mais de uma camada com perceptrons conectados entre si, por isso, podem também ser chamadas de redes neurais de múltiplas camadas ou *Multilayer Perceptron Neural Network*.

Rumelhart, Hinton e Williams (1986) propuseram o algoritmo chamado Backpropagation para treinar redes dessa topologia. Redes neurais de múltiplas camadas treinadas com Backpropagation podem também ser chamadas de Backpropagation Neural Networks. A seguir é apresentado uma Rede Neural *Feedforward*. Veja que o sinal é propagado em uma única direção.

Figura 8 – Rede Neural *Feedforward*



Fonte: Reproduzido de Rumelhart, Hinton e Williams (1986)

Redes Neurais Recorrentes ou Recurrent Neural Network, por sua vez, permitem que um sinal seja retroalimentado durante a cadeia. O sinal pode ser armazenado e reutilizado em etapas futuras do processo. O algoritmo Backpropagation Through Time, pode ser utilizado para treinar redes dessa arquitetura (WILLIAMS; ZIPSER, 1989). Redes neurais recorrentes adicionam o componente temporal na topologia da rede permitindo que dados passados influenciem dados futuros.

Uma topologia desse tipo de rede é a conexão da saída de um perceptron com a entrada desse perceptron e de outros perceptrons da mesma camada na próxima iteração (BUDUMA; LOCASCIO, 2017). Dessa forma, dados produzidos por uma camada serão utilizados como dados de entrada pela mesma camada na próxima iteração de treinamento.

2.4.4 Redes LSTM

Existem redes neurais recorrentes que possuem limitações à capacidade de propagação de dados através do tempo, haja vista que informações futuras podem depender de informações iniciais. A rede neural Long Short-Term Memory ou LSTM se torna útil para que informações importantes não sejam perdidas ao longo da rede neural, ao adicionar uma memória de longo prazo à cada célula. (HOCHREITER; SCHMIDHUBER, 1997).

Redes neurais LSTM também resolvem o problema do *vanish gradient*, no qual os pesos sinápticos das camadas iniciais da rede neural se modificam cada vez menos à medida que grandes sequências de dados são submetidos à rede. É por essa razão que essas redes se adaptam tão bem à predição de séries temporais e de textos.(DI; BHARDWAJ; WEI, 2018)

Consideremos um exemplo para ilustrar a necessidade de propagação de dados iniciais ao final de uma cadeia de valores. Tomemos um problema de predição de textos, na qual existe a necessidade de se prever o final da frase. O texto começa com "Eu morei na França.", após isso, o texto detalha todas as maravilhas de se morar lá. Ao final há a conclusão "Eu aprendi francês". A informação do país está no começo da sentença e precisa ser propagada até o final para que o algoritmo consiga gerar a correta previsão. (MENSHAWY, 2018).

Uma célula LSTM possui uma arquitetura de camadas que seleciona qual informação precisa ser propagada para momentos temporários futuros. Na Figura 9 é possível visualizar o encadeamento temporal de uma célula A de uma rede LSTM. Dentro da célula são destacadas as suas camadas, bem como as variáveis utilizadas no modelo. X representa os dados de entrada, h representa os dados de saída e C representa o estado da célula propagado temporalmente.

Cada camada possui um objetivo específico. São três as camadas internas ou gates: *Forget Gate*, *Input Gate* e *Output Gate*.

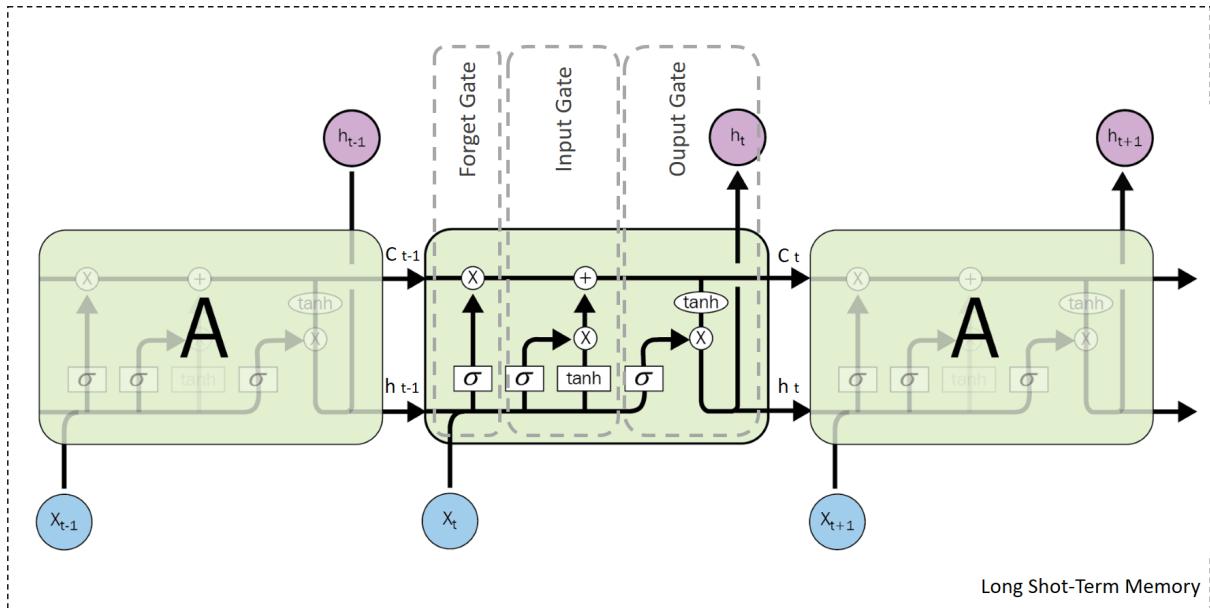
A *Forget Gate* decide qual estado anterior da célula C_{t-1} será apagado ou será propagado para a próxima etapa. Isso é feito através da multiplicação do estado anterior da célula com o resultado de uma função de ativação sigmóide. A função de ativação sigmoide considera a saída temporal anterior da célula h_{t-1} e a entrada atual da célula X_t .

Em seguida, o *Input Gate* decide qual informação será incorporada ao estado C da célula. Isso é feito através da soma do dado propagado pela *Forget Gate* e a multiplicação de duas funções de ativação tangente hiperbólica (\tanh) e mais uma função sigmóide.

Por fim, o *Output Gate* define qual será o valor da saída da célula h_t através da multiplicação do resultado da função sigmóide, dos dados de entrada, com a tangente hiperbólica

e o estado da célula (OLAH, 2015). O estado anterior da célula C_{t-1} , portanto, é utilizado como componente para definição da saída da visão temporal posterior. Ou seja, componentes temporárias anteriores serão considerados para calcular valores de saída da célula.

Figura 9 – Rede Neural LSTM



Fonte: Adaptado de (OLAH, 2015)

2.4.5 Overfitting e Underfitting

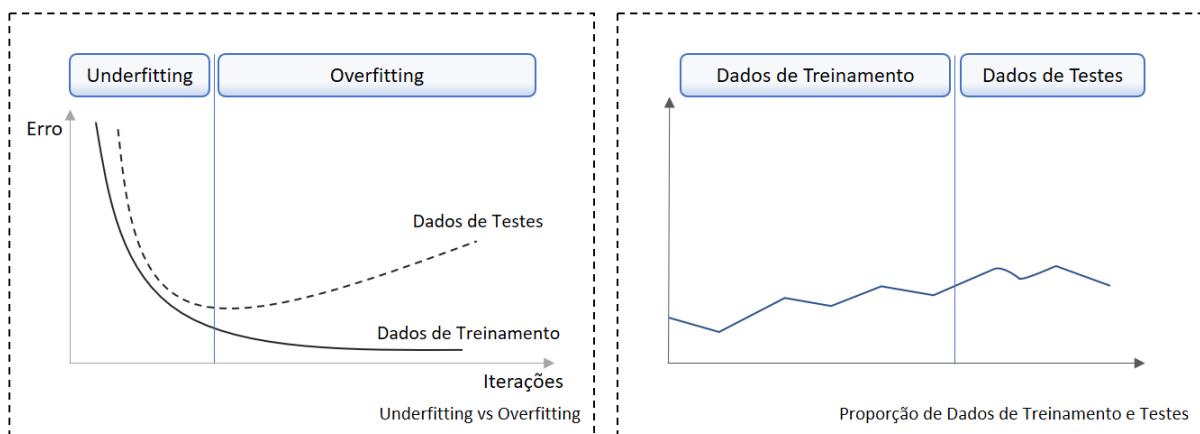
Uma das preocupações ao se trabalhar com redes neurais é a avaliação da validade do modelo. A rede neural deve ser generalizável, sendo satisfatória para qualquer conjunto de dados. Para verificar a sua generalização, medidas de erros são aplicadas para diferentes grupos de dados. O erro médio quadrático, por exemplo, avalia se o valor gerado pelo modelo é próximo do valor esperado. Uma das abordagens para essa validação é dividir a base de dados em dois grupos, uma treinamento e outra para testes. Uma proporção é aplicar 70% da base para treinamento e 30% da base de dados para testes.

Ao aplicar a base de dados de treinamento na rede neural é esperado que o erro do modelo vá decaindo ao longo do tempo, conforme a Figura 10. Os pesos sinápticos vão sendo ajustados até que o modelo seja o melhor possível. Aplica-se, em seguida, a base de testes no modelo. Goodfellow, Bengio e Courville (2016, pg. 111) citam dois fatores determinantes para uma boa performance de um modelo: A medida de erro da base de treinamentos deve ser pequena e a diferença entre o erro da base de treinamento e o da base de testes deve ser mínima. Dois comportamentos podem ser observados: Overfitting e Underfitting

O comportamento de Overfitting é representado pela boa adequação do modelo à base de treinamento, mas uma má adequação à base de testes. É um modelo que se adapta à complexidade dos dados apresentados no seu treinamento através de parametrizações que traduzam o comportamento da base de dados. Porém, ao ser generalizado para outros dados há um alto erro. Ou seja, o erro entre o dado esperado e o dado calculado ao testar o modelo é grande.

Underfitting é o comportamento na qual a rede neural não foi suficientemente boa para prever os dados apresentados tanto para base de treinamento quanto para a base de testes. É um modelo "preguiçoso", que não se esforça para atingir o seu objetivo de previsão dos dados.

Figura 10 – Validações do Modelo



Fonte: Adaptado de Marsland (2014) e Buduma e Locascio (2017)

3 PREPARAÇÃO PARA O EXPERIMENTO

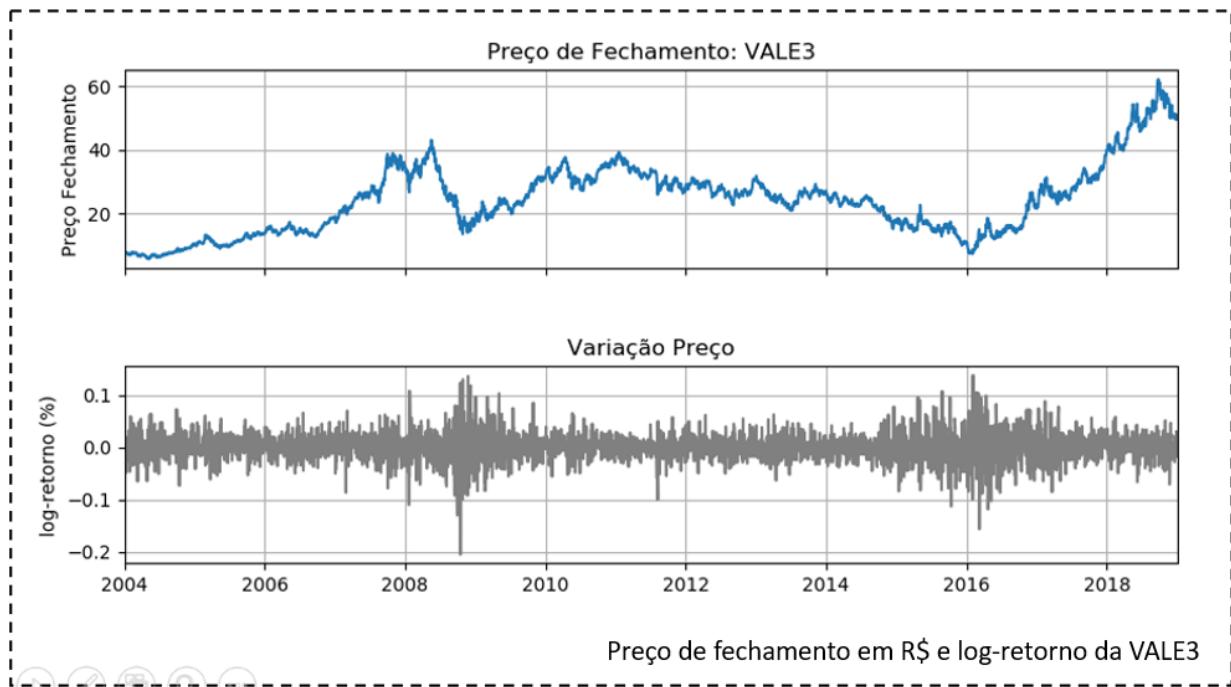
3.1 Dados para o Experimento

Foram utilizadas duas séries de dados para o experimento. Uma delas representa apenas uma empresa e outra a composição de ações de mais de uma empresa ou uma carteira de ações. Por isso, foram selecionados uma ação e um índice. São eles:

- VALE3
- IBOVESPA

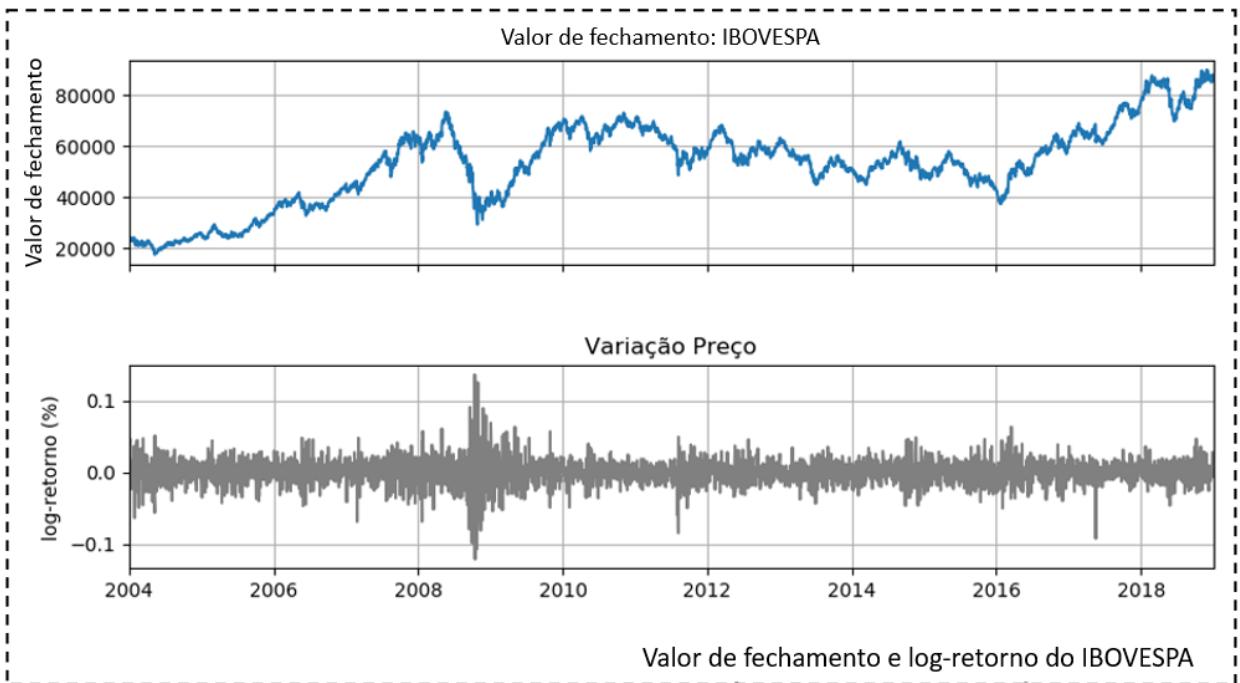
As próximas duas figuras, 11 e 12 apresentam essas séries de dados no período de 2004 à 2018.

Figura 11 – Preços de fechamento em R\$ da Vale no período



Fonte: Elaborado pelo autor

Figura 12 – Valor de fechamento do índice Bovespa no período



Fonte: Elaborado pelo autor

Foram utilizados dados macroeconômicos para compor as *features* ou previsores da rede neural LSTM, são eles:

- Valores de fechamento das séries a serem previstos
- Volumes negociados das séries a serem previstos
- Cotação de fechamento do Dólar frente ao Real
- Cotação de fechamento do Euro frente ao Real
- Taxa de Juros Brasileira
- Indicador de Inflação - IPCA

No apêndice D é possível visualizar a apresentação dos dados coletados e os primeiros e últimos valores de cada uma dessas séries de dados.

3.2 Métricas de Avaliação

Foram utilizadas três métricas de comparação entre os modelos paramétricos e os modelos que utilizam redes neurais. A composição das três métricas serve como validação da eficiência do modelo. São elas:

- Quantidade de Exceções
- Acurácia
- Erro Médio Quadrático

A primeira métrica de comparação é avaliar a quantidade de exceções que o modelo gerou. Ou seja, sempre que um valor real ultrapassar negativamente um dado de previsão, uma exceção será computada. Por exemplo, se o modelo previu 0,05% e tivemos um valor real de 0,06%, adicionamos uma unidade às quantidades de exceção. O modelo com mais exceções é considerado pior do que o modelo com menos exceções, denotado por N na equação 3.1.

$$\text{exceções} = N \quad (3.1)$$

O VaR calculado pelo modelo é comparado contra o log-retorno da diferença de dois dias do índice ou da ação para geração a exceção. Veja na equação 3.2 p_1 representando o dia na qual a previsão está sendo feita e o p_0 representando o dia anterior da previsão.

$$\text{log-retorno} = \ln(p_1/p_0) \quad (3.2)$$

O volume de acertos de uma amostragem T (T = quantidade de amostras), pode ser representado percentualmente através da acurácia, conforme equação 3.3.

$$\text{acurácia} = \frac{(T - N)}{(T)} \quad (3.3)$$

Por fim, o Erro Médio Quadrático (MSE), na equação 3.4, é calculado para verificar a diferença de previsões dos modelos. O valor y_e^i representa o valor esperado e o y_i^i representa o valor calculado. Dessa forma, conseguimos identificar o quanto distante do real uma exceção foi apresentada.

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (y_e^i - y_i^i)^2 \quad (3.4)$$

Após avaliar os três parâmetros, tomamos a decisão de qual modelo escolher como o mais eficiente, nessa ordem: Menor taxa de exceção, seguido por MSE de Teste, MSE de Previsão e MSE de Treino. Havendo uma diferença grande entre os MSEs, a melhor taxa de exceção subsequente é capturada. Ao encontrar algum valor discrepante que mereça consideração, mudamos a ordem de critério de seleção com as devidas justificativas.

- Menor Quantidade de Exceções
- Menor MSE de Treino, Teste e Previsão
- Menor Diferença de MSEs

Após escolher o melhor modelo dentre os paramétricos, *FeedForward* e LSTM, avaliamos a previsão sob o aspecto de mudanças abruptas de comportamento e crise.

3.3 Janelas de volatilidade e previsão

Uma definição relevante para os modelos de previsão é a janela considerada. A janela captura dados passados a fim de utilizá-los para prever um dia no futuro. Utilizamos três janelas de dados para os modelos paramétricos, são elas, 20, 60 e 1.000 dias.

3.3.1 Janela para modelo paramétrico

Os modelos que utilizaram desvio padrão e EWMA tiveram as suas volatilidades calculadas através de uma janela móvel de 20 e 60 dias, como sugerido por Jorion (2003, pg. 168). Ou seja, a cada dia de previsão de volatilidade, os últimos 20 ou 60 dias são utilizados. Os modelos que utilizaram GARCH tiveram as volatilidades calculadas de duas formas:

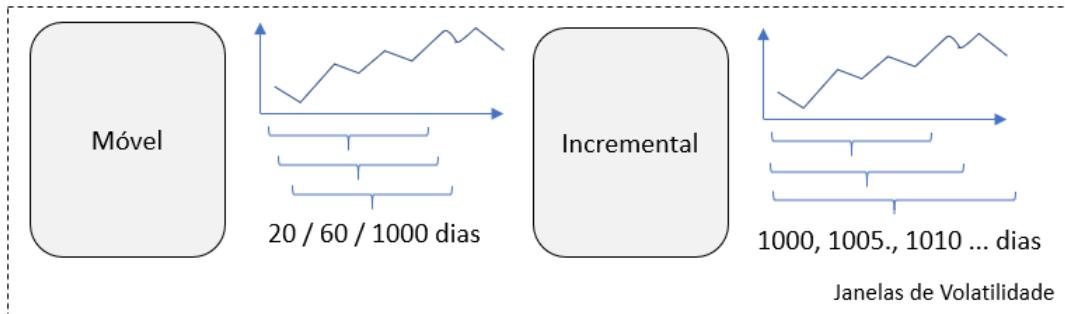
A primeira é através de uma janela fixa incremental. A janela começa com 1.000 dias e é incrementada a cada 5 dias concomitantemente com o recálculo dos parâmetros GARCH. Os parâmetros GARCH foram utilizados para calcular a volatilidade dos próximos 5 dias. Esse foi o método executado no estudo de Nilsson (2017) e aqui reproduzido.

A segunda forma é através de uma janela móvel de 1.000 dias. Os parâmetros GARCH foram recalculados a cada 5 dias, considerando os últimos 1.000 dias. Esses parâmetros foram utilizados para calcular os próximos 5 dias de volatilidade. Essa segunda forma se assemelha às janelas testadas no desvio padrão e EWMA, apenas com um período maior.

Portanto, a diferença da primeira forma para a segunda é a do uso de uma janela móvel de 1.000 dias e não de uma janela incremental. Entendemos ser relevante avaliarmos o GARCH como uma janela móvel haja vista a mesma comparação sendo feita para EWMA e desvio padrão. O período de 1.000 dias, utilizado por Nilsson (2017), parece fazer sentido pois utiliza dados de aproximadamente 4 anos, tempo em que é possível capturar comportamentos de longo prazo de uma série de dados.

A Figura 13 contém a ilustração de uma janela móvel e incremental para os períodos de 20, 60 e 1.000 dias para facilitar o entendimento.

Figura 13 – Janelas do cálculo de volatilidade



Fonte: Elaborado pelo autor

3.3.2 Janela rede neural

O melhor modelo de janela encontrado, dentre os 20 e 60 dias, para os modelos paramétricos foram reproduzidos para o modelo de rede neural.

De todo modo, utilizamos aproximadamente 1.000 dias para o treino da rede neural, sendo esse o período dividido entre as respectivas janelas. Entendendo que um ano possui 252 dias úteis, temos aproximadamente 4 anos de treino. O modelo é validado contra 428 dias para que tenhamos uma proporção de 70% e 30%. Ou seja, 1.000 são 70% e 428 são 30%.

Temos, portanto três períodos:

- Treino de aproximadamente 1.000 dias úteis de 01/01/2004 à 16/01/2008
- Teste de aproximadamente 428 dias úteis de 17/01/2008 à 29/09/2009
- Previsão de aproximadamente 2751 dias úteis de 16/01/2008 à 31/12/2018

Figura 14 – Janelas do cálculo de volatilidade



Fonte: Elaborado pelo autor

3.4 Montagem da rede neural

Este estudo não têm a pretensão de explorar todas as variáveis possíveis de configurações e parâmetros uma rede neural e com isso estudar comportamento resultante dessas mudanças. De todo o modo, é necessário variar minimamente alguns dos parâmetros a fim de verificar se há melhora na performance dos modelos para atingir o objetivo proposto deste estudo.

Dessa forma, algumas variações entre os modelos foram colocadas:

- Período de atualização dos pesos: *Batch Gradient Descent*, *Stochastic Gradient Descent* ou *Mini-Batch Gradient Descent*
- Função de ativação das camadas hidden para redes *Feedforward*: sigmóide, tangente hiperbólica e *Rectified Linear Unit*
- Quantidade de Neurônios da primeira *hidden layer*
- Quantidade de *hidden layers*
- Quantidade de Neurônios nas camadas *hidden layers* subsequentes

Além disso, alguns ajustes foram feitos a fim de verificar se há mudança no comportamento da previsão são eles:

- Percentual de taxa de correção do VaR paramétrico
- Preço de fechamento como previsor para *Feedforward*
- Combinação de previsores para redes LSTM

Para os dados de entrada, utilizamos as 60 informações anteriores à informação que está sendo prevista e fizemos a previsão para o dia subsequente. O número 60 é igual a quantidade de dias do melhor dado de volatilidade encontrado na Etapa 1, da Figura 15 a ser explorado na próxima seção.

A função custo é o erro médio quadrático (*Mean Squared Error*), da mesma forma como o critério de avaliação do VaR conforme seção 3.2.

Experimentamos três modos de cálculo de atualização dos pesos após o cálculo do custo. *Batch Gradient Descent*, quando a atualização acontece após todos os dados de treinamento serem avaliados. *Stochastic Gradient Descent*, quando a atualização acontece quando um dado ser avaliado. *Mini-Batch Gradient Descent*, quando a atualização acontece após um número fixo de dados serem avaliados, experimentamos três parâmetros: 32, 64 e 128.

Utilizamos para os *output layers* a função de ativação linear. Para redes *Feedforward*, fizemos uma variação das funções de ativação. Para as *hidden layers* experimentamos três funções de ativação são elas: sigmóide, tangente hiperbólica e *Rectified Linear Unit*.

Para encontrar a melhor quantidade de neurônios, encontramos dois métodos descritos no estudo de Panchal e Panchal (2014). O primeiro é o *Rule of Thumb Method*, são três propostas: a quantidade de neurônios deve ser algo entre a quantidade de dados de entrada versus a quantidade de dados de saída, ele é na proporção de 2/3 da quantidade de dados de

entrada ou é menor do que o dobro da quantidade de dados de entrada. O segundo método é o *Try and Error Method* com o *Forward approach* em que um número pequeno de neurônios é utilizado e é aumentado até se atingir um bom resultado. Para a quantidade de *hidden layers* utilizamos o método *Forward approach* em que aumentamos a sua quantidade até atingir um dado satisfatório.

Utilizamos uma quantidade de 2.000 épocas, porém, paramos de treinar quando não obtivemos melhora por 200 épocas. Começamos com uma taxa de atualização de 0,0001 e a reduzimos em 0,1 a cada 20 épocas sem melhora do custo.

Também, mudamos e/ou adicionamos *features*/previsores para validar se haveria melhora nos modelos.

Após encontrarmos o melhor modelo, fizemos um ajuste no valor de treinamento do VaR paramétrico a fim de aproximá-lo da queda real identificada. Fizermos um ajuste de 1%, 5% e 10% no valor do VaR para mais e para menos até atingir o limite superior e inferior do log-retorno. Outras técnicas de suavização de valores podem ser realizadas em estudos futuros.

3.5 Estratégia do Experimento

Nessa seção, detalhamos a sequência de execução do experimento e a sua estratégia. São três, os modelos comparados:

- Modelo Paramétrico
- Modelo com *Feedforward Neural Network*
- Modelo com rede *LSTM*

Os três modelos fazem a previsão do VaR, para as séries financeiras selecionadas, para o próximo dia útil de divulgação de informações dessa série.

A primeira etapa do experimento foi o cálculo do Value-at-Risk através do modelo paramétrico para três séries de dados, OMXS30, IBOVESPA e VALE3. O resultado do VaR calculado com a série OMXS30 foi comparado com o resultado apresentado pelo estudo de Nilsson (2017). Essa comparação serviu como ponto de referência entre os dois estudos. Em seguida, foi escolhido o modelo, dado a variabilidade de parâmetros, que trouxe melhor resultado para as séries IBOVESPA e VALE3. O modelo escolhido serviu como base de comparação para as próximas etapas do experimento.

A segunda etapa do experimento foi o cálculo através de uma rede *Feedforward* para séries IBOVESPA e VALE3. Foi utilizado como dados de treinamento da rede neural o melhor modelo paramétrico encontrado na etapa anterior. Também foi escolhido o melhor resultado encontrado e comparado com o resultado do modelo paramétrico.

A terceira etapa do experimento foi o cálculo através de uma rede LSTM para as séries IBOVESPA e VALE3. Também foi utilizado como base de treinamento o resultado do melhor

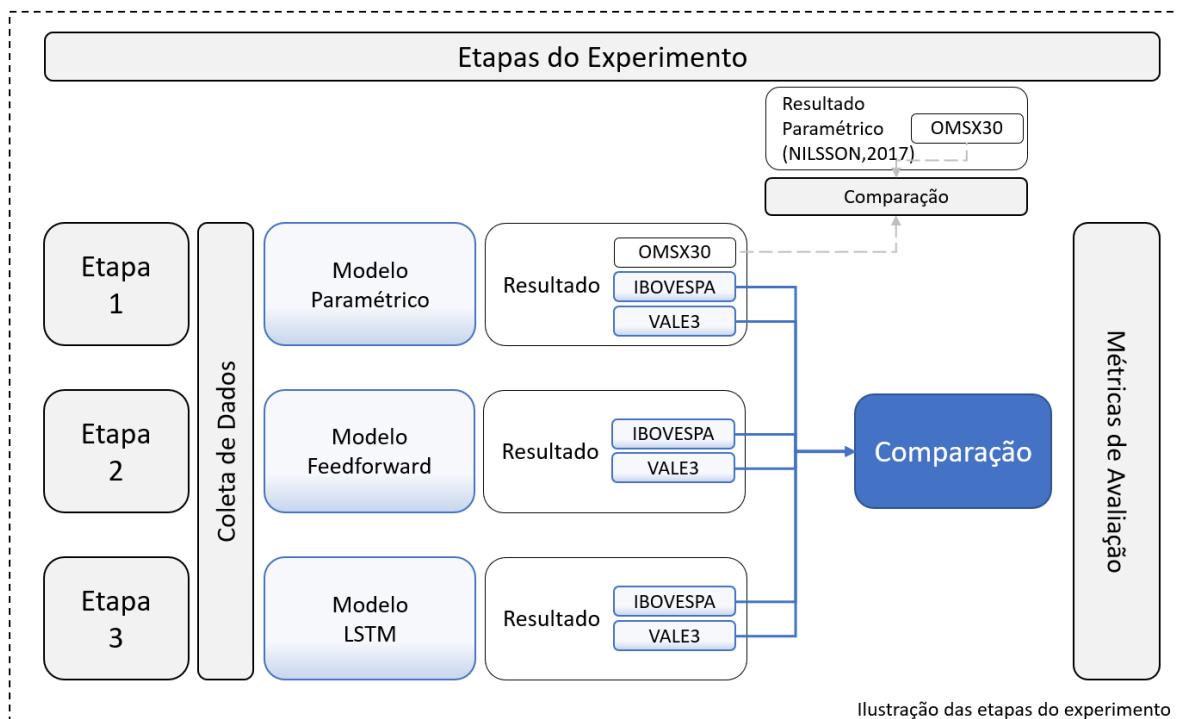
VaR paramétrico encontrado. Para essa topologia, foi explorado a variabilidade do cálculo através da adição do uso de dados macroeconômicos como previsores da rede LSTM. Foi incorporado o próprio VaR como atributo previsor em conjunto com os dados macroeconômicos bem como a sua supressão para verificar a viabilidade desse tipo de construção. Como os anteriores, foi escolhido o melhor resultado e comparamos com o modelo *Feedforward*.

Por fim, foi comparado o melhor resultado dos três modelos e apresentado as conclusões do experimento. Nessa etapa, validamos qual topologia de rede neural foi mais eficiente dado as métricas usadas neste estudo. Chegamos à conclusão, avaliando o resultado dos modelos contra o objetivo do estudo, ou seja, a validação da eficiência dos modelos em momentos de crise ou mudança abrupta de comportamento.

Para cada um das três formas de avaliação, variamos os modelos para identificar qual grupo de parâmetros têm o melhor resultado. O objetivo é identificar qual configuração de rede neural consegue se adaptar melhor á esse tipo de previsão e com isso explorar essa configuração variando previsores e o VaR utilizado como treinamento. As seções 3.5.0.1, 3.5.1 e 3.5.2, contém especificidades de cada um dos três modelos.

A comparação foi feita através das métricas especificadas na seção 3.2. A seção 3.1 contém detalhes sobre a coleta dos dados utilizados na execução dos modelos. Para facilitar a compreensão, a Figura 15, ilustra as etapas do experimento. As próximas seções demonstram os atributos previsores e previstos utilizados em cada um dos modelos.

Figura 15 – Etapas do Experimento



Fonte: Elaborado pelo autor

3.5.0.1 Etapa 1 - Modelo Paramétrico

Essa foi a primeira etapa do experimento, conforme descrito na Figura 15. O VaR utilizado para os previsores e para a previsão foi o melhor modelo encontrado na previsão paramétrica. Foram utilizados doze modelos paramétricos, são eles:

Tabela 1 – Modelos do Experimento Paramétrico

Nome	Intervalo Confiança	Distribuição Probabilidades	Volatilidade	Janela	Período
P1	95%	Normal	Desvio Padrão	Móvel	20 dias
P2	95%	Normal	Desvio Padrão	Móvel	60 dias
P3	95%	Normal	EWMA	Móvel	20 dias
P4	95%	Normal	EWMA	Móvel	60 dias
P5	95%	Normal	GARCH	Incremental	1.000 dias
P6	95%	Normal	GARCH	Móvel	1.000 dias
P7	99%	Normal	Desvio Padrão	Móvel	20 dias
P8	99%	Normal	Desvio Padrão	Móvel	60 dias
P9	99%	Normal	EWMA	Móvel	20 dias
P10	99%	Normal	EWMA	Móvel	60 dias
P11	99%	Normal	GARCH	Incremental	1.000 dias
P12	99%	Normal	GARCH	Móvel	1.000 dias

Fonte: Elaborado pelo autor

O objetivo foi definir qual desses modelos têm o melhor comportamento. Para todos eles, o VaR é calculado para o horizonte de um dia com distribuição normal de probabilidades. São validados três modelos de volatilidade: desvio padrão, EWMA e GARCH.

Utilizamos dois intervalos de confiança 95% e 99% para aferir o melhor modelo de volatilidade. Para as próximas etapas, seguimos com a validação das redes neurais com o intervalo de 95%. O melhor modelo encontrado para o cálculo de VaR paramétrico foi utilizado como base de comparação para os experimentos com redes neurais.

3.5.1 Etapa 2 - Modelo com Rede Neural *Feedforward*

Essa foi a segunda etapa do experimento, conforme Figura 15. Como explorado na seção 3.5, a rede neural foi treinada com o melhor resultado do VaR paramétrico encontrado na Etapa 1 do experimento. O desafio dessa etapa foi a de encontrar os melhores atributos da topologia *Feedforward* que gerem as melhores métricas possíveis e após isso variar os previsores e ajustar o VaR para encontrar uma melhor previsão para o modelo.

A Tabela 2 contém os experimentos a realizados nessa etapa.

Tabela 2 – Modelos do Experimento Feedforward

Nome	Batch Size	Ativação Hidden Layer	Camadas Células	Previsores	Previsão	% Ajuste
FF-1	940	Sigmóide	60,30,1	VaR	VaR	0%
FF-2	1	Sigmóide	60,30,1	VaR	VaR	0%
FF-3	32	Sigmóide	60,30,1	VaR	VaR	0%
FF-4	64	Sigmóide	60,30,1	VaR	VaR	0%
FF-5	128	Sigmóide	60,30,1	VaR	VaR	0%
FF-6	Fixo	Tanh	60,30,1	VaR	VaR	0%
FF-7	Fixo	ReLU	60,30,1	VaR	VaR	0%
FF-8	Fixo	Fixo	60,20,1	VaR	VaR	0%
FF-9	Fixo	Fixo	60,40,1	VaR	VaR	0%
FF-10	Fixo	Fixo	60,60,1	VaR	VaR	0%
FF-11	Fixo	Fixo	60,80,1	VaR	VaR	0%
FF-12	Fixo	Fixo	60,100,1	VaR	VaR	0%
FF-13	Fixo	Fixo	60,120,1	VaR	VaR	0%
FF-14	Fixo	Fixo	60,Fixo,Variável,1	VaR	VaR	0%
FF-15	Fixo	Fixo	60,Fixo,Variável,1	VaR	VaR	0%
FF-16	Fixo	Fixo	60,Fixo,Variável,1	VaR	VaR	0%
FF-17	Fixo	Fixo	60,Fixo,Variável,1	VaR	VaR	0%
FF-18	Fixo	Fixo	Fixo	Fechamento	VaR	0%
FF-19	Fixo	Fixo	Fixo	Fixo	VaR	1%
FF-20	Fixo	Fixo	Fixo	Fixo	VaR	5%
FF-21	Fixo	Fixo	Fixo	Fixo	VaR	10%

Fonte: Elaborado pelo autor

3.5.2 Etapa 3 - Modelo com Rede Neural *LSTM*

Essa foi a terceira etapa do experimento, conforme Figura 15. Também, como explorado na seção 3.5, a rede neural foi treinada com o melhor resultado do VaR paramétrico encontrado na Etapa 1 do experimento. Além de procurar encontrar a melhor topologia adicionamos dados macroeconômicos para a variação dos previsores antes do ajuste para encontrar uma melhor eficiência do VaR.

A estratégia de descoberta da melhor topologia é análoga à da rede neural *Feedforward*. A exceção é a não variabilidade das funções de ativação, visto seguirmos com as funções padrões dentro da célula de memória.

A Tabelas 3 contém os experimentos realizados nessa etapa.

Tabela 3 – Modelos do Experimento LSTM

Nome	Batch Size	Camadas Células	Previsores	Previsão	% Ajuste
LSTM-1	940	60,30,1	VaR	VaR	0%
LSTM-2	1	60,30,1	VaR	VaR	0%
LSTM-3	32	60,30,1	VaR	VaR	0%
LSTM-4	64	60,30,1	VaR	VaR	0%
LSTM-5	128	60,30,1	VaR	VaR	0%
LSTM-6	Fixo	60,20,1	VaR	VaR	0%
LSTM-7	Fixo	60,40,1	VaR	VaR	0%
LSTM-8	Fixo	60,60,1	VaR	VaR	0%
LSTM-9	Fixo	60,80,1	VaR	VaR	0%
LSTM-10	Fixo	60,100,1	VaR	VaR	0%
LSTM-11	Fixo	60,120,1	VaR	VaR	0%
LSTM-12	Fixo	60,Fixo,Variável,1	VaR	VaR	0%
LSTM-13	Fixo	60,Fixo,Variável,1	VaR	VaR	0%
LSTM-14	Fixo	60,Fixo,Variável,1	VaR	VaR	0%
LSTM-15	Fixo	60,Fixo,Variável,1	VaR	VaR	0%
LSTM-16	Fixo	60,Fixo,Variável,1	VaR	VaR	0%
LSTM-17	Fixo	60,Fixo,Variável,1	VaR	VaR	0%
LSTM-18	Fixo	Fixo	Variável	VaR	0%
...	0%
LSTM-31	Fixo	Fixo	Variável	VaR	0%
LSTM-32	Fixo	60,Variável,1	Fixo	VaR	0%
LSTM-33	Fixo	60,Variável,1	Fixo	VaR	0%
LSTM-34	Fixo	60,Variável,1	Fixo	VaR	0%
LSTM-35	Fixo	Fixo	Variável	VaR	Variável
...
LSTM-40	Fixo	Fixo	Variável	VaR	Variável

Fonte: Elaborado pelo autor

Deixamos um espaço para experimentação variável após encontrarmos o melhor conjunto de previsores para o LSTM. Ao adicionar previsores, a complexidade da rede aumentou e pudemos experimentar novos conjuntos de dados, como mais camadas de células, para chegar ao melhor resultado possível.

3.5.3 Análise e Apresentação dos dados

As tabelas com os resultados dos experimentos estão apresentadas na seção 4.

A representação gráfica dos melhores modelos, tanto para o paramétrico, *Feedforward* quanto para o LSTM é feita no apêndice deste estudo. Os primeiros e últimos valores das séries previstas foram apresentados para que estudos futuros pudessem comparar os valores encontrados neste estudo.

Ao final, cada os melhores modelos encontrados para a previsão paramétrica, *Feedforward* e LSTM foram analisados contra cenários de crise e mudanças abruptas de comportamento. Analisamos os 5 piores cenários de quedas abruptas.

4 EXPERIMENTO

4.1 Ambiente de trabalho

O experimento foi feito em uma máquina pessoal com processador Intel I7-8750H com 6 núcleos e 12 processadores lógicos. A máquina contém 16 GB de memória RAM e um disco SSD Liteon CV8-8E256-11. A descrição da máquina é relevante para aqueles que querem avaliar a performance do treinamento das redes neurais.

A linguagem Python foi selecionada como linguagem de programação para o desenvolvimento do experimento. O ambiente foi criado a partir da distribuição da Anaconda. Abaixo uma tabela com os componentes e versões mais relevantes utilizados na instalação.

Tabela 4 – Componentes do ambiente do experimento

Tipo	Nome	Versão
Linguagem	Python	3.6.8
IDE	Spyder	3.3.2
Biblioteca	Pandas	0.24.0
Biblioteca	Numpy	1.54.4
Biblioteca	Matplotlib	3.0.2
Biblioteca	Keras	2.2.4
Biblioteca	Tensorflow	1.12.0
Biblioteca	arch	4.7.0

Fonte: Elaborado pelo autor

Utilizamos a biblioteca arch de Sheppard et al. (2018) para estimar os parâmetros α_0 , α_1 e β do GARCH, conforme fórmula 2.3.

4.2 Etapa 1 - Comparaçāo com estudo preliminar

O experimento iniciou-se através do cálculo do Value-at-Risk através do método paramétrico. Calculamos o VaR para a série OMXS30 e comparamos com os resultados obtidos por Nilsson (2017). Utilizamos os intervalos de confiança de 95% e 99% com a volatilidade através do GARCH. Portanto, são usados os modelos P5 e P11 da Tabela 1.

A volatilidade é calculada considerando os primeiros 1.000 dias, de 03/01/1990 à 28/12/1993. Os parâmetros GARCH são calculados e utilizados para prever a volatilidade dos próximos 5 dias. O apêndice C contém a série dos parâmetros GARCH calculados para o OMXS30. A partir de 29/12/1993 e concluindo em 30/12/2016 as previsões foram feitas com 5.778 dados de testes.

A Tabela 5 contém os resultados obtidos para esse experimento.

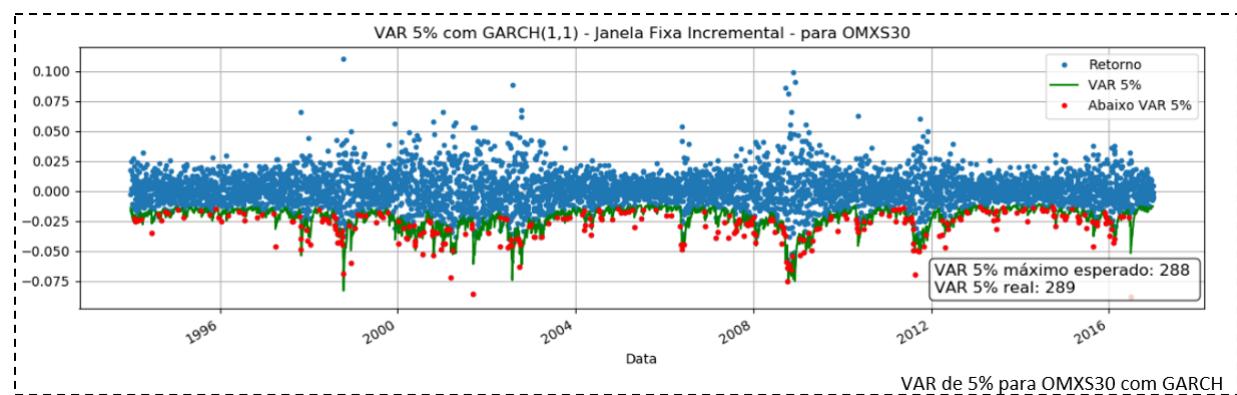
Tabela 5 – Resultado Experimento OMXS30

Nome	Máx Experado	Exceções	Acurácia	MSE	Exceções Nilsson
P5	288	289	95,00%	0,00083850	301
P11	57	73	98,74%	0,00144832	75

Fonte: Elaborado pelo autor

Se compararmos com o experimento de Nilsson (2017), tanto a série de parâmetros do GARCH quanto as taxas de exceções dos dois experimentos são equivalentes, o que valida essa primeira etapa do experimento. No apêndice B apresentamos os dados utilizados e no apêndice C apresentamos as taxas de exceções e parâmetros GARCH.

Figura 16 – Value-at-Risk para OMXS30



Fonte: Elaborado pelo autor

4.3 Etapa 1 - Previsão paramétrica para IBOVESPA e VALE3

Ainda na Etapa 1 fizemos a previsão paramétrica para as séries IBOVESPA e VALE3. Nessa etapa, executamos o experimento para todos os modelos previstos na Tabela 1, ou seja, P1 à P12. A Tabela 6 contém o resultado do experimento para o IBOVESPA. Já a Tabela 7 contém o resultado do experimento para a VALE3.

Tabela 6 – Resultado Experimento Paramétrico IBOVESPA

Nome	Máx Experado	Exceções	Acurácia	MSE
P1	135	141	94,80%	0,00113559
P2	135	146	94,62%	0,00114080
P3	135	220	91,89%	0,00088161
P4	135	133	95,10%	0,00111070
P5	135	131	95,17%	0,00112337
P6	135	142	94,77%	0,00110237
P7	27	27	99,01%	0,00196605
P8	27	37	98,64%	0,00197176
P9	27	58	97,86%	0,00147196
P10	27	21	99,23%	0,00191505
P11	27	32	98,82%	0,00194011
P12	27	31	98,86%	0,00189762

Fonte: Elaborado pelo autor

Tabela 7 – Resultado Experimento Paramétrico VALE3

Nome	Máx Experado	Exceções	Acurácia	MSE
P1	135	143	94,73%	0,00294811
P2	135	142	94,77%	0,00294380
P3	135	225	91,71%	0,00231174
P4	135	138	94,92%	0,00288044
P5	135	134	95,07%	0,00285839
P6	135	140	94,84%	0,00289952
P7	27	26	99,04%	0,00510039
P8	27	36	98,67%	0,00508840
P9	27	61	97,75%	0,00382842
P10	27	18	99,34%	0,00496351
P11	27	37	98,64%	0,00491929
P12	27	34	98,75%	0,00500028

Fonte: Elaborado pelo autor

Nota-se que a diferença entre a acurácia dos modelos com intervalos de confiança 95% e 99% é compatível com o aumento do erro apresentado nesses dois grupos. Quanto maior o intervalo de confiança, melhor é a acurácia e pior é o erro. Intervalos de confiança maiores geram resultados mais conservadores e distantes da série de dados real.

Tanto para o IBOVESPA quanto para a VALE3 no grupo de intervalo de confiança de 95%, P1 à P6, obtivemos um melhor resultado para as volatilidades EWMA com 60 dias e GARCH incremental. Os modelos P4 e P5 obtiveram as menores taxas de exceção, maiores

acuráncias e erros compatíveis. Esse foi o mesmo resultado tanto para IBOVESPA quanto para a VALE3. Para o grupo de intervalo de confiança de 99%, P7 à P12, obtivemos um melhor resultado para as volatilidades desvio padrão com 20 dias e EWMA com 60 dias ou modelos P7 e P10 respectivamente.

Concluímos que o melhor modelo para os dois intervalos de confiança foi o modelo com EWMA de 60 dias. Dessa forma, utilizamos o modelo P4 para as janelas de previsão para as redes neurais e como comparador de resultados.

O apêndice D contém os primeiros e últimos dados do IBOVESPA e VALE3 representados em tabela. As séries foram também plotadas. O apêndice E e F contém os gráficos do VaR com as taxas de exceção e tabela com valores previstos para os experimentos P4, P5, P7 e P10 para o IBOVESPA e VALE3 respectivamente.

4.4 Etapa 2 - Previsão com rede Feedforward para IBOVESPA e VALE3

É na etapa 2 que iniciamos a previsão do VaR através de redes neurais para o IBOVESPA e VALE3. A Tabela 8 contém os modelos testados enquanto a Tabela 9 contém o resultado. Em negrito, na Tabela 8, temos os parâmetros fixados para as interações seguintes. Já o negrito da Tabela 9 representa o modelo selecionado.

Tabela 8 – Modelos *Feedforward* - IBOVESPA

Nome	Batch Size	Ativação Hidden Layer	Camadas Células	Previsores	Previsão	% Ajuste
FF-1	940	Sigmóide	60,30,1	VaR	VaR	0%
FF-2	1	Sigmóide	60,30,1	VaR	VaR	0%
FF-3	32	Sigmóide	60,30,1	VaR	VaR	0%
FF-4	64	Sigmóide	60,30,1	VaR	VaR	0%
FF-5	128	Sigmóide	60,30,1	VaR	VaR	0%
FF-6	128	Tanh	60,30,1	VaR	VaR	0%
FF-7	128	ReLU	60,30,1	VaR	VaR	0%
FF-8	128	Sigmóide	60,20,1	VaR	VaR	0%
FF-9	128	Sigmóide	60,40,1	VaR	VaR	0%
FF-10	128	Sigmóide	60,60,1	VaR	VaR	0%
FF-11	128	Sigmóide	60,80,1	VaR	VaR	0%
FF-12	128	Sigmóide	60,100,1	VaR	VaR	0%
FF-13	128	Sigmóide	60,120,1	VaR	VaR	0%
FF-14	128	Sigmóide	60,30,30,1	VaR	VaR	0%
FF-15	128	Sigmóide	60,30,15,1	VaR	VaR	0%
FF-16	128	Sigmóide	60,30,15,15,1	VaR	VaR	0%
FF-17	128	Sigmóide	60,30,15,7,1	VaR	VaR	0%
FF-18	128	Sigmóide	60,30,1	Fechamento	VaR	0%
FF-19	128	Sigmóide	60,30,1	VaR	VaR	1%
FF-20	128	Sigmóide	60,30,1	VaR	VaR	5%
FF-21	128	Sigmóide	60,30,1	VaR	VaR	10%

Fonte: Elaborado pelo autor

A primeira escolha de parâmetros aconteceu entre os experimentos FF-1 para o FF-5. Nesse momento decidimos qual *batch size* utilizaríamos para os experimentos seguintes. A melhor taxa de exceção foi o FF-2, porém, com uma alta taxa de erro no MSE de Teste. Por isso, decidimos pela execução FF-5, por ter a menor taxa de exceção do modelo após o modelo FF-2.

A segunda escolha de parâmetros aconteceu entre os experimentos FF-5 e FF-7, no momento em que experimentamos outras funções de ativação nas *hidden layers*. Apesar de não haver muita diferença entre as taxas de exceção, notamos uma diferença considerável entre o MSE de Treino e MSE de Teste. Como o teste é feito em um grande período de volatilidade, veja o gráfico D, um erro diferente entre treino e teste mostra que o modelo não conseguiu performar bem durante o período de queda das cotações. Por isso, mantivemos a função de ativação sigmoidal.

Tabela 9 – Experimento *Feedforward* - IBOVESPA

Nome	Máx Experado	Exceções	Acurácia	MSE Previsão	MSE Treino	MSE Teste
FF-1	135	149	94,51%	0,00107425	0,00338769	0,03600977
FF-2	135	143	94,73%	0,00113964	0,00155151	0,12150621
FF-3	135	152	94,40%	0,00111745	0,00172081	0,02472096
FF-4	135	150	94,47%	0,00109410	0,00199947	0,01767988
FF-5	135	147	94,58%	0,00112418	0,00251834	0,02074686
FF-6	135	150	94,47%	0,00106379	0,00231863	0,05436109
FF-7	135	152	94,40%	0,00164790	0,00230329	2,19043453
FF-8	135	150	94,47%	0,00109119	0,00211122	0,02579722
FF-9	135	151	94,44%	0,00109495	0,00202951	0,01848576
FF-10	135	151	94,44%	0,00109792	0,00197274	0,01388717
FF-11	135	152	94,40%	0,00109737	0,00192877	0,01600972
FF-12	135	153	94,36%	0,00109845	0,00196874	0,01235423
FF-13	135	152	94,40%	0,00110020	0,00197154	0,01111870
FF-14	135	152	94,40%	0,00106754	0,00209746	0,05271987
FF-15	135	147	94,58%	0,00106688	0,00219188	0,0662913
FF-16	135	155	94,29%	0,00100155	0,00213468	0,24658671
FF-17	135	152	94,40%	0,00101140	0,00232814	0,2114077
FF-18	135	72	97,35%	0,00148185	0,01794855	0,52975652
FF-19	135	152	94,40%	0,00109282	0,00249628	0,02077054
FF-20	135	172	93,66%	0,00100452	0,00354088	0,04188595
FF-21	135	188	93,07%	0,00095882	0,00465604	0,01973137

Fonte: Elaborado pelo autor

A terceira escolha de parâmetros aconteceu entre os experimentos FF-8 e FF-13. Modificamos a quantidade de neurônios e notamos que não há diferença relevante do resultado apresentado. Dessa forma, mantivemos a quantidade de neurônios do teste FF-5.

A quarta escolha de parâmetros aconteceu entre os experimentos F-14 e F-17. Aumentamos a quantidade de *hidden layers* e notamos que quanto mais camadas aumentamos pior fica o resultado. Apesar do teste FF-15 ter melhorado a taxa de exceção, a diferença de MSE de Treino e de Teste mostra uma baixa aderência do modelo. Mantivemos a quantidade de neurônios da FF-5.

A quinta validação foi a de verificar se os últimos dias de preço de fechamento poderiam ser utilizados para prever o VaR. O experimento FF-18 nos mostra que, somente com esse previsor, não há melhora na previsão do VaR. Apesar da taxa de exceção ser atraente, o erro de previsão, de treino e de testes demonstram que não é um bom modelo. Mantivemos o modelo FF-5 como melhor até esse ponto.

A última validação foi a de verificar se ajustando a curva VaR para um número mais próximo do ideal a rede neural conseguisse fazer o mesmo ajuste e gerar melhores previsões. Fizemos isso para três percentuais de ajuste 1%, 5% e 10%. Em nenhum deles houve melhora na previsão, mas sim o contrário.

Enfim, os modelos FF-2, FF-15 e FF-18 tiveram uma taxa de exceção melhor ou iguais ao do modelo paramétrico utilizado como base de comparação. Porém, os MSE de Testes foram mais altos do que o do experimento FF-5. Se avaliarmos o gráfico com as taxas de exceção, notaremos que o período de alta volatilidade não foi corretamente previsto para esses modelos, conforme a Figura 33 do apêndice G.

A Tabela 10, contém os parâmetros selecionados para a VALE, sendo em negrito os selecionados para as iterações seguintes. Já a Tabela 11 mostra o resultado do experimento e em negrito o modelo selecionado.

Tabela 10 – Modelos *Feedforward* - VALE3

Nome	Batch Size	Ativação Hidden Layer	Camadas Células	Previsores	Previsão	% Ajuste
FF-1	940	Sigmóide	60,30,1	VaR	VaR	0%
FF-2	1	Sigmóide	60,30,1	VaR	VaR	0%
FF-3	32	Sigmóide	60,30,1	VaR	VaR	0%
FF-4	64	Sigmóide	60,30,1	VaR	VaR	0%
FF-5	128	Sigmóide	60,30,1	VaR	VaR	0%
FF-6	128	Tanh	60,30,1	VaR	VaR	0%
FF-7	128	ReLU	60,30,1	VaR	VaR	0%
FF-8	128	Sigmóide	60,20,1	VaR	VaR	0%
FF-9	128	Sigmóide	60,40,1	VaR	VaR	0%
FF-10	128	Sigmóide	60,60,1	VaR	VaR	0%
FF-11	128	Sigmóide	60,80,1	VaR	VaR	0%
FF-12	128	Sigmóide	60,100,1	VaR	VaR	0%
FF-13	128	Sigmóide	60,120,1	VaR	VaR	0%
FF-14	128	Sigmóide	60,40,40,1	VaR	VaR	0%
FF-15	128	Sigmóide	60,40,20,1	VaR	VaR	0%
FF-16	128	Sigmóide	60,40,20,20,1	VaR	VaR	0%
FF-17	128	Sigmóide	60,20,20,10,1	VaR	VaR	0%
FF-18	128	Sigmóide	60,40,1	Fechamento	VaR	0%
FF-19	128	Sigmóide	60,40,1	Fechamento	VaR	1%
FF-20	128	Sigmóide	60,40,1	Fechamento	VaR	5%
FF-21	128	Sigmóide	60,40,1	Fechamento	VaR	10%

Fonte: Elaborado pelo autor

Tabela 11 – Experimento *Feedforward* - VALE3

Nome	Máx Experado	Exceções	Acurácia	MSE Previsão	MSE Treino	MSE Teste
FF-1	135	161	94,07%	0,00278014	0,00453806	0,03329625
FF-2	135	313	88,48%	0,00191095	0,00208167	1,33472241
FF-3	135	158	94,18%	0,00284148	0,00224035	0,01218945
FF-4	135	158	94,18%	0,00279726	0,00244252	0,02019337
FF-5	135	158	94,18%	0,00279943	0,00280530	0,01817810
FF-6	135	158	94,18%	0,00278970	0,00253777	0,02986845
FF-7	135	198	92,71%	0,00225687	0,00282788	0,87774644
FF-8	135	156	94,26%	0,00279528	0,00254037	0,02521399
FF-9	135	151	94,44%	0,00290368	0,00305277	0,01388285
FF-10	135	164	93,96%	0,00275238	0,00268368	0,02301630
FF-11	135	155	94,29%	0,00285563	0,00247900	0,01215081
FF-12	135	156	94,26%	0,00285488	0,00245358	0,01121849
FF-13	135	156	94,26%	0,00285185	0,00260807	0,01227523
FF-14	135	155	94,29%	0,00282461	0,00279607	0,03021847
FF-15	135	154	94,33%	0,00284992	0,00277725	0,02933778
FF-16	135	167	93,85%	0,00257521	0,00273739	0,15452235
FF-17	135	169	93,78%	0,00249283	0,00279489	0,23924678
FF-18	135	196	92,78%	0,00232935	0,03257316	0,94259381
FF-19	135	201	92,60%	0,00223658	0,02694648	0,90129883
FF-20	135	211	92,23%	0,00221750	0,02506414	0,70844315
FF-21	135	31	91,49%	0,00211080	0,02095073	0,53519002

Fonte: Elaborado pelo autor

Utilizamos a mesma dinâmica de decisão para a VALE3. As decisões foram parecidas e por isso não foram aqui detalhadas. As exceções foram na escolha dos parâmetros dos experimentos FF-6 à FF-7. Mantivemos a função de ativação sigmóide do FF-5 pela taxa de exceção ser a mesma da tangente hiperbólica e a primeira ter sido a melhor função para o IBOVESPA.

Enfim, o modelos FF-21 teve a melhor taxa de exceção, porém, o MSE de Teste foi mais alto do que o FF-9. Observe a Figura 35 do apêndice H para identificar a piora na previsão.

Os apêndices G e H apresentam os gráficos dos modelos selecionados para essa rede, bem como os primeiros e últimos dados dessas séries.

4.5 Etapa 3 - Previsão com rede LSTM para IBOVESPA e VALE3

Nessa última etapa do experimento foi feita a previsão do VaR através das redes neurais LSTM tanto para o IBOVESPA quanto para a VALE3.

As Tabelas 12 e 13 apresentam os modelos validados no experimento para o IBOVESPA. Em negrito estão marcados os parâmetros fixados para as iterações seguintes.

Tabela 12 – Modelos do Experimento LSTM - IBOVESPA (1/2)

Nome	Batch Size	Camadas Células	Previsores	% Ajuste
LSTM-1	940	60,30,1	VaR	0%
LSTM-2	1	60,30,1	VaR	0%
LSTM-3	32	60,30,1	VaR	0%
LSTM-4	64	60,30,1	VaR	0%
LSTM-5	128	60,30,1	VaR	0%
LSTM-6	128	60,20,1	VaR	0%
LSTM-7	128	60,40,1	VaR	0%
LSTM-8	128	60,60,1	VaR	0%
LSTM-9	128	60,80,1	VaR	0%
LSTM-10	128	60,100,1	VaR	0%
LSTM-11	128	60,120,1	VaR	0%
LSTM-12	128	60,120,120,1	VaR	0%
LSTM-13	128	60,120,60,1	VaR	0%
LSTM-14	128	60,120,120,120,1	VaR	0%
LSTM-15	128	60,120,120,60,1	VaR	0%
LSTM-16	128	60,120,120,60,60,1	VaR	0%
LSTM-17	128	60,120,120,60,30,1	VaR	0%
LSTM-18	128	60,120,120,60,1	Fechamento	0%
LSTM-19	128	60,120,120,60,1	log-ret	0%
LSTM-20	128	60,120,120,60,1	Fechamento, log-ret	0%
LSTM-21	128	60,120,120,60,1	Fechamento, Volume, log-ret, PTAX Dólar, PTAX Euro, Selic, IPCA	0%
LSTM-22	128	60,120,120,60,1	VaR, Fechamento	0%
LSTM-23	128	60,120,120,60,1	LSTM-22, Volume	0%
LSTM-24	128	60,120,120,60,1	LSTM-23, log-ret	0%
LSTM-25	128	60,120,120,60,1	LSTM-24, PTAX Dolar, PTAX Euro	0%
LSTM-26	128	60,120,120,60,1	LSTM-25, SELIC, IPCA	0%
LSTM-27	128	60,120,120,60,1	LSTM-22, log-ret	0%
LSTM-28	128	60,120,120,60,1	LSTM-27, PTAX Dolar, PTAX Euro	0%
LSTM-29	128	60,120,120,60,1	LSTM-28, SELIC, IPCA	0%
LSTM-30	128	60,120,120,60,1	LSTM-22, PTAX Dolar, PTAX Euro	0%
LSTM-31	128	60,120,120,60,1	LSTM-30, SELIC, IPCA	0%

Fonte: Elaborado pelo autor

Iniciamos a execução do experimento com o IBOVESPA avaliando qual é o melhor batch size para essa amostra de dados. Entre as execuções LSTM-1 e LSTM-5, o menor número de exceções foi encontrado em LSTM-5. Com esse resultado, fixamos o batch-size em 128 para

Tabela 13 – Modelos do Experimento LSTM - IBOVESPA (2/2)

Nome	Batch Size	Camadas Células	Previsores	% Ajuste
LSTM-32	128	60,240,240,120,1	LSTM-28	0%
LSTM-33	128	60,480,480,240,1	LSTM-28	0%
LSTM-34	128	60,600,600,300,1	LSTM-28	0%
LSTM-35	128	60,120,120,60,1	VaR	1%
LSTM-36	128	60,120,120,60,1	VaR	5%
LSTM-37	128	60,120,120,60,1	VaR	10%
LSTM-38	128	60,120,120,60,1	LSTM-28	1%
LSTM-39	128	60,120,120,60,1	LSTM-28	5%
LSTM-40	128	60,120,120,60,1	LSTM-28	10%

Fonte: Elaborado pelo autor

as próximas iterações.

Em seguida aumentamos progressivamente a quantidade de neurônios na primeira *hidden layer*. Aumentamos a quantidade em um intervalo de 20 neurônios até o limite de 120 neurônios. Apesar das taxas de exceções serem muito próximas, identificamos que a quantidade de 120 neurônios, na execução LSTM-11, obteve o melhor resultado com uma taxa de exceções de 160 contra 161 das quatro execuções anteriores. Dessa forma fixamos a quantidade de neurônios na primeira camada em 120 neurônios.

Nas execuções LSTM-12 à LSTM-17, aumentamos gradativamente o número de camadas com a diminuição concomitante de neurônios nas últimas camadas. Identificamos que o experimento LSTM-15 apresentou o melhor resultado com 120 neurônios na primeira *hidden layers*, 120 na segunda e 60 na terceira. Damos sequência através da variação dos atributos previsores da rede. Entre LSTM-18 e LSTM-21 experimentamos retirar o VaR como dado previsor da rede neural. A ideia foi avaliar se sem esse componente é possível fazer uma boa previsão. Não obtivemos sucesso. Ao retirar o VaR dos componentes de previsão tivemos uma excelente taxa de exceção mas um péssimo erro de teste, demonstrando que o modelo não foi bem adequado aos dados apresentados.

Já entre LSTM-22 e LSTM-31 retornamos o VaR nos atributos previsores e variamos os dados macroeconômicos na rede. Interessante notar a disparidade dos resultados. Ora boa taxa de exceção com erro de teste ruim, ora taxa de exceção ruim com erro de teste ruim. Optamos por selecionar o LSTM-28 por ter recebido uma taxa de exceção de 124, apesar de termos notado uma piora na erro da previsão, demonstrando que os dados ao longo da série ficaram descolados da base real.

Como adicionamos dados previsores, naturalmente aumentamos a quantidade de informações repassadas para a rede neural. Dessa forma, decidimos fazer três novas execuções, LSTM-32 à LSTM-34, aumentando a quantidade de neurônios nas três camadas já pré-selecionadas. Não tivemos sucesso. Nos três cenários, tivemos piora nos dados.

Por fim, nas execuções LSTM-35 à LSTM-40 ajustamos a série VaR original em 1%, 5% e 10% e validamos contra os parâmetros das melhores execuções com dados macroeconômicos (LSTM-28) e sem dados macroeconômicos (LSTM-15). Em nenhum desses cenários, obtivemos dados satisfatórios. Ou seja, quanto maior o ajuste dos dados de entrada, pior o resultado final.

As Tabelas 14 e 15 contém os resultados dos experimentos para essa série. A linha em negrito representa o modelo selecionado. As linhas sublinhadas representam execuções com bom resultado, que fizeram com que algum parâmetro fosse selecionado.

Tabela 14 – Resultado Experimento LSTM - IBOVESPA 1/2

Nome	Máx Experado	Exceções	Acurácia	MSE Previsão	MSE Treino	MSE Teste
LSTM-1	135	158	94,17%	0,00103569	0,00230127	0,09468825
LSTM-2	135	159	94,13%	0,00103733	0,00165735	0,06972710
LSTM-3	135	155	94,28%	0,00105557	0,00163662	0,05357488
LSTM-4	135	156	94,24%	0,00105411	0,00164605	0,05062322
<u>LSTM-5</u>	<u>135</u>	<u>154</u>	<u>94,32%</u>	<u>0,00105448</u>	<u>0,00167300</u>	<u>0,05960077</u>
LSTM-6	135	155	94,28%	0,00106301	0,00165987	0,03954944
LSTM-7	135	154	94,32%	0,00104977	0,00169107	0,06317451
LSTM-8	135	154	94,32%	0,00105364	0,00166307	0,05488764
LSTM-9	135	154	94,32%	0,00106329	0,00166659	0,03960345
LSTM-10	135	153	94,35%	0,00106966	0,00164976	0,03087671
<u>LSTM-11</u>	<u>135</u>	<u>153</u>	<u>94,35%</u>	<u>0,00107207</u>	<u>0,00168419</u>	<u>0,02803185</u>
LSTM-12	135	150	94,46%	0,00108079	0,00163168	0,02079071
LSTM-13	135	153	94,35%	0,00106370	0,00162471	0,03927400
LSTM-14	135	151	94,43%	0,00108153	0,00165415	0,02175013
<u>LSTM-15</u>	<u>135</u>	<u>146</u>	<u>94,61%</u>	<u>0,00108674</u>	<u>0,00163700</u>	<u>0,02085885</u>
LSTM-16	135	148	94,54%	0,00104056	0,00161615	0,10146890
LSTM-17	135	147	94,58%	0,00106015	0,00159061	0,07381592
LSTM-18	135	111	95,90%	0,00121552	0,00396993	0,71775327
LSTM-19	135	119	95,61%	0,00113775	0,02113598	0,29716925
LSTM-20	135	103	96,20%	0,00121279	0,00096176	0,63788877
LSTM-21	135	81	97,01%	0,00128624	0,00108171	0,68525707
LSTM-22	135	133	95,09%	0,00110703	0,00154900	0,01995600
LSTM-23	135	133	95,09%	0,00109616	0,00154280	0,03288834
LSTM-24	135	134	95,06%	0,00114705	0,00153872	0,02952593
LSTM-25	135	139	94,87%	0,00106524	0,00144687	0,17848494
LSTM-26	135	109	95,98%	0,00118377	0,00138864	0,14221733
LSTM-27	135	133	95,09%	0,00112792	0,00153957	0,02749139
LSTM-28	135	124	95,42%	0,00119223	0,00162328	0,01947803
LSTM-29	135	121	95,54%	0,00112718	0,00133552	0,37470068
LSTM-30	135	123	95,46%	0,00117296	0,00157434	0,03692866
LSTM-31	135	126	95,35%	0,00111055	0,00159776	0,28739765

Fonte: Elaborado pelo autor

Tabela 15 – Resultado Experimento LSTM - IBOVESPA 2/2

Nome	Máx Experado	Exceções	Acurácia	MSE Previsão	MSE Treino	MSE Teste
LSTM-32	135	125	95,39%	0,00113781	0,00155992	0,07110444
LSTM-33	135	131	95,17%	0,00131508	0,00150129	0,28512121
LSTM-34	135	134	95,06%	0,00120958	0,00154525	0,10596190
LSTM-35	135	157	94,21%	0,00105165	0,00187336	0,04096836
LSTM-36	135	166	93,87%	0,00102953	0,00301845	0,02279927
LSTM-37	135	190	92,99%	0,00093432	0,00444140	0,04569298
LSTM-38	135	132	95,13%	0,00109077	0,00166858	0,19679059
LSTM-39	135	146	94,61%	0,00105256	0,00300067	0,11011901
LSTM-40	135	170	93,73%	0,00096845	0,00423194	0,11116159

Fonte: Elaborado pelo autor

Portanto, para o IBOVESPA, a execução LSTM-28 foi a selecionado como o melhor entre os comparados nessa etapa. Ao todo foram aproximadamente 16 horas de processamento computacional para as 40 execuções. A execução que levou mais tempo foi a LSTM-34 com 2 horas e 25 minutos, seguida pela LSTM-2 com 2 horas e 15 minutos. A mais rápida foi a LSTM-6 com 55 segundos, seguida pela LSTM-7 com 1 minuto e 3 segundos.

É possível visualizar, no apêndice I, a os gráficos dos experimentos LSTM-5, LSTM-11, LSTM-15, LSTM-20 e LSTM-28.

Sobre o experimento com a VALE, a Tabela 16 apresenta os modelos executados para essa série com LSTM. Em negrito, os parâmetros fixados para as iterações seguintes. A Tabela 17 contém o resultado do experimento para a VALE com LSTM.

A dinâmica do experimento foi análoga ao da IBOVESPA para LSTM. Iniciamos com a identificação do melhor batch-size para esse conjunto de dados. Identificamos, diferentemente do cenário com IBOVESPA, que o LSTM-32 com 32 foi o que apresentou o melhor resultado.

Em seguida, iniciamos a validação da quantidade de neurônios na primeira *hidden layer*. A mesma quantidade de 120 encontrado no IBOVESPA foi também encontrado para a VALE. O mesmo aconteceu para a identificação da quantidade de *hidden layers* e neurônios em cada uma delas. A tríade 120, 120, 60 no LSTM-15 foi a encontrada selecionada.

A partir daí, nenhum outro cenário se mostrou satisfatório. Fizemos a validação de previsores com e sem o VaR como componente além de adicionarmos os percentuais de ajuste da série original. Como não tivemos resultados satisfatórios com a adição de dados macroeconômicos não necessitamos explorar a adição de mais neurônios nas camadas encontradas.

Tabela 16 – Modelos do Experimento LSTM - VALE

Nome	Batch Size	Camadas Células	Previsores	% Ajuste
LSTM-1	940	60,30,1	VaR	0%
LSTM-2	1	60,30,1	VaR	0%
LSTM-3	32	60,30,1	VaR	0%
LSTM-4	64	60,30,1	VaR	0%
LSTM-5	128	60,30,1	VaR	0%
LSTM-6	32	60,20,1	VaR	0%
LSTM-7	32	60,40,1	VaR	0%
LSTM-8	32	60,60,1	VaR	0%
LSTM-9	32	60,80,1	VaR	0%
LSTM-10	32	60,100,1	VaR	0%
LSTM-11	32	60,120,1	VaR	0%
LSTM-12	32	60,120,120,1	VaR	0%
LSTM-13	32	60,120,60,1	VaR	0%
LSTM-14	32	60,120,120,120,1	VaR	0%
LSTM-15	32	60,120,120,60,1	VaR	0%
LSTM-16	32	60,120,120,60,60,1	VaR	0%
LSTM-17	32	60,120,120,60,30,1	VaR	0%
LSTM-18	32	60,120,120,60,1	Fechamento	0%
LSTM-19	32	60,120,120,60,1	log-ret	0%
LSTM-20	32	60,120,120,60,1	Fechamento, log-ret	0%
LSTM-21	32	60,120,120,60,1	Fechamento, Volume, log-ret, PTAX Dólar, PTAX Euro, Selic, IPCA	0%
LSTM-22	32	60,120,120,60,1	VaR, Fechamento	0%
LSTM-23	32	60,120,120,60,1	LSTM-22, Volume	0%
LSTM-24	32	60,120,120,60,1	LSTM-23, log-ret	0%
LSTM-25	32	60,120,120,60,1	LSTM-24, PTAX Dolar, PTAX Euro	0%
LSTM-26	32	60,120,120,60,1	LSTM-25, SELIC, IPCA	0%
LSTM-27	32	60,120,120,60,1	LSTM-22, log-ret	0%
LSTM-28	32	60,120,120,60,1	LSTM-27, PTAX Dolar, PTAX Euro	0%
LSTM-29	32	60,120,120,60,1	LSTM-28, SELIC, IPCA	0%
LSTM-30	32	60,120,120,60,1	LSTM-22, PTAX Dolar, PTAX Euro	0%
LSTM-31	32	60,120,120,60,1	LSTM-30, SELIC, IPCA	0%
LSTM-32	32	60,120,120,60,1	VaR	1%
LSTM-33	32	60,120,120,60,1	VaR	5%
LSTM-34	32	60,120,120,60,1	VaR	10%

Fonte: Elaborado pelo autor

Com isso, chegamos a conclusão que o melhor conjunto para a previsão da VALE é aquele encontrado na LSTM-15.

A execução de todos os experimentos da VALE levou aproximadamente 7 horas de processamento computacional. As execuções mais demoradas foram LSTM-2 e LSTM-18 com 1 hora e 7 minutos e 19 minutos e 14 segundos respectivamente. As execuções mais rápidas ficaram foram LSTM-5 e LSTM-1 com 56 segundos e 59 segundos respectivamente.

É possível visualizar, no apêndice J, o gráfico dos experimentos LSTM-3, LSTM-11, LSTM-15 e LSTM-25.

Tabela 17 – Resultado Experimento LSTM - VALE

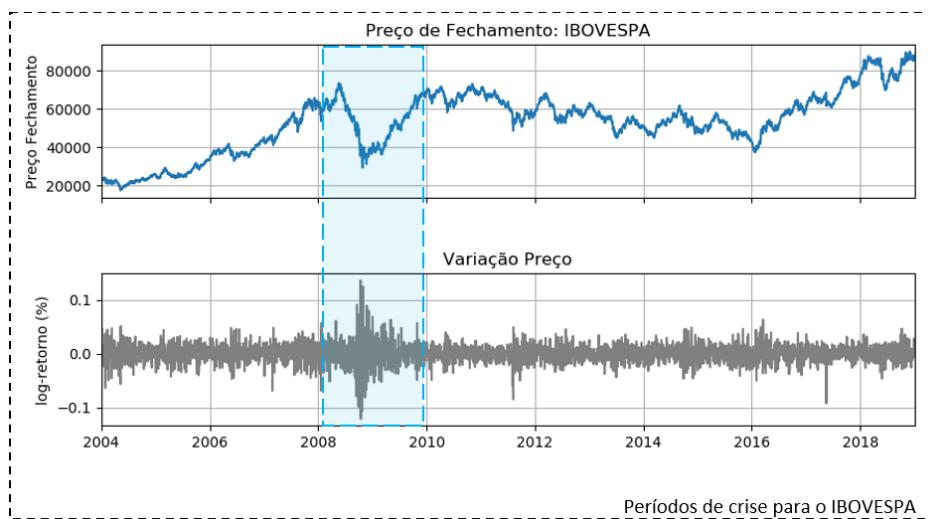
Nome	Máx Experado	Exceções	Acurácia	MSE Previsão	MSE Treino	MSE Teste
LSTM-1	135	165	93,91%	0,00270311	0,00266802	0,05795087
LSTM-2	135	163	93,98%	0,00280605	0,00218217	0,01496610
<u>LSTM-3</u>	<u>135</u>	<u>159</u>	<u>94,13%</u>	<u>0,00279970</u>	<u>0,00214038</u>	<u>0,02394622</u>
LSTM-4	135	162	94,02%	0,00272266	0,00214041	0,05714866
LSTM-5	135	163	93,98%	0,00273725	0,00215416	0,04896138
LSTM-6	135	165	93,91%	0,00268194	0,00215056	0,08757502
LSTM-7	135	163	93,98%	0,00273765	0,00213657	0,04505901
LSTM-8	135	161	94,05%	0,00277899	0,00213248	0,02735928
LSTM-9	135	161	94,05%	0,00279475	0,00213263	0,02045032
LSTM-10	135	161	94,05%	0,00279243	0,00213019	0,02313716
<u>LSTM-11</u>	<u>135</u>	<u>160</u>	<u>94,05%</u>	<u>0,00280400</u>	<u>0,00212940</u>	<u>0,01835540</u>
LSTM-12	135	159	94,13%	0,00280684	0,00213701	0,01570012
LSTM-13	135	164	93,94%	0,00276990	0,00213945	0,02327734
LSTM-14	135	159	94,13%	0,00281365	0,00212557	0,01535845
LSTM-15	135	157	94,20%	0,00291285	0,00210226	0,02374832
LSTM-16	135	157	94,20%	0,00273008	0,00201545	0,04331383
LSTM-17	135	162	94,02%	0,00266528	0,00207337	0,09127766
LSTM-18	135	184	93,21%	0,00233292	0,00059815	0,75870186
LSTM-19	135	215	92,06%	0,00215065	0,00043502	0,68882109
LSTM-20	135	196	92,76%	0,00227446	0,00049934	0,81842565
LSTM-21	135	111	95,90%	0,00300440	0,00057242	0,54699812
LSTM-22	135	157	94,20%	0,00257619	0,00202095	0,14845256
LSTM-23	135	129	95,24%	0,00270338	0,00195381	0,34087720
LSTM-24	135	127	95,31%	0,00270784	0,00176158	0,39264454
LSTM-25	135	119	95,61%	0,00280728	0,00159551	0,41917942
LSTM-26	135	126	95,35%	0,00278049	0,00057412	0,45527293
LSTM-27	135	165	93,91%	0,00245628	0,00196044	0,26111015
LSTM-28	135	163	93,98%	0,00247499	0,00187387	0,33872183
LSTM-29	135	149	94,50%	0,00251294	0,00084372	0,38838274
LSTM-30	135	176	93,50%	0,00244953	0,00180955	0,36403095
LSTM-31	135	172	93,65%	0,00247288	0,00127309	0,45116189
LSTM-32	135	165	93,91%	0,00277418	0,00225575	0,01613858
LSTM-33	135	180	93,35%	0,00269702	0,00300356	0,01769480
LSTM-34	135	199	92,65%	0,00249534	0,00433909	0,02542626

Fonte: Elaborado pelo autor

4.6 Avaliação em períodos de crise

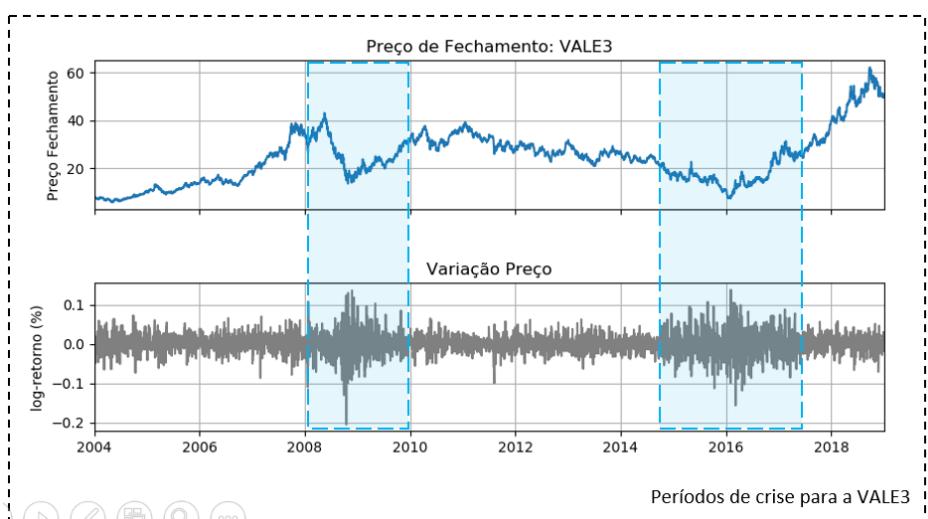
Para identificar os momentos de crise avaliamos os gráficos de preço de fechamento e log-retorno da IBOVESPA e VALE. A VALE e IBOVESPA tiveram alta oscilação de preços e quedas bruscas entre 2008 e 2010. Interessante notar a alta volatilidade ocorrida para a VALE entre 2015 e 2017. Observe as Figuras 17 e 18.

Figura 17 – IBOVESPA de 2004 à 2018 com seleção de crise



Fonte: Elaborado pelo autor

Figura 18 – VALE3 de 2004 à 2018 com seleção de crise



Fonte: Elaborado pelo autor

Para contribuir com a análise de crise, avaliamos 5 datas nesse período que tiveram o percentual de perda entre um dia e outro, e assim, compararamos qual modelo conseguiu fazer uma melhor previsão para esses dias.

A Tabela 18 contém a comparação para o IBOVESPA. As datas 15/10/2008, 22/10/2008, 29/09/2008, 12/11/2008 e 15/09/2008 tiveram respectivamente o seguinte log-retorno representados na coluna 2: -12,09%, -10,73%, -9,82%, -8,06% e -7,89%.

Tabela 18 – Comparação momentos de crise - IBOVESPA

Data	Log-Retorno	P4	FF-5	LSTM-28
15/10/08	-0,120960	-0,099191	-0,080582	-0,078190
22/10/08	-0,107346	-0,100181	-0,087894	-0,088370
29/09/08	-0,098292	-0,071492	-0,064997	-0,058159
12/11/08	-0,080675	-0,093997	-0,092179	-0,095510
15/09/08	-0,078923	-0,048012	-0,036667	-0,036542

Fonte: Elaborado pelo autor

Já a Tabela 19 contém a comparação para a VALE. As datas 15/10/2008, 29/09/2008, 02/10/2008, 21/01/2008 e 27/10/2008 tiveram respectivamente o seguinte log-retorno representados na coluna 2: -20,49%, -13,01%, -11,11%, -10,99% e -9,88%.

Tabela 19 – Comparação momentos de crise - VALE

Data	Log-Retorno	P4	FF-9	LSTM-15
15/10/08	-0,204987	-0,125072	-0,095396	-0,096924
29/09/08	-0,130125	-0,091033	-0,075422	-0,070836
02/10/08	-0,111198	-0,098820	-0,090700	-0,082971
21/11/08	-0,109940	-0,057707	-0,038479	-0,037934
27/10/08	-0,098854	-0,120262	-0,112623	-0,114039

Fonte: Elaborado pelo autor

Todos os cenários paramétricos são mais conservadores do que os cenários com redes neurais. Para o IBOVESPA, no dia 12/11/2008, os modelos paramétricos e de redes neurais conseguiram prever a quebra brusca frente ao log-retorno. Para a VALE a correta previsão para os modelos aconteceu no dia 27/10/2008.

5 CONCLUSÃO

Este estudo avaliou o comportamento do cálculo do Value-at-Risk em três métodos diferentes: Paramétrico, Redes Neurais *Feedforward* e Redes Neurais LSTM. Para construir o modelo paramétrico, comparamos qual modelo de volatilidade se mostrava mais vantajoso, entre desvio padrão, EWMA e GARCH.

O método paramétrico com EWMA sendo calculado a cada 60 dias foi selecionado para servir como comparação entre os modelos de redes neurais. Estes, por sua vez, precisaram ser construídos em uma topologia e parâmetros em que a previsão se mostrasse mais eficiente. Camadas e parâmetros da rede foram experimentados a fim de chegar à melhor configuração e após isso experimentar diferentes dados previsores e o ajuste na série paramétrico utilizada para a previsão. Métricas de avaliação como taxas de exceção, acurácia e erro médio quadrático foram selecionadas para usar como base de comparação dos métodos.

Durante a dissertação, para dar base para o estudo, temas como Value-at-Risk, Volatilidade, Redes Neurais *Feedforward* e LSTM foram discorridos.

Para validar a relevância do tema, uma revisão sistemática foi aplicada. Foram encontrados diversos estudos que demonstravam o interesse em avaliar métodos mais eficientes do cálculo do VaR bem como a lacuna dos modelos existentes terem uma baixa eficiência em épocas de crise e mudanças abruptadas de comportamento. Este portanto, foi o objetivo aplicado para o estudo.

Para atingir o objetivo algumas hipóteses foram selecionadas, como a melhor eficiência ao incorporar dados macro econômicos e no uso de redes LSTM.

A primeira hipótese levantada é a do uso de dados macroeconômicos como taxa de juros e cotação de moedas podem gerar uma melhor previsão do VaR para redes LSTM. Essa hipótese não foi verdadeira para uma das séries e verdadeira para outra. A previsão com LSTM para a VALE3 não teve melhor resultado ao adicionarmos dados macroeconômicos. O resultado para essa série foi o inverso do esperado. Nessa série o melhor resultado utilizou apenas o VaR como atributo previsor. Já o IBOVESPA teve performance melhor ao adicionar preço de fechamento, log-retorno e as cotações do Dólar e Euro. Como o resultado não foi o mesmo para as duas séries e também não houve um padrão percebido, entendemos que a hipótese não foi confirmada.

A segunda hipótese é de que redes LSTM são mais eficientes na previsão de séries temporais do que redes *Feedforward*. De fato, a previsão para o IBOVESPA com LSTM teve um melhor resultado tanto na taxa de exceção quanto no erro médio quadrático da base de testes. Já para a série VALE3 tivemos um melhor resultado para as redes *Feedforward*. Como o resultado também não foi o mesmo para as duas séries, concluímos que a hipótese não foi

confirmada.

Seguem na Tabela 20 as comparações de taxa de exceção e erros médio quadráticos para os três métodos.

Tabela 20 – Comparação final dos modelos

Série	Nome	Exceções	Acurácia	MSE Previsão	MSE Treino	MSE Teste
IBOVESPA	P4	133	95,10%	0,00113559	-	-
IBOVESPA	FF-5	147	94,58%	0,00112418	0,00251834	0,02074686
IBOVESPA	LSTM-28	124	95,42%	0,00119223	0,00162328	0,01947803
VALE3	P4	138	94,92%	0,00288044	-	-
VALE3	FF-9	151	94,44%	0,00290368	0,00305277	0,01388285
VALE3	LSTM-15	157	94,20%	0,00291285	0,00210226	0,02374832

Fonte: Elaborado pelo autor

Os períodos de crise e mudanças abruptas de comportamento foram avaliados individualmente nos 5 piores dias de queda de 17/01/2008 à 29/09/2009. É possível verificar o percentual de variação nas tabelas 18 e 19.

Para o IBOVESPA, no dia 12/11/2008 os três métodos conseguiram prever a queda abrupta de preços. A rede LSTM foi mais conservadora na previsão frente às redes *Feedforward* e o método paramétrico. De qualquer modo a rede *Feedforward* conseguiu ficar mais próxima a da previsão de log-retorno da série. Para os outros 4 dias, nenhum dos métodos conseguiu realizar a previsão adequadamente. Para esses dias, o modelo que mais se aproximou das quedas apresentadas foi o modelo paramétrico.

Para a VALE, no dia 27/10/2008 os três métodos conseguiram prever a queda. O método mais conservador foi o paramétrico. O que mais se aproximou da variação apresentada para o dia foi o método *Feedforward*. Também para os outros 4 dias, o método paramétrico se mostrou mais adequado e conservador para a previsão do Value-at-Risk.

O estudo conclui que as redes neurais tanto *FeedForward* quanto *LSTM* não foram adequadas para a previsão do Value-at-Risk para momentos de crise ou mudanças abruptas de comportamento. Esse resultado corrobora com os estudos apresentados na revisão da literatura. Em contrapartida para momentos de estabilidade de mercado obtivemos uma melhor resposta de redes LSTM para o IBOVESPA frente aos outros modelos, principalmente quando são agregados dados macroeconômicos. Haja vista o alto esforço computacional para o cálculo do VaR através de redes neurais e o resultado apresentado por este estudo, o cálculo através das redes exploradas não é recomendado.

Ao avaliarmos as hipóteses e objetivo notamos uma discrepância de resultados para o IBOVESPA e para a VALE3. Já observamos que o IBOVESPA teve alta oscilação de preços e quedas bruscas entre 2008 e 2010 contra a VALE com oscilações entre 2008 e 2010 e uma alta volatilidade para o período de 2015 à 2017 Os gráficos nas Figuras 17 e 18 demonstram esse

comportamento. Ou seja, a VALE possui mais cenários de volatilidade do que o IBOVESPA, por isso, os modelos de redes neurais tiveram um pior resultado para a VALE do que para o IBOVESPA.

Em nenhuma das séries houve melhora após o ajuste do VaR paramétrico utilizado para previsão. Ou seja, ainda os melhores resultados apresentados foram através da utilização do próprio VaR paramétrico como valor de treino da série. Para o IBOVESPA a adição de dados macroeconômicos fez com que a série prevista capturasse nuances que ajustaram a previsão para uma melhor taxa de exceção com uma ligeira piora do MSE de Previsão. Uma analista de risco pode decidir utilizar esse modelo se a conservadorismo do risco calculado for o objetivo e não a eficiência do valor real versus o valor previsto capturado pelo MSE.

5.1 Estudos Futuros e Ameaças à validade

Como estudos futuros os seguintes pontos são sugeridos.

A validação do comportamento em séries com características semelhantes. Além disso, é sugerido avaliar o uso de outros algoritmos de aprendizado de máquina e outras topologias de redes neurais. Outros parâmetros de configuração das redes neurais podem ser utilizados para explorar modos de eficiência de cenário.

As redes neurais foram treinadas apenas uma vez, sendo que seus pesos sinápticos foram mantidos para as previsões de todo o período validado. É sugerido realizar um estudo com treinos periódicos da rede para validar se há melhora na eficiência. Um período sugerido é o de 5 em 5 dias, visto que processos "batch" de treinamento em uma instituição financeira, poderiam ser executados durante os finais de semana.

Para janela de previsão de rede neural utilizamos a mesma janela do cálculo de volatilidade, ou seja, os últimos 60 lançamentos foram utilizados como entrada das redes neurais. Esse número pode ser variado para verificar o comportamento da série ainda mais em redes LSTM, na qual memórias antigas podem ser utilizadas em previsões futuras.

Explorar a estratégias que minimizem o MSE entre o valor previsto e o valor real mesmo que isso leve um aumento na taxa de exceção. Nesse cenário, é sugerido utilizar como dados de treinamento o próprio log-retorno das séries estudadas. Como uma série desse tipo não tem características lineares é sugerido explorar diferentes técnicas de suavização de séries.

Como ameaças à validade, podemos considerar:

A exploração limitada de variáveis e configurações possíveis para uma rede neural. Essa limitação foi pontuada na seção 3.4 junto com os parâmetros utilizados em nossa configuração de rede. Foram utilizados um número limitado de informações macroeconômicas e com alta correlação como PTAX Dólar e Euro. Os dados macroeconômicos utilizados podem ser relevantes para índice como o IBOVESPA mas não serem interessantes para uma ação

como a VALE3.

Por fim, apontamos o uso do VaR paramétrico como base de treinamento para as redes neurais. O estudo procurou mitigar essa estratégia ao variar dados previsores e ao ajustar essa série para deixá-la mais eficiente.

6 REFERÊNCIAS

- ABU-MOSTAFA, Y. S.; MAGDON-ISMAIL, M.; LIN, H.-T. **Learning From Data: A Short Course**. California: AMLBook, 2012.
- ADCOCK, C. J.; MEADE, N. Using parametric classification trees for model selection with applications to financial risk management. **European Journal Of Operational Research**, Elsevier, v. 259, n. 2, p. 746–765, jun. 2017.
- BACEN. **Circular nº 3634, de 4 de março de 2013**. Brasília: Imprensa Nacional, 2013.
- BACEN. **Cotações e Boletins**. BACEN, 2019. Disponível em: <<https://www4.bcb.gov.br/pec/taxas/port/ptaxnpesq.asp?frame=1>>. Acesso:14jan.2019.
- BACEN. **Histórico de Taxas de Juros**. BACEN, 2019. Disponível em: <<https://www.bcb.gov.br/acessoinformacao/legado?url=https://www.bcb.gov.br/%2FPec%2FCopom%2FPort%2FtaxaSelic.as>>. Acesso:14jan.2019.
- BAIDYA, T. K. N.; COSTA, P. H. S. Métodos de medição de risco de mercado: um estudo comparativo. **Produção**, SciELO Brasil, São Paulo, v. 13, n. 3, p. 19–33, 2003.
- BARRETO, R. G. **Operações de hedge cambial em empresas não financeiras: um estudo de caso das empresas Aracruz Celulose e Sadia**. Dissertação (Mestrado) — Fundação Getúlio Vargas, Rio de Janeiro, 2011.
- BASEL COMMITTEE ON BANKING SUPERVISION. **Basel II - International Convergence of Capital Measurement and Capital Standards: A Revised Framework - Comprehensive Version**. Switzerland, 2006.
- BOLLERSLEV, T. Generalized autoregressive conditional heteroskedasticity. **Journal of Econometrics**, Elsevier, v. 31, n. 3, p. 307–327, abr. 1986.
- BOLLERSLEV, T. Glossary to ARCH (GARCH). **CREATES Research Paper**, CRESTES, p. 46, 2008.
- BRIGMAN, E. F.; C., M. E. **Administração financeira: teoria e prática**. São Paulo: Cengage Learning, 2010.
- BROOMHEAD, D. S.; LOWE, D. **Radial basis functions, multi-variable functional interpolation and adaptive networks**. Malvern, 1988.
- BUDUMA, N.; LOCASCIO, N. **Fundamentals of Deep Learning: Designing Next-generation Machine Intelligence Algorithms**. Sebastopol: O'Reilly Media, 2017.
- BUSSAB, W. de O.; MORETTIN, P. A. **Estatística básica**. 6. ed. São Paulo: Saraiva, 2010.
- CHEN, X.; LAI, K. K.; YEN, J. A statistical neural network approach for Value-at-Risk analysis. In: **2009 International Joint Conference on Computational Sciences and Optimization**. Hainan: IEEE, 2009. v. 2, p. 17–21.
- DAMODARAN, A. **Avaliação de empresas**. 2. ed. São Paulo: Prentice Hall Brasil, 2007.

- DI, W.; BHARDWAJ, A.; WEI, J. **Deep Learning Essentials**. Birmingham: Packt Publishing, 2018.
- ENGLE, R. F. Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation. **Econometrica**, [Wiley, Econometric Society], v. 50, n. 4, p. 987–1007, 1982.
- FELIZARDO, K. et al. **Revisão sistemática da literatura em engenharia de software: Teoria e Prática**. Rio de Janeiro: Elsevier, 2017.
- GAIO, L. E. **Value at Risk no mercado financeiro internacional**: avaliação da performance dos modelos nos países desenvolvidos e emergentes. Tese (Doutorado) — FEA-RP/USP, Ribeirão Preto, 2015.
- GIL, A. C. **Como elaborar projetos de pesquisa**. 4. ed. São Paulo: Atlas, 2002.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Cambridge: MIT Press, 2016. <<http://www.deeplearningbook.org>>.
- GROUP OF THIRTY. **Derivatives**: Practice and Principles. Washington, 1993.
- HAJIZADEH, E. et al. A hybrid modeling approach for forecasting the volatility of S&P 500 index return. **Expert Systems with Applications**, Elsevier, v. 39, n. 1, p. 431–436, jan. 2012.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, MIT Press, v. 9, n. 8, p. 1735–1780, nov. 1997.
- HULL, J. **Fundamentos dos Mercados Futuros e de Opções**. 4. ed. São Paulo: BM&F, 2009.
- IBGE. **Índice Nacional de Preços ao Consumidor**. IBGE, 2019. Disponível em: <https://ww2.ibge.gov.br/home/estatistica/indicadores/precos/inctc_ipca/defaultseriesHist.sht>. Acesso:14jan.2019.
- Infomoney. **Histórico de Cotações**. Infomoney, 2019. Disponível em: <<https://www.infomoney.com.br/mercados/ferramentas/historico-de-cotacoes>>. Acesso:14jan.2019.
- JORION, P. **Value at Risk: The New Benchmark for Controlling Market Risk**. Irwin Professional Pub., 1997. ISBN 9780786308484. Disponível em: <<https://books.google.com.br/books?id=u8efQgAACAAJ>>.
- JORION, P. **Value at Risk**: A nova fonte de referência para a gestão do risco financeiro. 2. ed. São Paulo: BM&F, 2003.
- KIM, H. Y.; WON, C. H. Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models. **Expert Systems with Applications**, Elsevier, v. 103, p. 25–37, ago. 2018.
- KITCHENHAM, B. **Procedures for performing systematic reviews**. Keele, UK, 2004.
- KREBS, C. et al. **Neurociências Ilustrada**. Porto Alegre: Artmed, 2012.

KUESTER, K.; MITTNIK, S.; PAOLELLA, M. S. Value-at-Risk prediction: A comparison of alternative strategies. **Journal of Financial Econometrics**, Oxford University Press, v. 4, n. 1, p. 53–89, jan. 2006.

KUPIEC, P. Techniques for verifying the accuracy of risk measurement models. **The Journal of Derivatives**, Washington, v. 3, n. 2, set. 1995.

LAPES. **StArt - State of the Art through Systematic Review, v 3.0.3 beta 3**. São Carlos: LaPES, 2017. Disponível em: <http://lapes.dc.ufscar.br/tools/start_tool>. Acesso: 30 jan. 2018.

LIN, H.-Y.; CHEN, A.-P. Application of dynamic financial time-series prediction on the interval artificial neural network approach with Value-at-Risk model. In: **2008 IEEE International Joint Conference on Neural Networks (IEEE World Congress on Computational Intelligence)**. Hong Kong: IEEE, 2008. p. 3918–3925.

MACIEL, L. S. Valor em risco de longo prazo: uma abordagem para modelos da família ach e redes neuronais. **Revista Economia e Gestão**, Belo Horizonte, v. 10, n. 24, p. 103–126, 2010.

MARSLAND, S. **Machine Learning: An Algorithmic Perspective**. 2nd. ed. Boca Raton: Chapman & Hall/CRC, 2014.

MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. **The Bulletin of mathematical biophysics**, v. 5, n. 4, p. 115–133, dez. 1943.

MENSHAWY, A. **Deep Learning By Example**. Birmingham: Packt Publishing, 2018.

MERRIAM-WEBSTER. **Merriam-Webster Dictionary**. Merriam-Webster, 2018. Disponível em: <<https://www.merriam-webster.com/dictionary/risk>>. Acesso: 19 ago. 2018.

MONFARED, S. A.; ENKE, D. Volatility forecasting using a hybrid GJR-GARCH neural network model. **Procedia computer science**, v. 36, p. 246–253, jan. 2014.

MORGAN, J. P.; REUTERS. **RiskMetrics - Technical Document**. 4. ed. New York, 1996.

NELSON, D. B. Conditional heteroskedasticity in asset returns: A new approach. **Econometrica**, [Wiley, Econometric Society], v. 59, n. 2, p. 347–370, 1991.

NILSSON, C. **Forecasting Swedish Stock Market Volatility and Value-at-Risk: A Comparison of EWMA and GARCH Models**. Dissertação (Mestrado) — Lund University, Lund, 2017.

OLAH, C. **Understanding LSTM Networks**. 2015. <<http://colah.github.io/posts/2015-08-Understanding-LSTMs/>>. Accessed: 2018-12-16.

OLIVEIRA, A. B. **Usando redes neurais para estimativa da volatilidade**: redes neurais e modelo híbrido GARCH aumentado por redes neurais. Dissertação (Mestrado) — Universidade Federal do Rio Grande do Sul, Porto Alegre, 2010.

OLIVEIRA, S. D. de. **Estimação de volatilidade para o cálculo do valor em risco de uma carteira de ações**. Dissertação (Mestrado) — Faculdades Integradas de Pedro Leopoldo, Pedro Leopoldo, 2007.

- OROZCO, J. M.; VELÁSQUEZ, J. D. A new forecasting combination system for predicting volatility. **Revista Innovar**, Escuela de Administración de Empresas y Contaduría Pública. Universidad Nacional de Colombia., Colombia, v. 23, n. 50, p. 5–16, 2013.
- PANCHAL, F. S.; PANCHAL, M. Review on methods of selecting number of hidden nodes in artificial neural network. **International Journal of Computer Science and Mobile Computing**, India, v. 3, n. 11, p. 455–464, 2014.
- ROSENBLATT, F. The perceptron: a probabilistic model for information storage and organization in the brain. **Psychological Review**, v. 65, n. 6, p. 386–408, nov. 1958.
- RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **Nature**, Nature Publishing Group, v. 323, p. 533–536, out. 1986.
- SHEPPARD, K. et al. **Bashtage/Arch v 4.7.0**. Zenodo: Zenodo, 2018. <<https://arch.readthedocs.io/en/latest/index.html>>.
- WILLIAMS, R. J.; ZIPSER, D. A learning algorithm for continually running fully recurrent neural networks. **Neural Computation**, MIT Press, v. 1, n. 2, p. 270–280, jun. 1989.
- WOLKE, T. **Risk Management**. Berlin: Walter de Gruyter GmbH & Co KG, 2017.

Apêndices

A DESVALORIZAÇÃO SADIA CONTRA COTAÇÃO DO DÓLAR

Abaixo segue figura demonstrando o impacto da cotação da ação da SADIA frente a alta oscilação do dólar.

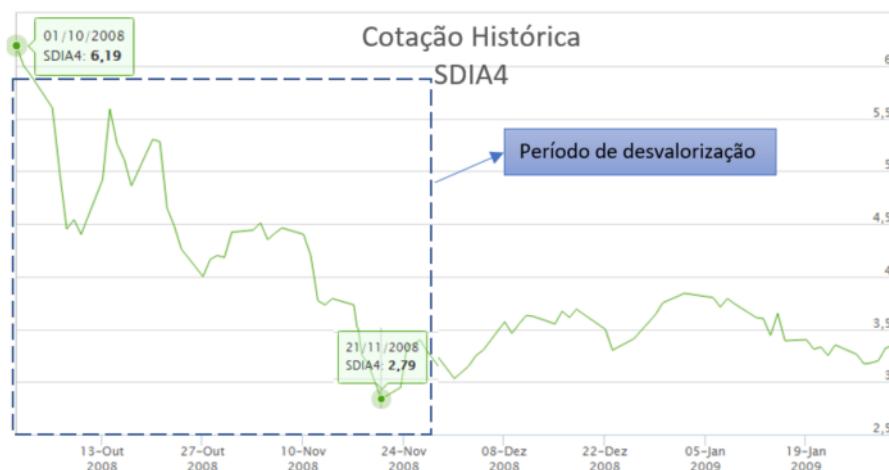
A Figura 19 apresenta o período de alta desvalorização do real frente ao dólar. Já a Figura 20 demonstra o impacto da cotação da ação da empresa quando o mercado tomou conhecimento da operação de derivativo altamente exposta ao dólar.

Figura 19 – Cotação Dólar e Real no período.



Fonte: Série de dados da Investing.com, extraído em 17/02/2018, gráfico gerado pelo autor.

Figura 20 – Desvalorização SADIA.

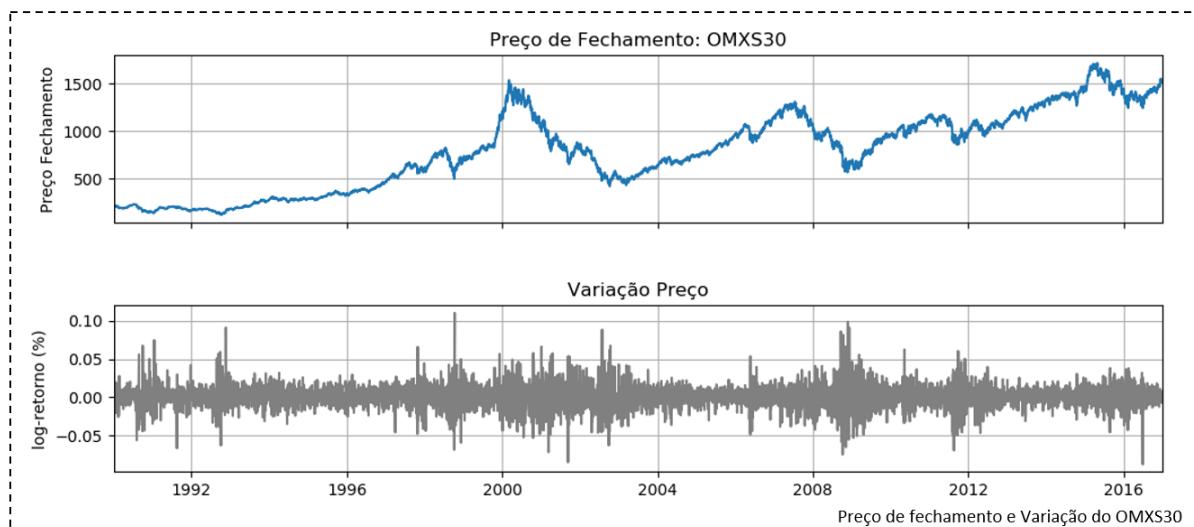


Fonte: Site Fundamentus, extraído em 17/02/2018, modificado pelo autor.

B DADOS PARA EXPERIMENTO - OMXS30

A Figura 21 representa o preço de fechamento do índice OMXS30 de 02 de janeiro de 1990 à 30 de dezembro de 2016 e o cálculo do log-retorno diário para o mesmo período.

Figura 21 – OMXS30 de 1990 à 2016



Fonte: Elaborado pelo autor

A coleta foi feita do site (<http://www.nasdaqomxnordic.com>). No pré-processamento, retiramos os seis dias que continham dados em branco e calculamos o log-retorno do preço de fechamento. Ao final, trabalhamos com um total de 6.778 dias. A Tabela 21 representa o início e fim da série de dados.

Tabela 21 – OMXS30 de 1990 à 2016

Data	Preço de Fechamento	Log Retorno
1990-01-02	206.69	
1990-01-03	208.44	0.008431
1990-01-04	211.82	0.016086
1990-01-05	214.36	0.011920
1990-01-08	215.62	0.005861
...
2016-12-23	1525.80	0.004111
2016-12-27	1533.31	0.004910
2016-12-28	1527.30	-0.003927
2016-12-29	1518.37	-0.005864
2016-12-30	1517.20	-0.000771

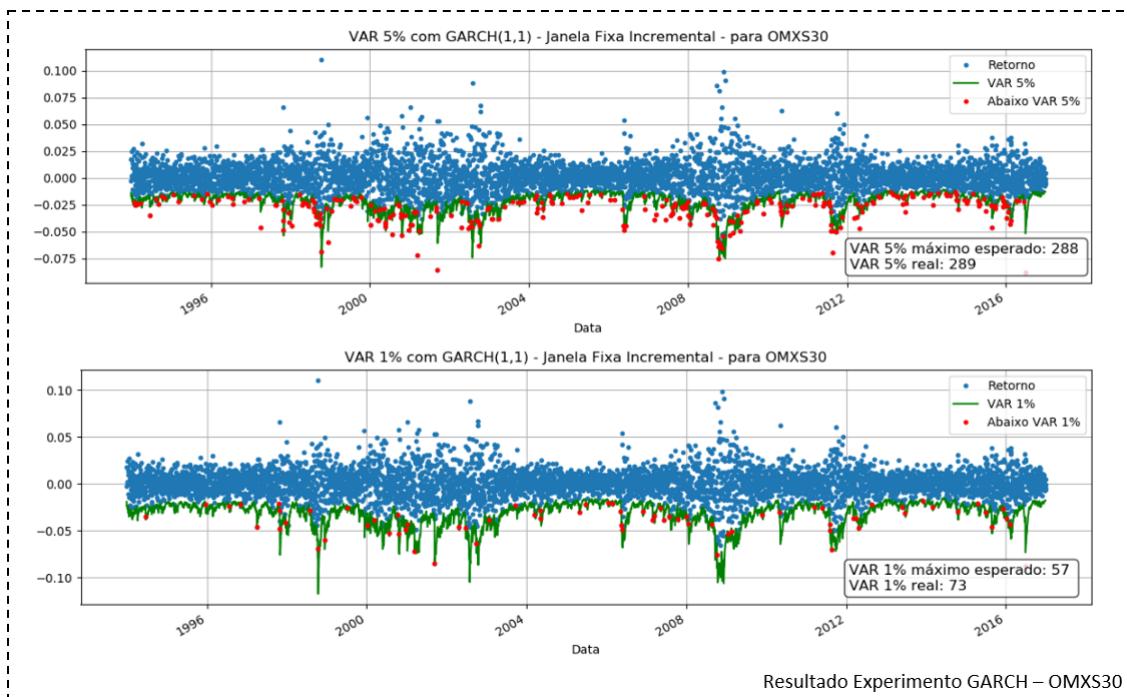
Fonte: Elaborado pelo autor

C RESULTADO - ETAPA 1 COM OMXS30

Os resultados do experimento que valida o cálculo do GARCH frente aos executados por Nilsson (2017) estão demonstrados nesse apêndice.

A Figura 22 contém o resultado do cálculo do VaR paramétrico com 95% e 99% de intervalo de confiança com distribuição normal e utilizar GARCH como medida de volatilidade.

Figura 22 – Value-at-Risk para OMXS30



Fonte: Elaborado pelo autor

O VaR calculado com um intervalo de confiança de 95% gerou uma acurácia de 94,998269% com um MSE de 0,000838497. Já o VaR calculado com intervalo de confiança de 99% gerou uma acurácia de 98,736587% com um MSE de 0,001448.

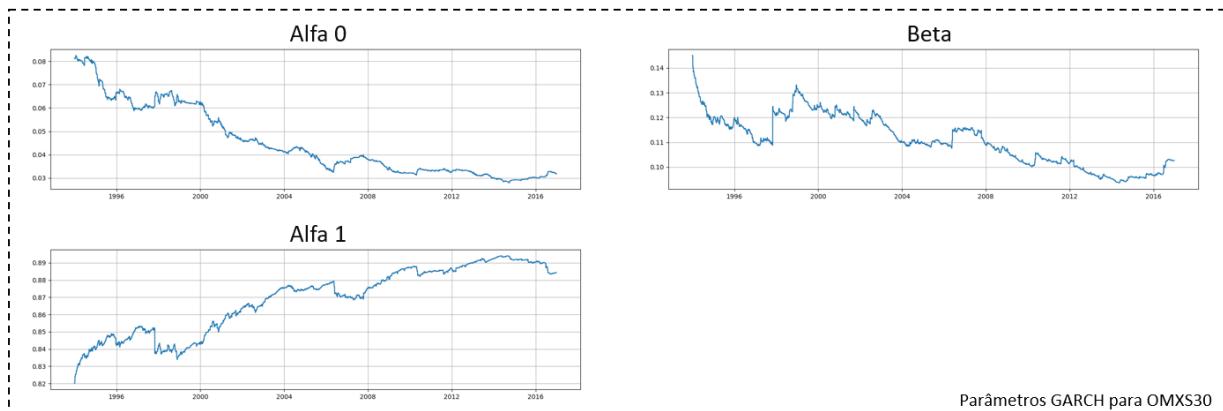
A Tabela 22 demonstra os primeiros e últimos registros dessas previsões. Os parâmetros do GARCH podem ser comparados com o do estudo do Nilsson (2017, fig. B2) na seção sGARCH-norm. A Figura 23 contém a apresentação dos valores.

Já a Tabela 23 contém, os primeiros e últimos valores dessas séries. Observe que o estudo de Nilsson (2017) nomeia as variáveis como ômega, Beta e Alfa respectivamente.

Tabela 22 – VaR paramétrico de OMXS30 de 1990 à 2016

Data	Preço de Fechamento	Log Retorno	VaR 95%	VaR 99%
1993-12-29	275.72	0.017488	-0.013545	-0.019157
1993-12-30	274.98	-0.002687	-0.017101	-0.024187
1994-01-03	279.59	0.016626	-0.016269	-0.023009
1994-01-04	280.04	0.001608	-0.018642	-0.026365
1994-01-05	280.63	0.002105	-0.017551	-0.024822
...
2016-12-21	1525.47	-0.007348	-0.012762	-0.018049
2016-12-22	1519.54	-0.003895	-0.012947	-0.018311
2016-12-23	1525.80	0.004111	-0.012691	-0.017949
2016-12-27	1533.31	0.004910	-0.012480	-0.017651
2016-12-28	1527.30	-0.003927	-0.012539	-0.017733

Fonte: Elaborado pelo autor

Figura 23 – Parâmetros GARCH para VaR da OMXS30

Fonte: Elaborado pelo autor

Tabela 23 – Tabela de parâmetros GARCH para VaR da OMXS30

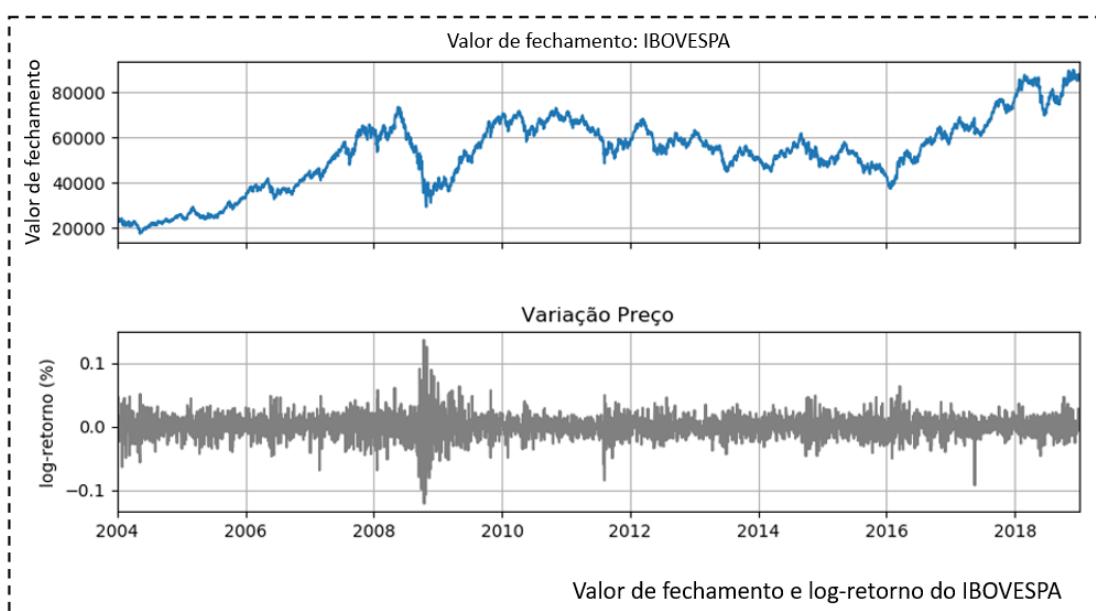
Data	Alfa 0	Alfa 1	Beta
1993-12-29	0.081167	0.820256	0.145016
1993-12-30	0.081167	0.820256	0.145016
1994-01-03	0.081167	0.820256	0.145016
1994-01-04	0.081167	0.820256	0.145016
1994-01-05	0.081167	0.820256	0.145016
1994-01-07	0.081064	0.824185	0.140311
...
2016-12-21	0.031889	0.884290	0.884337
2016-12-22	0.031889	0.884290	0.884337
2016-12-23	0.031889	0.884290	0.884337
2016-12-27	0.031889	0.884290	0.884337
2016-12-28	0.031713	0.884337	0.102628

Fonte: Elaborado pelo autor

D DADOS PARA EXPERIMENTO

As Figuras 24 e 25 representam o preço de fechamento das séries IBOVESPA e VALE3 de 01 de janeiro de 2004 à 28 de dezembro de 2018, além do cálculo do log-retorno diário e volume de negociação para o mesmo período. As coletas foram feitas de Infomoney (2019). As Tabelas 24 e 25 representam o início e fim dessas séries de dados.

Figura 24 – IBOVESPA de 2004 à 2018



Fonte: Elaborado pelo autor

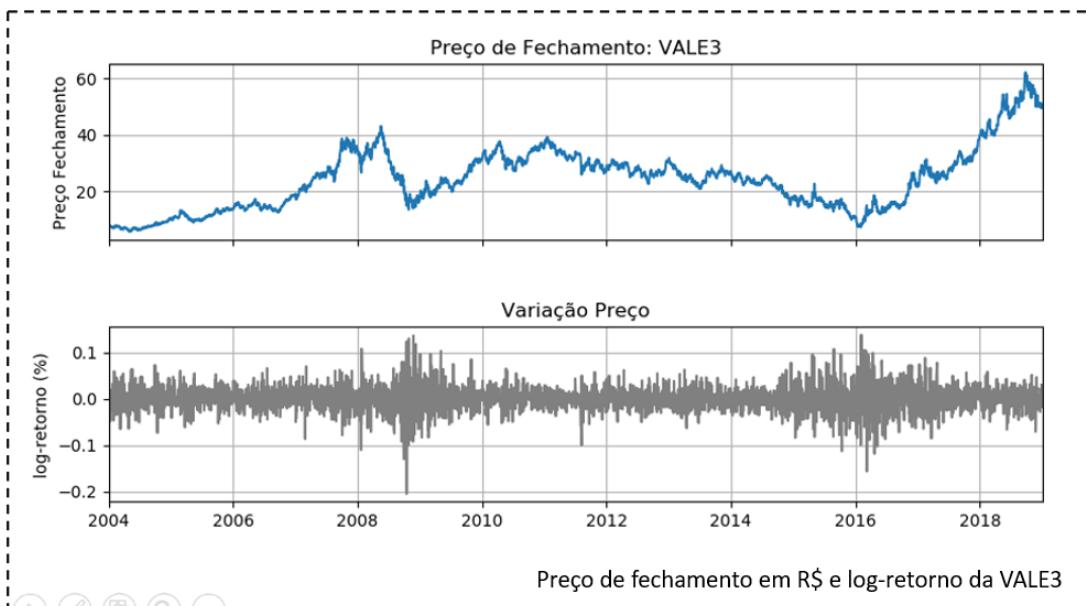
Tabela 24 – IBOVESPA 2004 à 2018

Data	Fechamento	Log Retorno	Volume
2004-01-02	22444		855.478.317,00
2004-01-05	23532	0,047338	1.433.454.559,00
2004-01-06	23576	0,001868	1.666.471.694,00
2004-01-07	23320	-0,010918	1.643.540.157,00
2004-01-08	23717	0,016881	1.613.646.310,00
...
2018-12-20	85269	-0,0047381	16.252.940.419,00
2018-12-21	85697	0,0050070	17.972.415.247,00
2018-12-26	85136	-0,0065680	9.586.361.405,00
2018-12-27	85460	0,0037980	9.777.819.097,00
2018-12-28	87887	0,0280030	11.320.102.981,00

Fonte: Elaborado pelo autor

No pré-processamento, da série IBOVESPA, retiramos um dos dias, que continha dados em branco. Além disso, calculamos o log-retorno para um dia do preço de fechamento. A base após o pré-processamento possui um total de 6.183 dias.

Figura 25 – VALE3 de 2004 à 2018



Fonte: Elaborado pelo autor

Tabela 25 – VALE3 de 2004 à 2018

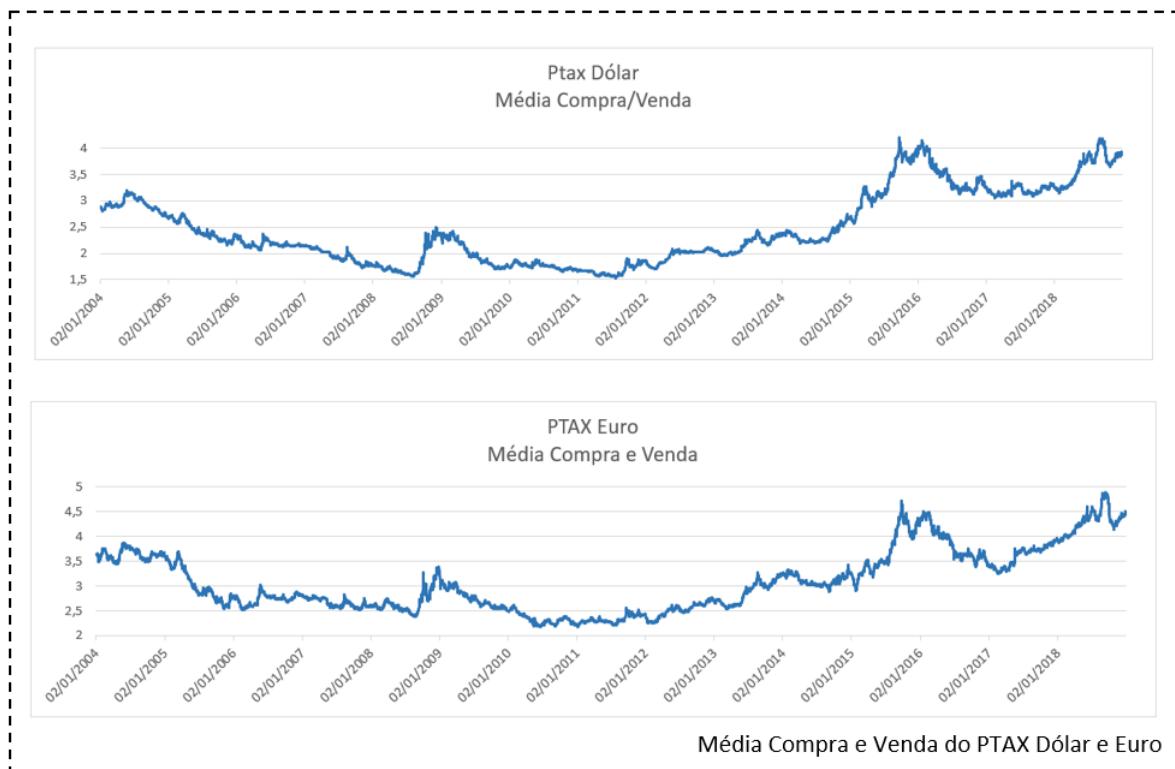
Data	Fechamento	Log Retorno	Volume
2004-01-02	7,77		259.196,00
2004-01-05	8,02	0,031668	328.600,00
2004-01-06	8,01	-0,001248	492.286,00
2004-01-07	7,62	-0,049914	551.009,00
2004-01-08	7,77	0,019494	1.278.872,00
...
2018-12-20	49,81	-0,004007	1.277.518.438,00
2018-12-21	50,86	0,020861	1.437.350.581,00
2018-12-26	50,44	-0,008292	669.735.755,00
2018-12-27	49,50	-0,018812	714.974.681,00
2018-12-28	51,00	0,029853	603.856.237,00

Fonte: Elaborado pelo autor

Já no pré-processamento, da série VALE3, todos os valores foram considerados, totalizando 6.175 dias. Após a coleta de dados, também, calculamos o log-retorno de um dia para a série.

A Figura 26 e Tabela 26 representam a média do PTAX de Compra e Venda Dólar e Euro para o período de 01/01/2004 à 31/12/2018. As coletas foram feitas do site BACEN (2019a) . Sendo a série 978 para o PTAX Euro e a série 220 para o PTAX Dólar.

Figura 26 – PTAX Dólar e PTAX Euro de 2004 à 2018



Fonte: Elaborado pelo autor

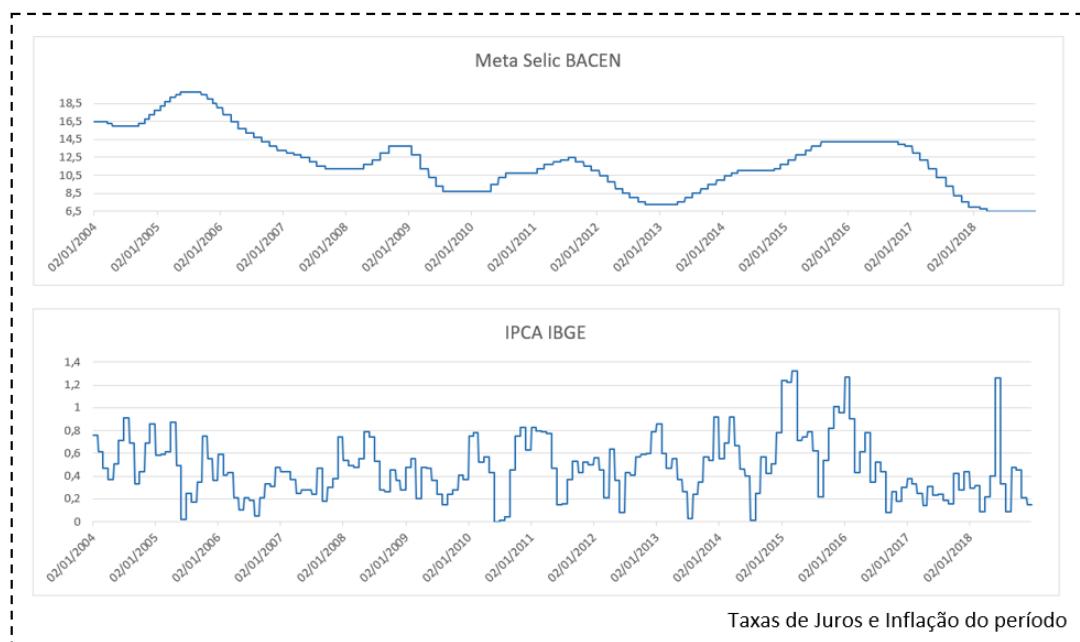
Tabela 26 – Média compra e venda do PTAX Dólar e PTAX Euro

Data	PTAX Dólar	PTAX Euro
2004-01-02	2,8858	3,6346
2004-01-05	2,8623	3,6296
2004-01-06	2,8504	3,6388
2004-01-07	2,8719	3,6320
2004-01-08	2,8584	3,6490
...
2018-12-20	3,8440	4,4010
2018-12-21	3,8668	4,4093
2018-12-26	3,9255	4,4693
2018-12-27	3,9327	4,4964
2018-12-28	3,8745	4,4382

Fonte: Elaborado pelo autor

A Figura 27 e Tabela 27 representam a meta de taxa de juros SELIC e o índice de inflação IPCA de 01/01/2004 à 31/12/2018. A SELIC foi coletada de BACEN (2019b) . O IPCA foi coletado de IBGE (2019).

Figura 27 – SELIC e IPAC de 2004 à 2018



Fonte: Elaborado pelo autor

Tabela 27 – Taxa de Juros e Inflação do período de 2004 à 2018 Euro

Data	SELIC	IPCA
2004-01-02	16,5	0,76
2004-01-05	16,5	0,76
2004-01-06	16,5	0,76
2004-01-07	16,5	0,76
2004-01-08	16,5	0,76
...
2018-12-20	6,5	0,15
2018-12-21	6,5	0,15
2018-12-26	6,5	0,15
2018-12-27	6,5	0,15
2018-12-28	6,5	0,15

Fonte: Elaborado pelo autor

Para essas duas séries, todos os dados foram considerados. Não houve necessidade de realizar, no pré-processamento, qualquer tipo de ajuste.

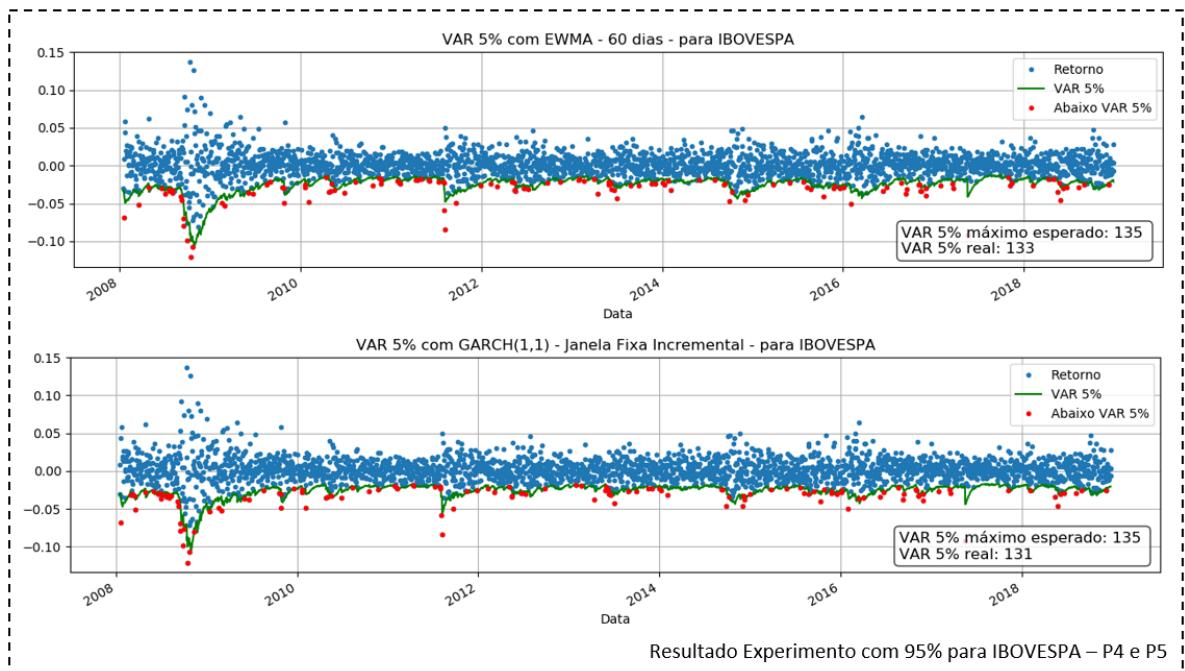
E RESULTADO - ETAPA 1 COM IBOVESPA

Os resultados do experimento calculado com o VaR paramétrico feito para a IBOVESPA para os modelos P4, P5, P7 e P10 da Tabela 1 estão parcialmente apresentados nessa seção.

O período de 01 de janeiro de 2004 à 16 de janeiro de 2008 foi utilizado como treinamento com 1.000 dias. O período de 17 de janeiro de 2008 e 28 de dezembro de 2018 foi utilizado como teste com 2.714 dias.

A Figura 28 contém apresentação do VaR paramétrico para IBOVESPA nos modelos P4 e P5.

Figura 28 – IBOVESPA paramétrico modelos P4 e P5

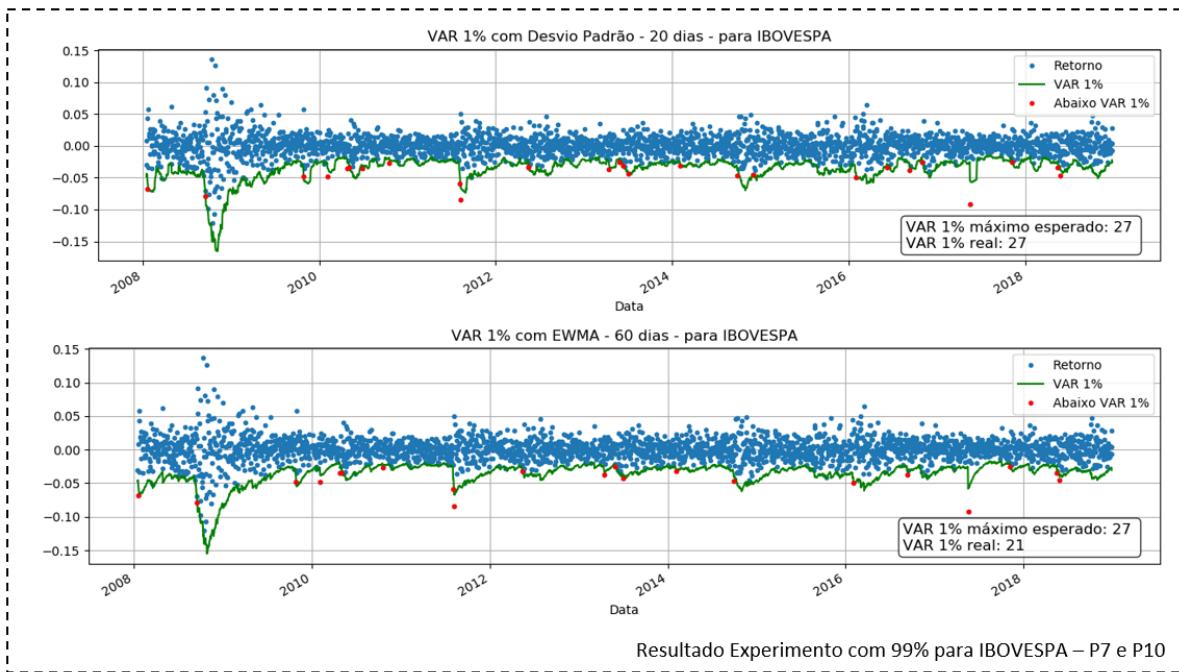


Fonte: Elaborado pelo autor

Obtivemos um resultado de 133 exceções, com uma acurácia de 95,10% e erro de 0,00111070 para o modelo P4 que utiliza a volatilidade EWMA em 60 dias. E obtivemos um resultado de 131 exceções, com uma acurácia de 95,17% e erro de 0,00112337 para o modelo P5 que utiliza a volatilidade GARCH incremental.

A Figura 29 contém a apresentação do VaR paramétrico para IBOVESPA nos modelos P7 e P10.

Figura 29 – IBOVESPA paramétrico modelos P7 e P10



Fonte: Elaborado pelo autor

Obtivemos um resultado de 27 exceções, com uma acurácia de 99,01% e erro de 0,00196605 para o modelo P7 que utiliza a volatilidade desvio padrão em 20 dias. E obtivemos um resultado de 21 exceções, com uma acurácia de 99,23% e erro de 0,00191505 para o modelo P10 que utiliza a volatilidade EWMA com 60 das.

A Tabela 28 contém os primeiros e últimos valores previstos para a série IBOVESPA com os modelos P4, P5, P7 e P10.

Tabela 28 – VaR paramétrico do IBOVESPA de 2008 à 2018

Data	Fechamento	Log Ret.	VaR P4	VaR P5	VaR P7	VaR P10
2008-01-17	57037	-0.030050	-0.033088	-0.030557	-0.048048	-0.046797
2008-01-18	57506	0.008189	-0.032215	-0.031610	-0.043591	-0.045562
2008-01-21	53709	-0.068309	-0.041629	-0.030832	-0.053756	-0.058877
2008-01-22	56097	0.043502	-0.043937	-0.038784	-0.059208	-0.062140
2008-01-23	54235	-0.033756	-0.044715	-0.040639	-0.061012	-0.063242
...
2018-12-20	85269	-0.004738	-0.020329	-0.021436	-0.027436	-0.028752
2018-12-21	85697	0.005007	-0.019781	-0.021001	-0.026645	-0.027977
2018-12-26	85136	-0.006568	-0.019353	-0.020545	-0.026541	-0.027372
2018-12-27	85460	0.003798	-0.018826	-0.020206	-0.022126	-0.026626
2018-12-28	87887	0.028003	-0.021432	-0.019759	-0.025565	-0.030311

Fonte: Elaborado pelo autor

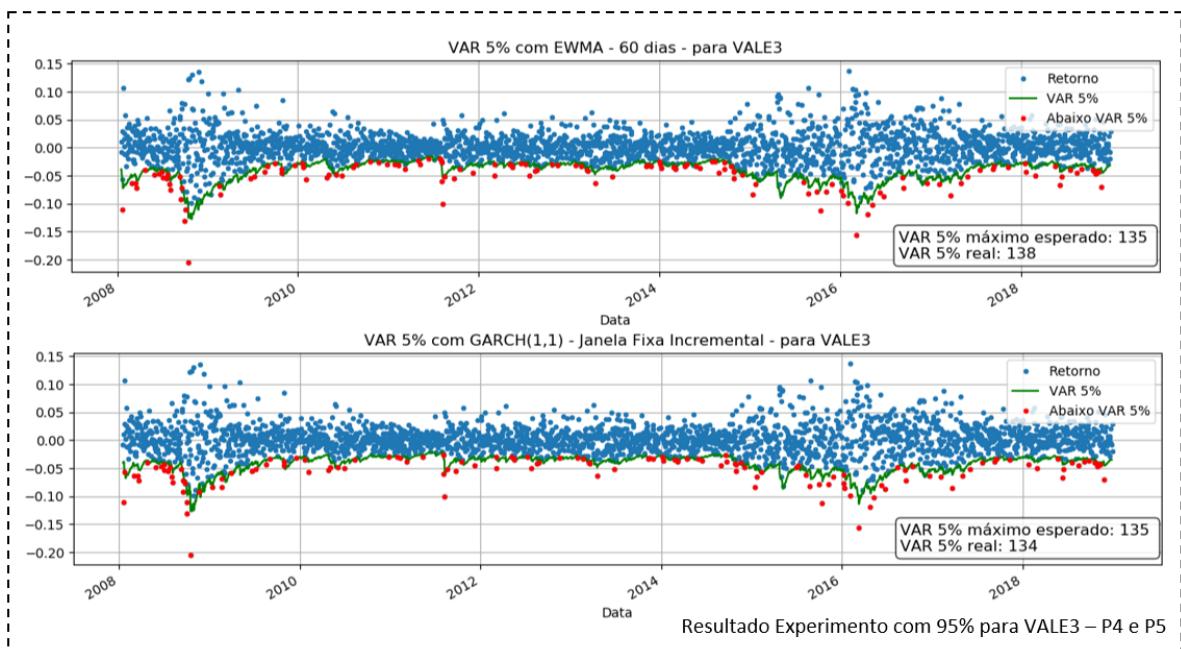
F RESULTADO - ETAPA 1 COM VALE3

Nesse apêndice, apresentamos os resultados do experimento para a VALE3 para os modelos P4, P5, P7 e P10. Para o detalhamento de cada modelo avalie a Tabela 1.

Assim como para o IBOVESPA, o período de 01 de janeiro de 2004 à 16 de janeiro de 2008 foi utilizado como treinamento com 1.000 dias. O período de 17 de janeiro de 2008 e 28 de dezembro de 2018 foi utilizado como teste com 2.714 dias.

A Figura 30 contém a apresentação do VaR paramétrico para VALE3 nos modelos P4 e P5.

Figura 30 – VALE3 paramétrico modelos P4 e P5

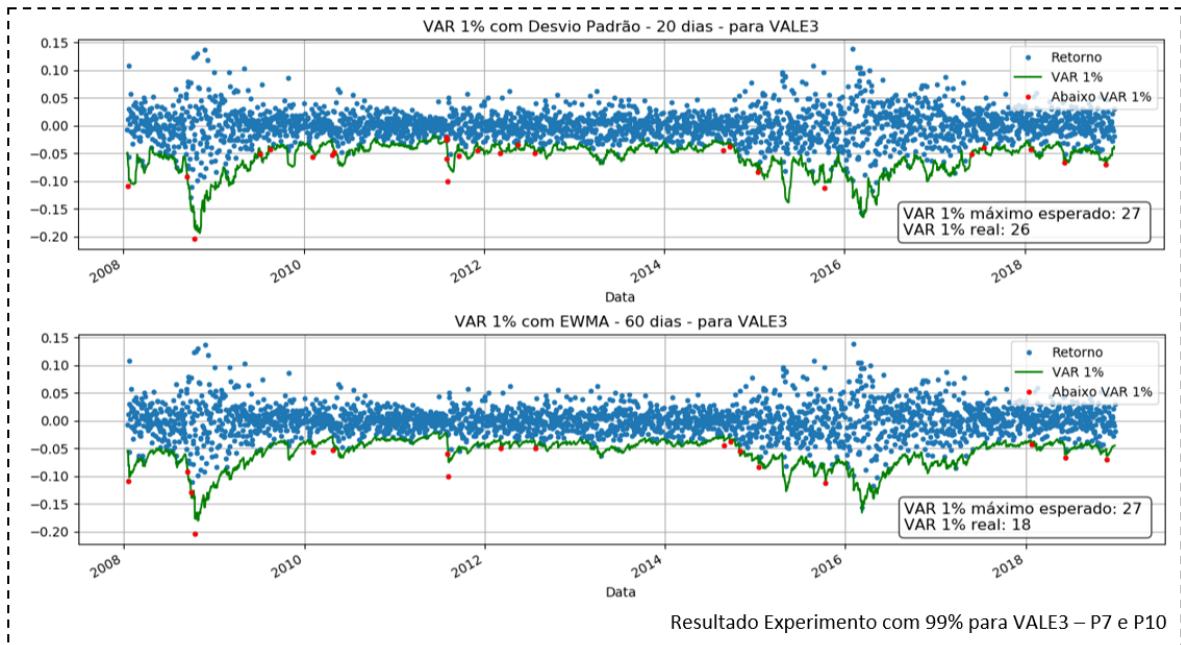


Fonte: Elaborado pelo autor

Obtivemos um resultado de 138 exceções, com uma acurácia de 94,92% e erro de 0,00288044 para o modelo P4 que utiliza a volatilidade EWMA em 60 dias. E obtivemos um resultado de 134 exceções, com uma acurácia de 95,07% e erro de 0,00285839 para o modelo P5 que utiliza a volatilidade GARCH incremental.

A Figura 31 contém a apresentação do VaR paramétrico para IBOVESPA nos modelos P7 e P10.

Figura 31 – VALE3 paramétrico modelos P7 e P10



Fonte: Elaborado pelo autor

Obtivemos um resultado de 26 exceções, com uma acurácia de 99,04% e erro de 0,00510039 para o modelo P7 que utiliza a volatilidade desvio padrão em 20 dias. E obtivemos um resultado de 18 exceções, com uma acurácia de 99,34% e erro de 0,00496351 para o modelo P10 que utiliza a volatilidade EWMA com 60 das.

A Tabela 29 contém os primeiros e últimos valores previstos para a série VALE3 com os modelos P4, P5, P7 e P10.

Tabela 29 – VaR paramétrico do VALE3 de 2008 à 2018

Data	Fechamento	Log Ret.	VaR P4	VaR P5	VaR P7	VaR P10
2008-01-17	30.31	-0.007232	-0.039109	-0.039840	-0.050632	-0.055312
2008-01-18	30.64	0.010829	-0.038155	-0.038911	-0.048886	-0.053963
2008-01-21	27.45	-0.109940	-0.057708	-0.038141	-0.072376	-0.081617
2008-01-22	28.27	0.029435	-0.057075	-0.053498	-0.074279	-0.080723
2008-01-23	26.72	-0.056389	-0.059816	-0.052763	-0.076606	-0.084598
...
2018-12-20	49.81	-0.004007	-0.032842	-0.035545	-0.053949	-0.046450
2018-12-21	50.86	0.020861	-0.032922	-0.034702	-0.041266	-0.046562
2018-12-26	50.44	-0.008292	-0.032027	-0.034758	-0.041441	-0.045297
2018-12-27	49.50	-0.018812	-0.031883	-0.034056	-0.042581	-0.045093
2018-12-28	51.00	0.029853	-0.033165	-0.034020	-0.037962	-0.046906

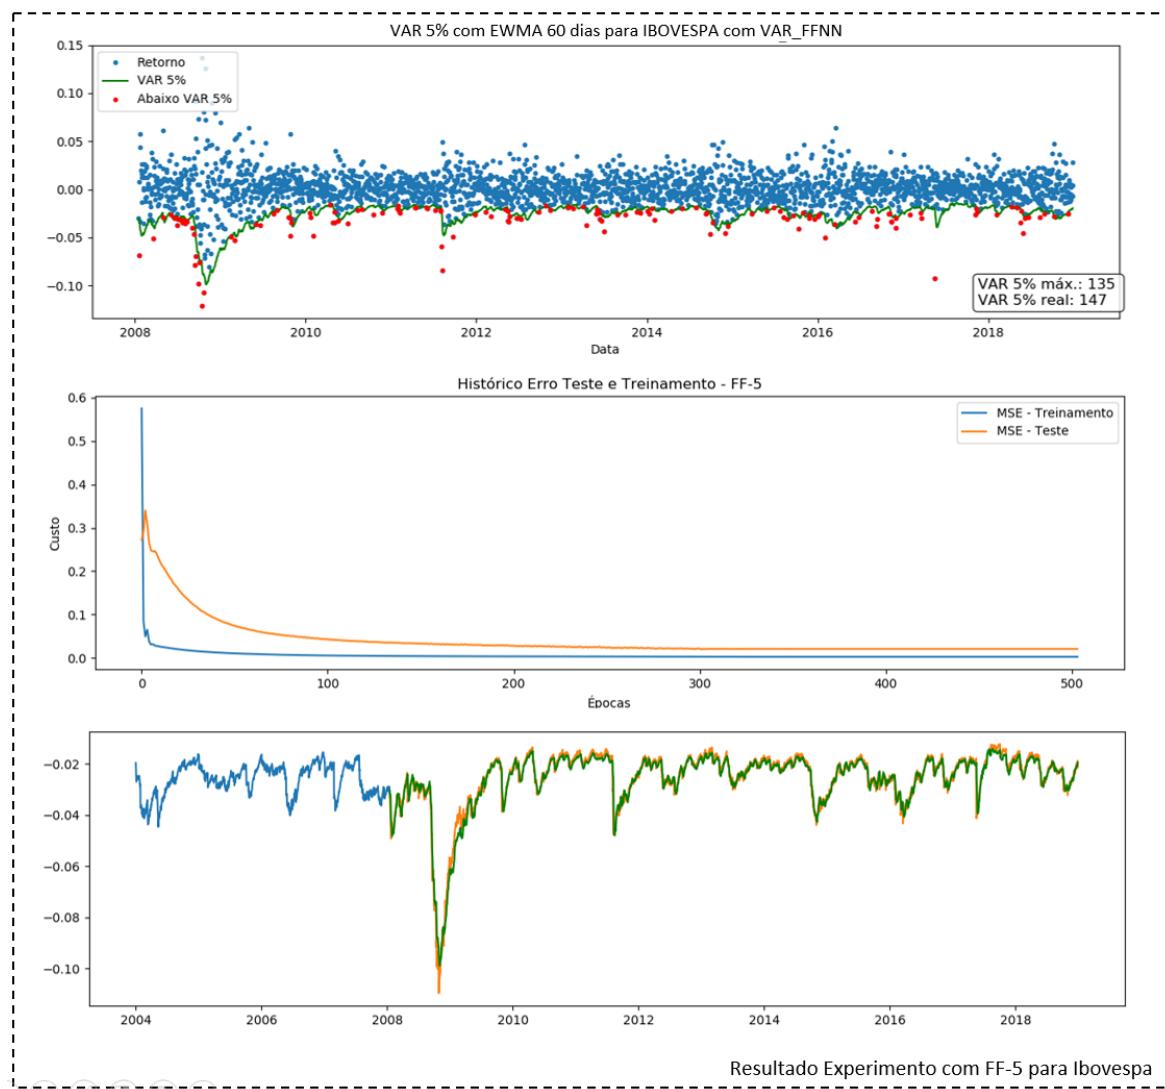
Fonte: Elaborado pelo autor

G RESULTADO - ETAPA 2 COM IBOVESPA

Apresentamos o resultado do experimento FF-5, que teve melhor desempenho dentre os registrados na Tabela 9. Apresentamos também, o gráfico do VaR dos modelos FF-2, FF-15 e FF-18 para fins de comparação.

A Figura 32 contém a apresentação do VaR paramétrico para IBOVESPA nos modelos P4 e P5.

Figura 32 – IBOVESPA Feedforward FF-5

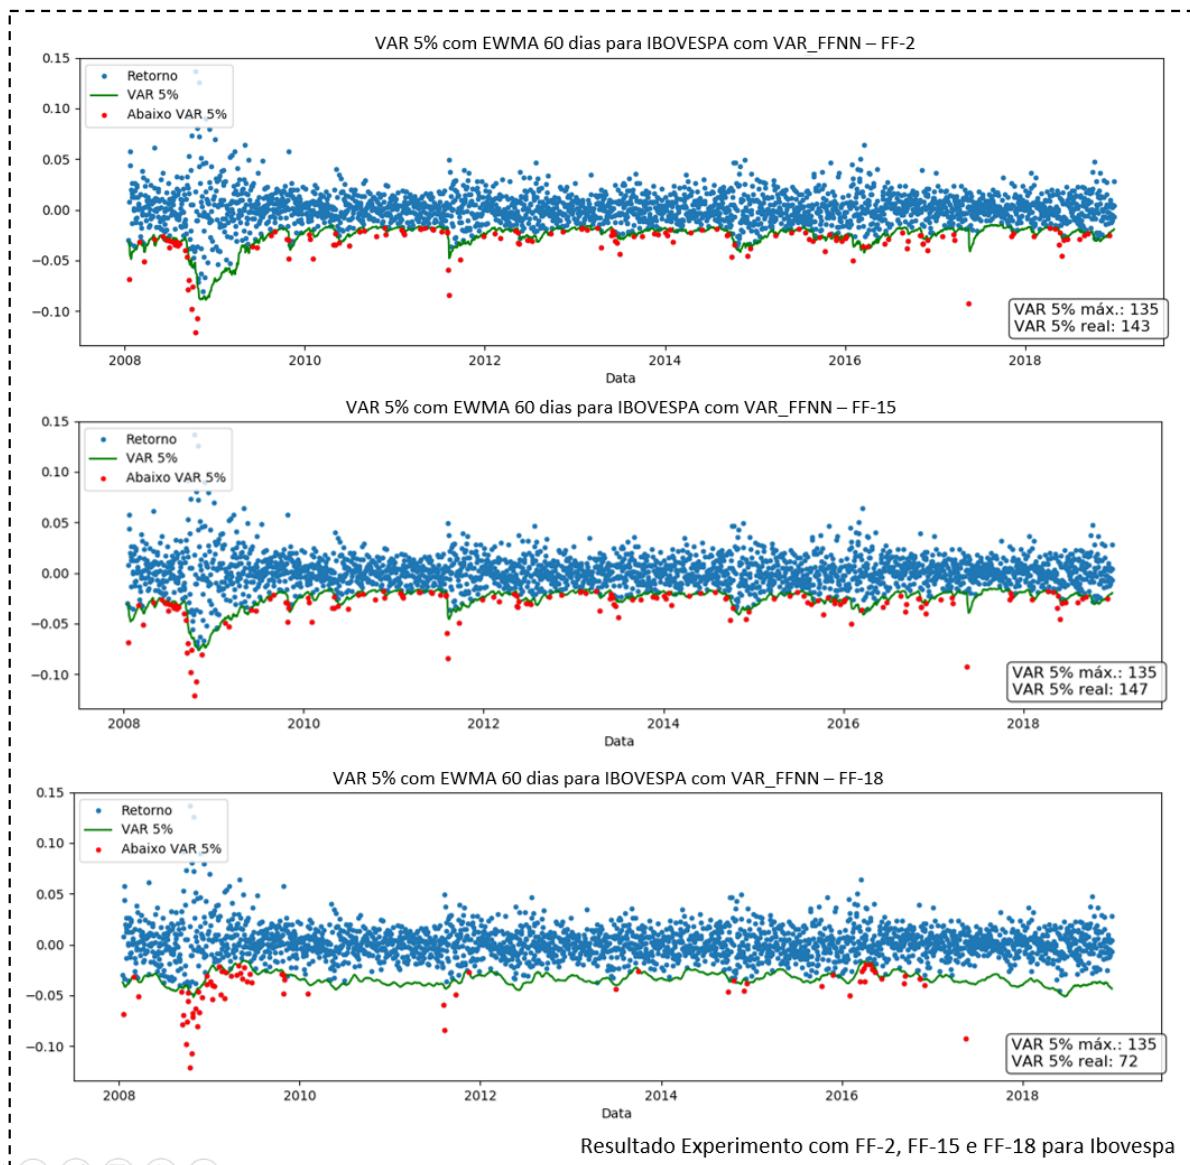


Fonte: Elaborado pelo autor

Obtivemos um resultado de 147 exceções, com uma acurácia de 94,58% e erro de 0,00112418 para o modelo FF-5 que utiliza a volatilidade EWMA em 60 dias.

A Figura 33 contém a apresentação do VaR paramétrico para IBOVESPA nos modelos FF-2, FF-15 e FF-18. Ao compararmos com o resultado do modelo FF-5 nós obtivemos uma piora na previsão apesar do valor de exceção ter sido igual ou menor ao respectivo modelo.

Figura 33 – IBOVESPA Feedforward modelos FF-2, FF-15 e FF-18



Fonte: Elaborado pelo autor

A Tabela 30 contém os primeiros e últimos valores previstos para a série IBOVESPA com os modelos FF-5

Tabela 30 – VaR FFNN, FF-5 do IBOVESPA de 2008 à 2018

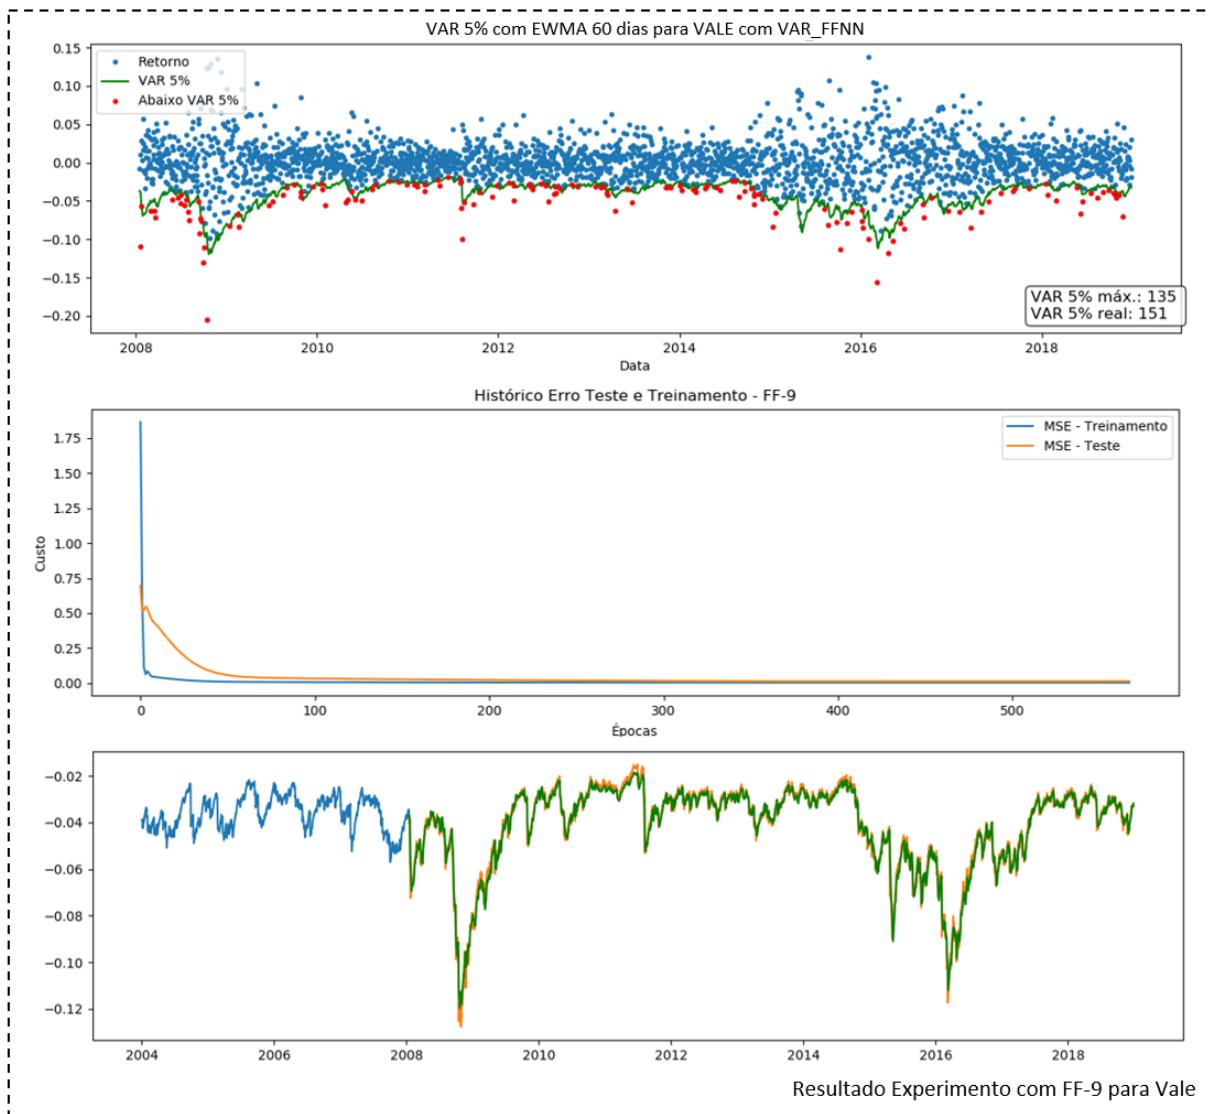
Data	Fechamento	Log Ret.	VaR FF-5
2008-01-17	57037	-0.030050	-0.030596
2008-01-18	57506	0.008189	-0.031727
2008-01-21	53709	-0.068309	-0.032017
2008-01-22	56097	0.043502	-0.034806
2008-01-23	54235	-0.033756	-0.038224
...
2018-12-20	85269	-0.004738	-0,020736
2018-12-21	85697	0.005007	-0,020569
2018-12-26	85136	-0.006568	-0,020844
2018-12-27	85460	0.003798	-0,02034
2018-12-28	87887	0.028003	-0,019475

Fonte: Elaborado pelo autor

H RESULTADO - ETAPA 2 COM VALE

Apresentamos o resultado do experimento FF-9 da VALE, que teve melhor desempenho dentre os registrados na Tabela 11. Apresentamos também, a gráfico do VaR do modelo FF-21. A Figura 34 contém a apresentação do VaR paramétrico para IBOVESPA nos modelos P4 e P5.

Figura 34 – VALE Feedforward FF-9

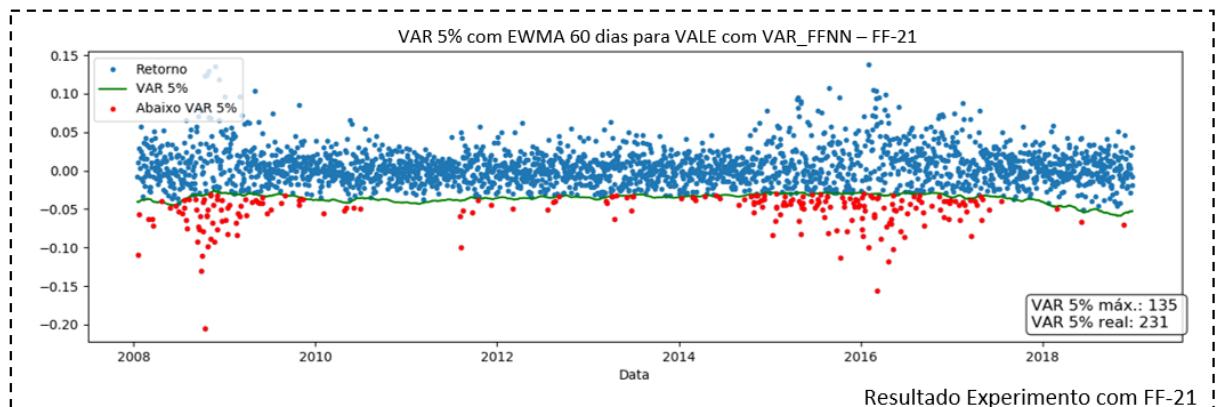


Fonte: Elaborado pelo autor

Obtivemos um resultado de 151 exceções, com uma acurácia de 94,44% e erro de 0,00290368 para o modelo FF-9 que utiliza a volatilidade EWMA em 60 dias.

A Figura 35 contém a apresentação do VaR paramétrico para VALE nos modelos FF-21. Ao compararmos com o resultado do modelo FF-9 nós obtivemos uma piora na previsão apesar do valor de exceção ter sido igual ou menor ao respectivo modelo.

Figura 35 – VALE Feedforward modelos FF-21



Fonte: Elaborado pelo autor

A Tabela 31 contém os primeiros e últimos valores previstos para a série VALE com os modelos FF-9.

Tabela 31 – VaR FFNN, FF-5 do VALE de 2008 à 2018

Data	Fechamento	Log Ret.	VaR FF-9
2008-01-17	30.31	-0.007232	-0,036848
2008-01-18	30.64	0.010829	-0,037847
2008-01-21	27.45	-0.109940	-0,038480
2008-01-22	28.27	0.029435	-0,047060
2008-01-23	26.72	-0.056389	-0,052812
...
2018-12-20	49.81	-0.004007	-0,032832
2018-12-21	50.86	0.020861	-0,032767
2018-12-26	50.44	-0.008292	-0,032652
2018-12-27	49.50	-0.018812	-0,032948
2018-12-28	51.00	0.029853	-0,031770

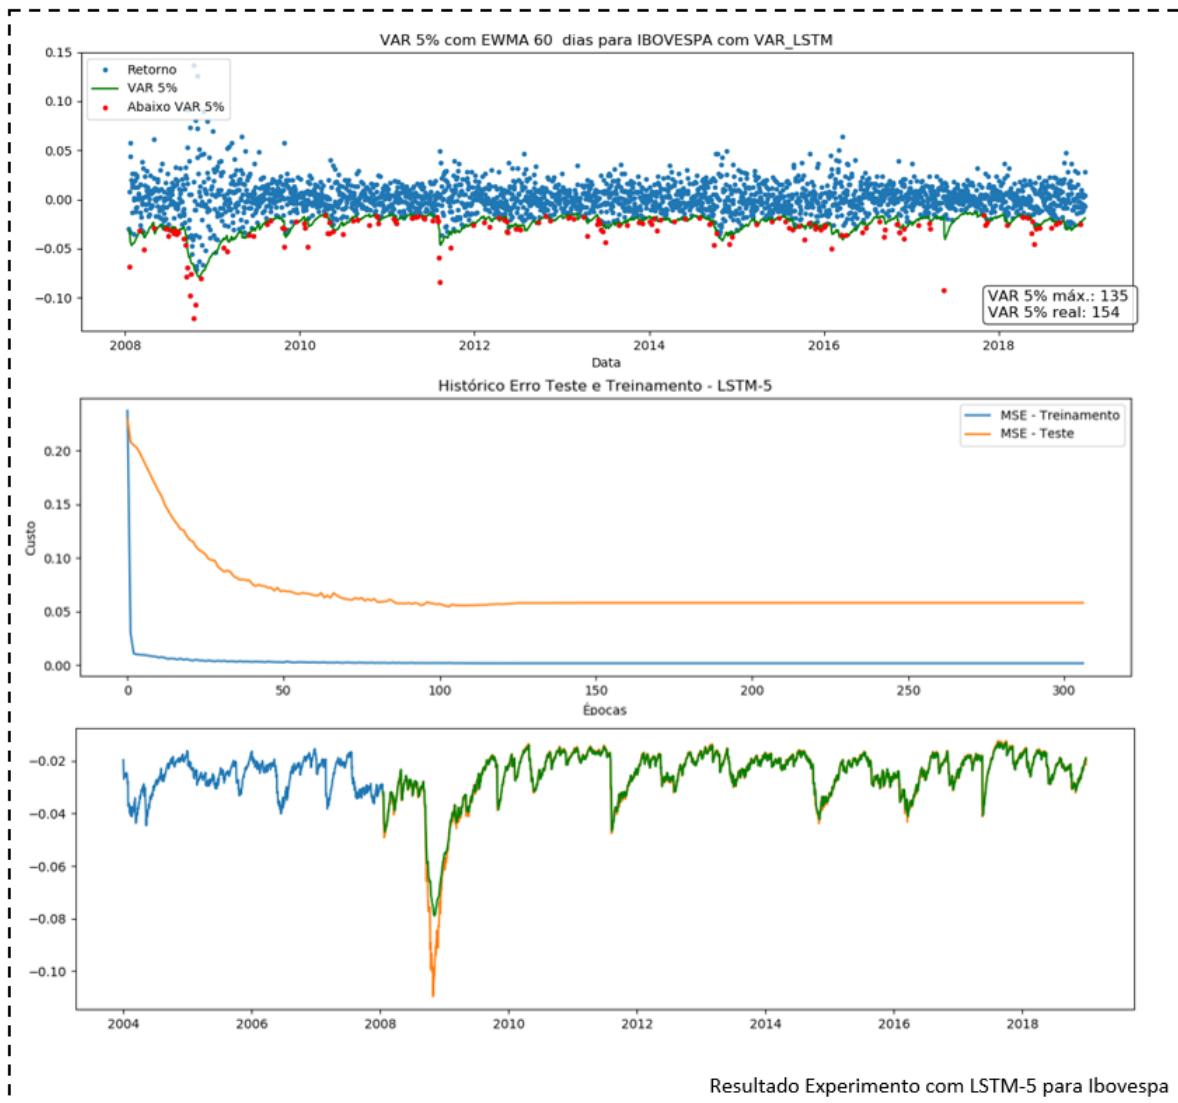
Fonte: Elaborado pelo autor

I RESULTADO - ETAPA 3 COM IBOVESPA

Apresentamos nesse apêndice os gráficos dos experimentos LSTM-5, LSTM-11, LSTM-15, LSTM-20 e LSTM-28.

A Figura 36 contém a apresentação do VaR para o modelo LSTM-5. Obtivemos um resultado de 154 exceções, com uma acurácia de 94,32% e erro de 0,00105448. O tempo de treino e previsão foi de 1 minuto e 8 segundos.

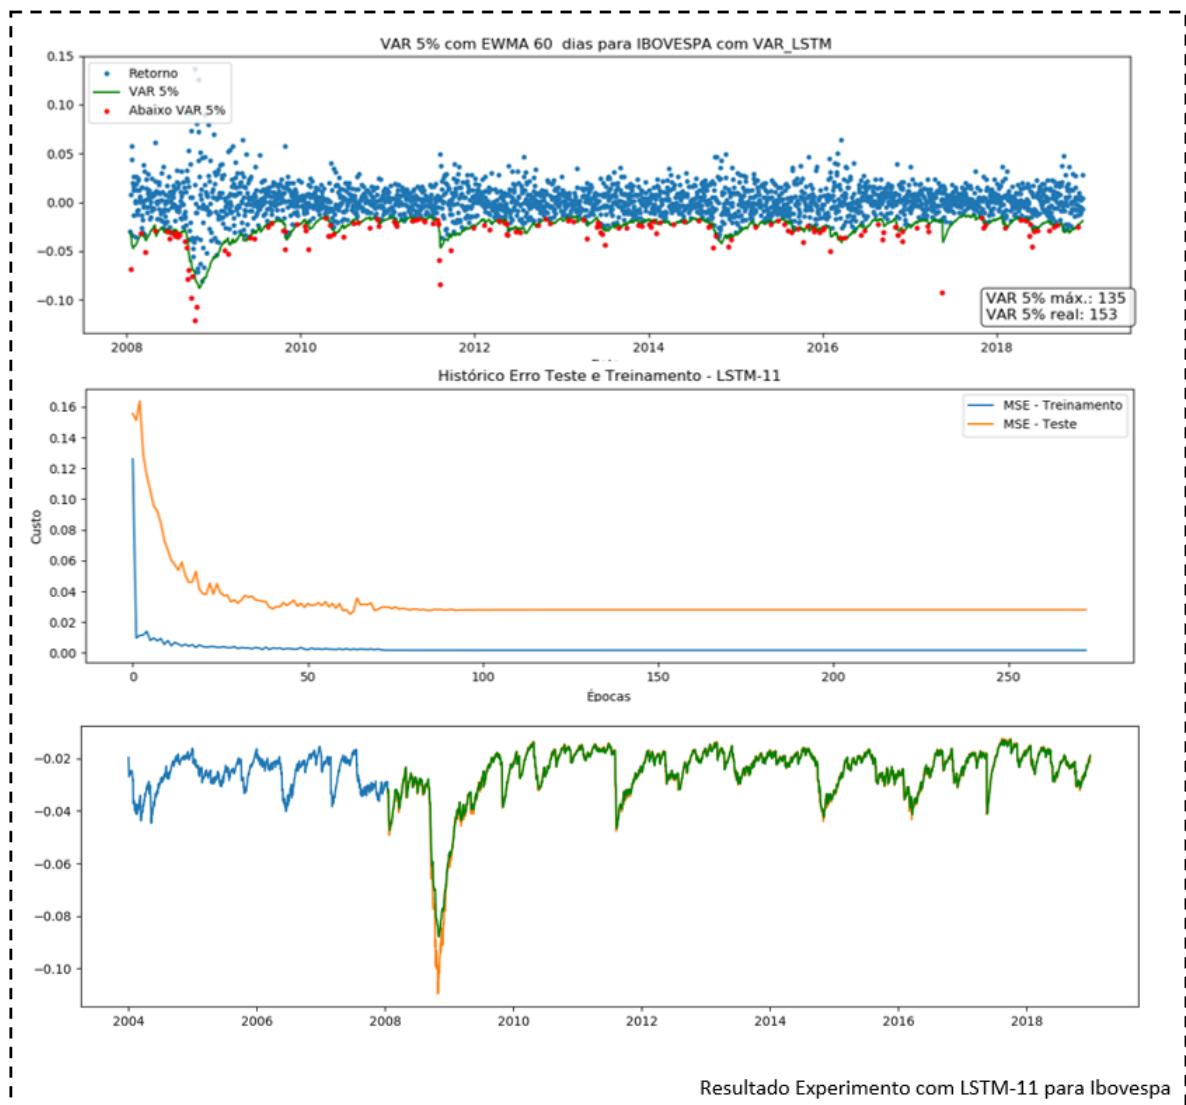
Figura 36 – IBOVESPA LSTM-5



Fonte: Elaborado pelo autor

A Figura 37 contém a apresentação do VaR para o modelo LSTM-11. Obtivemos um resultado de 153 exceções, com uma acurácia de 94,35% e erro de 0,00107207. A duração do treino e previsão foi de 2 minutos e 47 segundos.

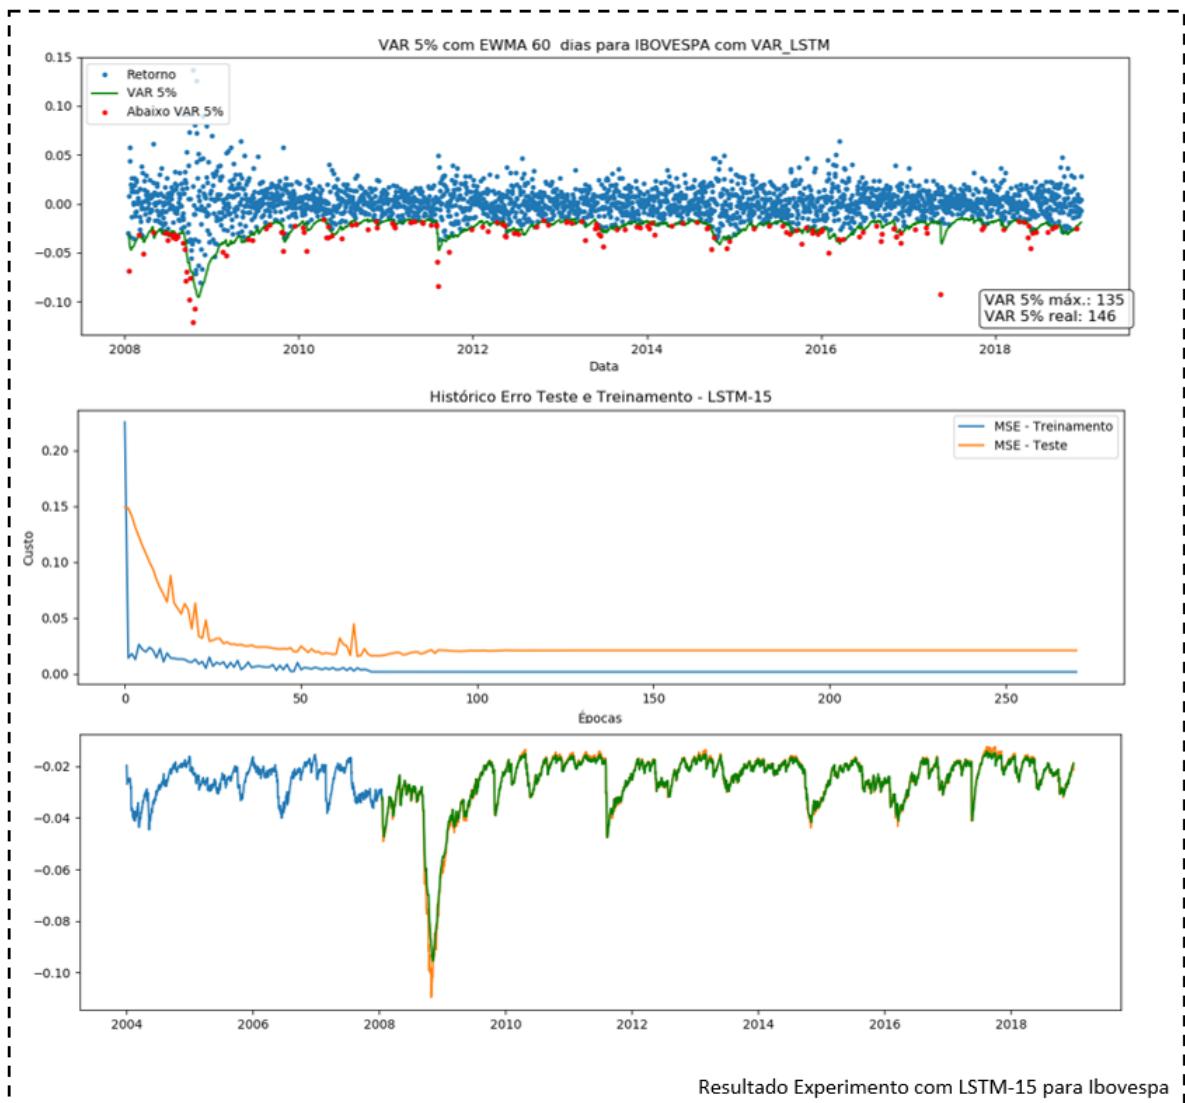
Figura 37 – IBOVESPA LSTM-11



Fonte: Elaborado pelo autor

A Figura 38 contém a apresentação do VaR para o modelo LSTM-15. Obtivemos um resultado de 146 exceções, com uma acurácia de 94,61% e erro de 0,00108674. O tempo gasto com treino e previsão foi de 12 minutos e 7 segundos.

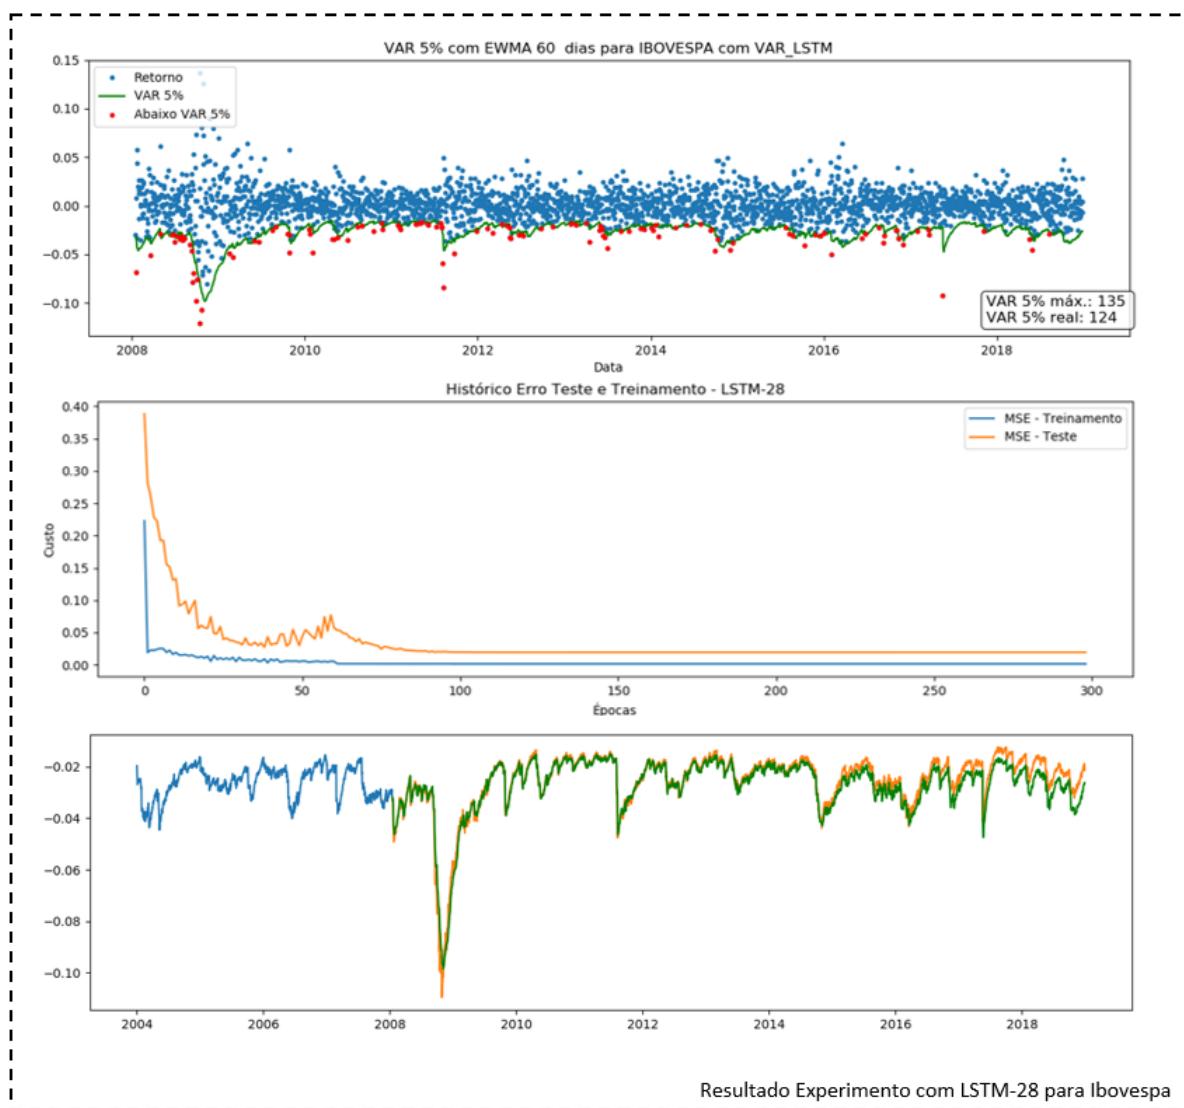
Figura 38 – IBOVESPA LSTM-15



Fonte: Elaborado pelo autor

A Figura 39 contém a apresentação para o modelo LSTM-28. Obtivemos um resultado de 124 exceções, com uma acurácia de 95,42% e erro de 0,00119223. O tempo gasto com treino e previsão foi de 17 minutos e 13 segundos.

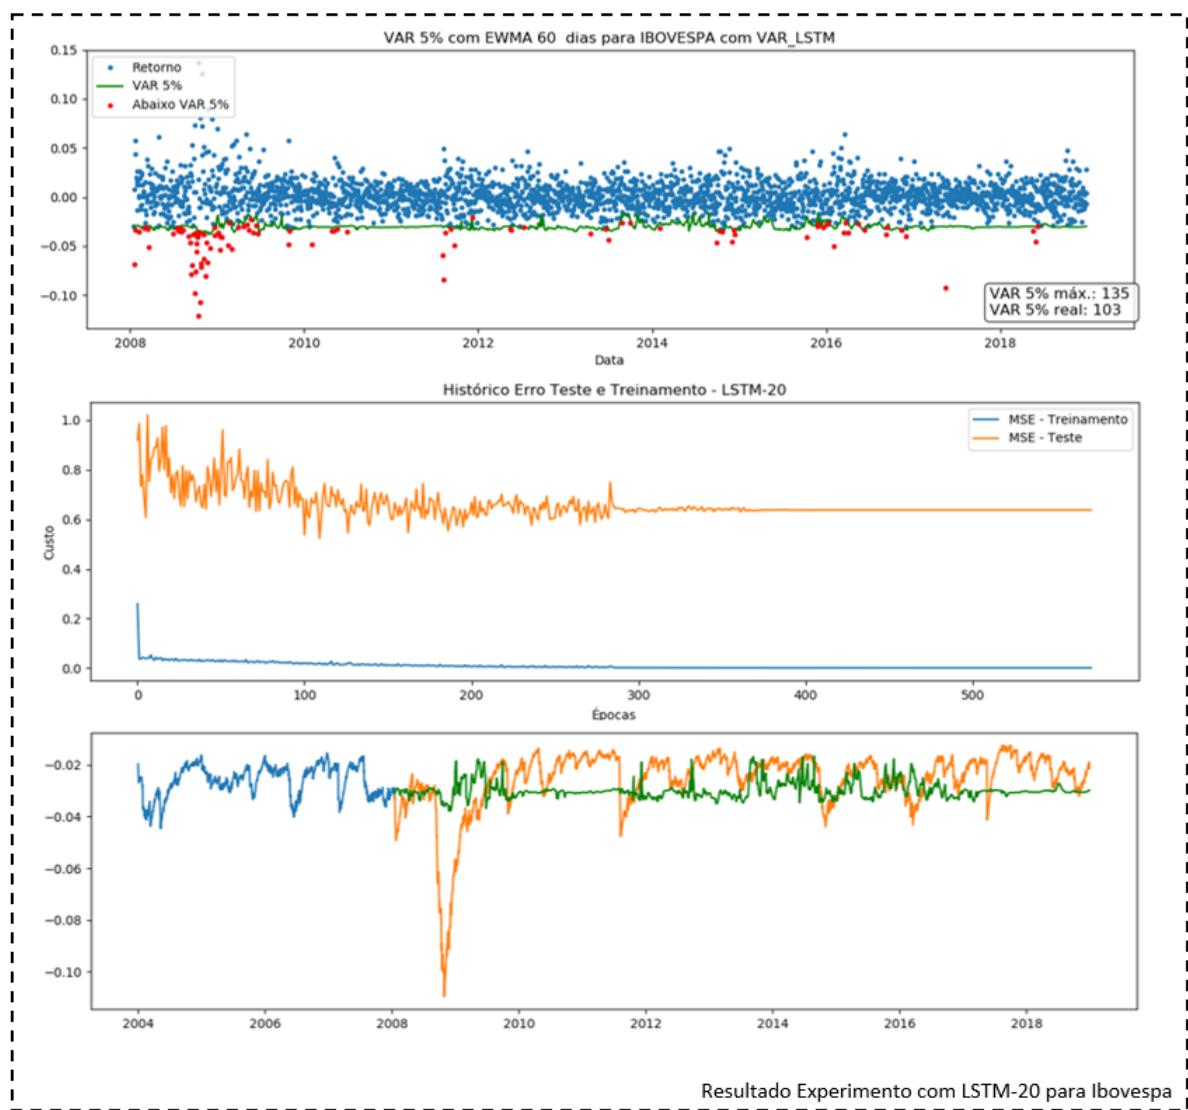
Figura 39 – IBOVESPA LSTM-28



Fonte: Elaborado pelo autor

Por fim, deixamos o contraponto de um treino não bem sucedido. Escolhemos o LSTM-20 para essa demonstração. Por mais que a taxa de exceção esteja abaixo do esperado (103) e o erro da previsão esteja próximo dos anteriores (0,00121279), o erro de teste ficou muito elevado (0,63788877), conforme a Figura 40.

Figura 40 – IBOVESPA LSTM-20



Fonte: Elaborado pelo autor

A Tabela 32 contém os primeiros e últimos valores previstos para a série IBOVESPA para o modelo LSTM-28

Tabela 32 – VaR LSTM-28 de IBOVESPA de 2008 à 2018

Data	Fechamento	Log Ret.	VaR LSTM-28
2008-01-17	57037	-0.030050	-0,031994
2008-01-18	57506	0.008189	-0,033047
2008-01-21	53709	-0.068309	-0,032814
2008-01-22	56097	0.043502	-0,037879
2008-01-23	54235	-0.033756	-0,041739
...
2018-12-20	85269	-0.004738	-0,028541
2018-12-21	85697	0.005007	-0,027564
2018-12-26	85136	-0.006568	-0,026660
2018-12-27	85460	0.003798	-0,026741
2018-12-28	87887	0.028003	-0,026257

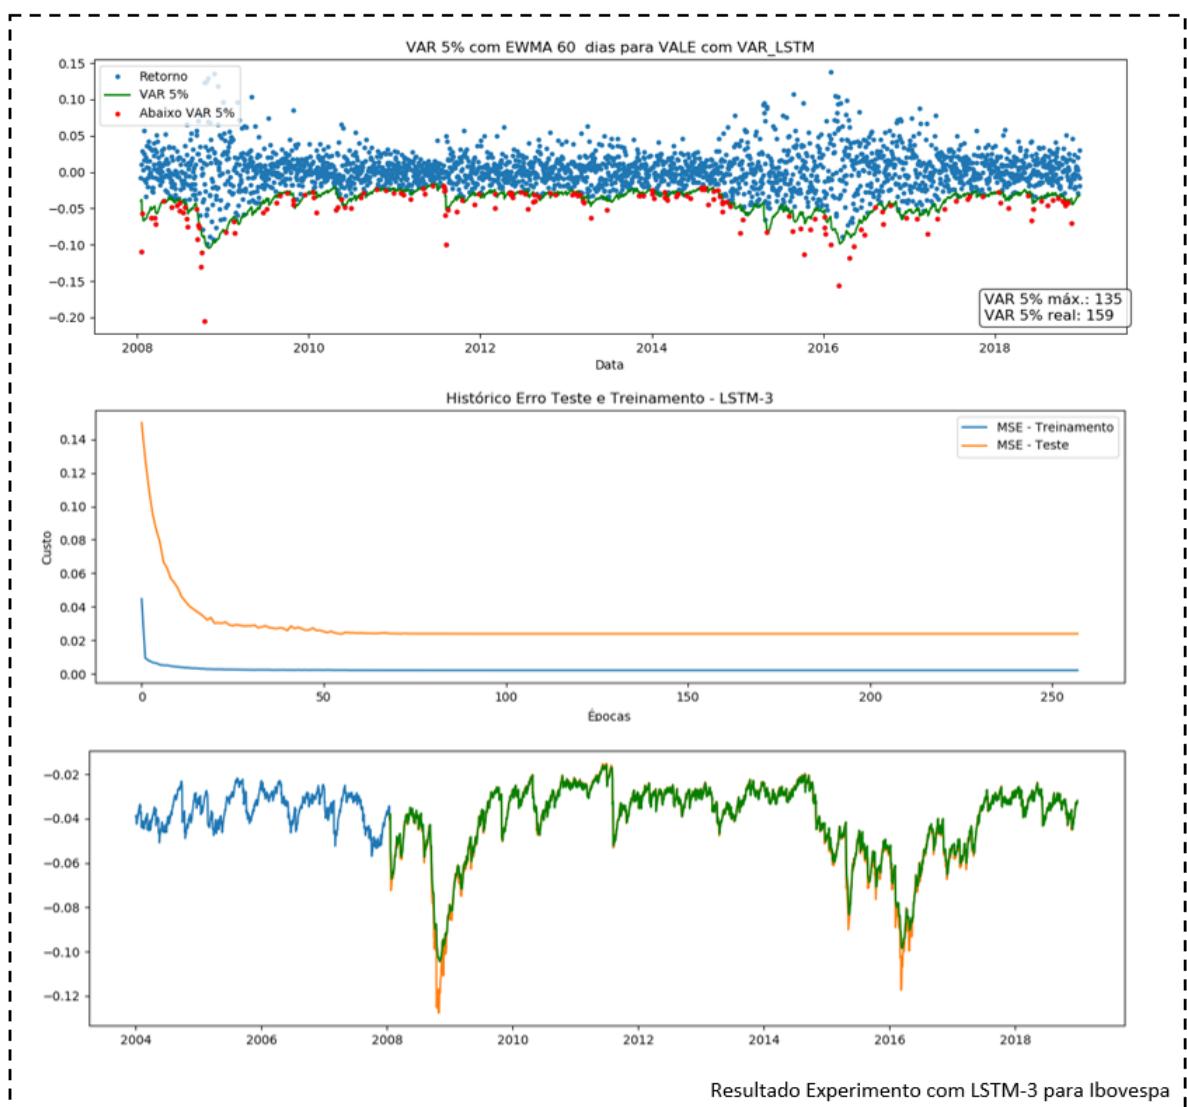
Fonte: Elaborado pelo autor

J RESULTADO - ETAPA 3 COM VALE

Apresentamos nesse apêndice os gráficos dos experimentos LSTM-3, LSTM-11, LSTM-15 e LSTM-25. Sendo que o LSTM-25 executando como um contraponto às execuções do LSTM-3 à LSTM-25.

A Figura 41 contém a apresentação do VaR para o modelo LSTM-3. Obtivemos um resultado de 159 exceções, com uma acurácia de 94,13% e erro de 0,00279970. O tempo de treino e previsão foi de 2 minutos e 33 segundos.

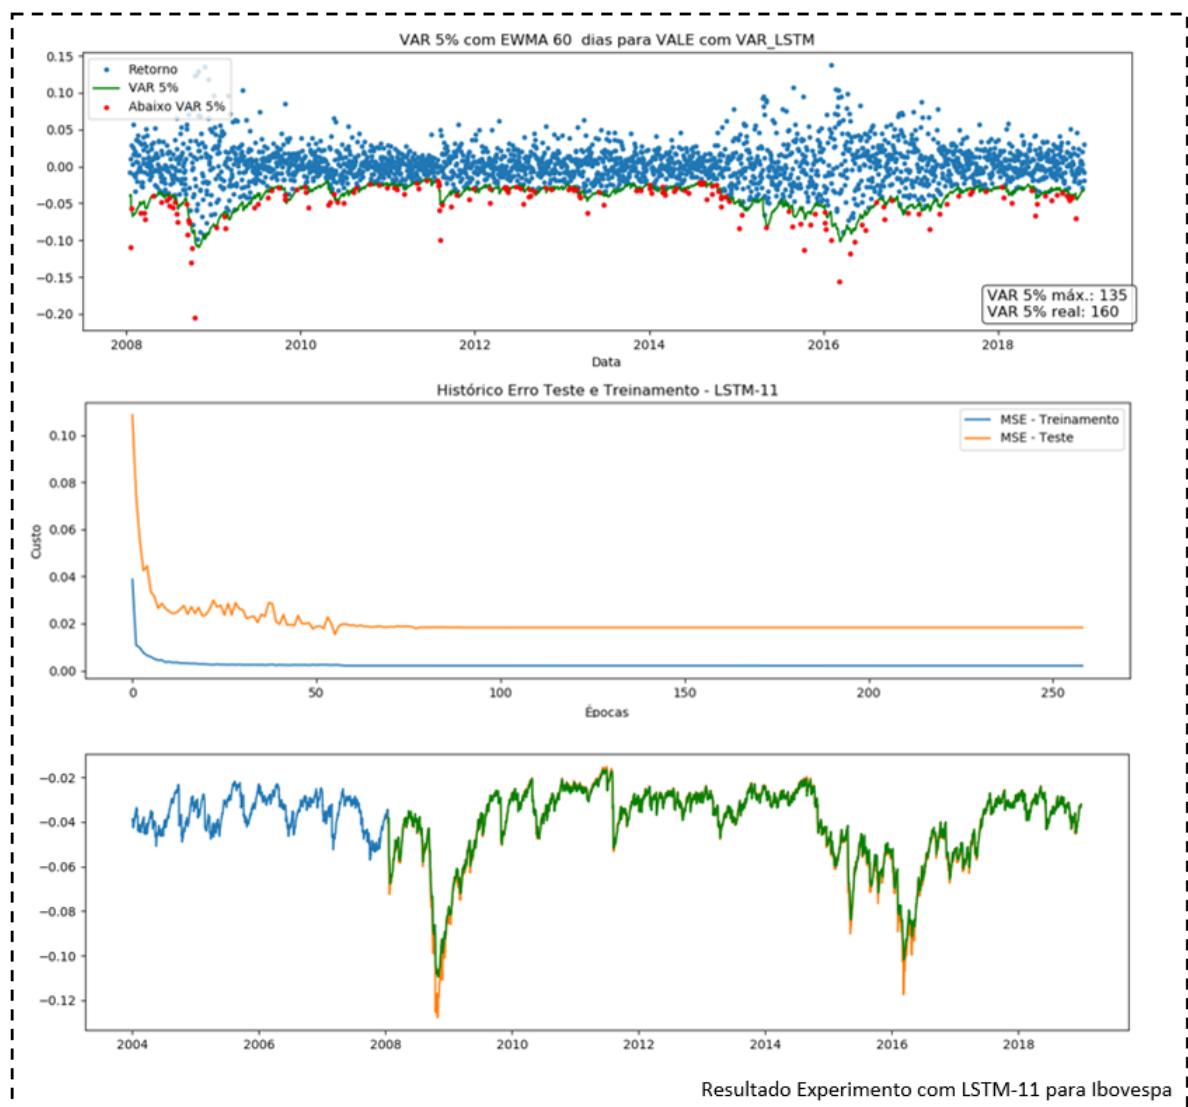
Figura 41 – VALE LSTM-3



Fonte: Elaborado pelo autor

A Figura 42 contém a apresentação do VaR para o modelo LSTM-11. Obtivemos um resultado de 160 exceções, com uma acurácia de 94,09% e erro de 0,00280400. A duração do treino e previsão foi de 3 minutos e 48 segundos.

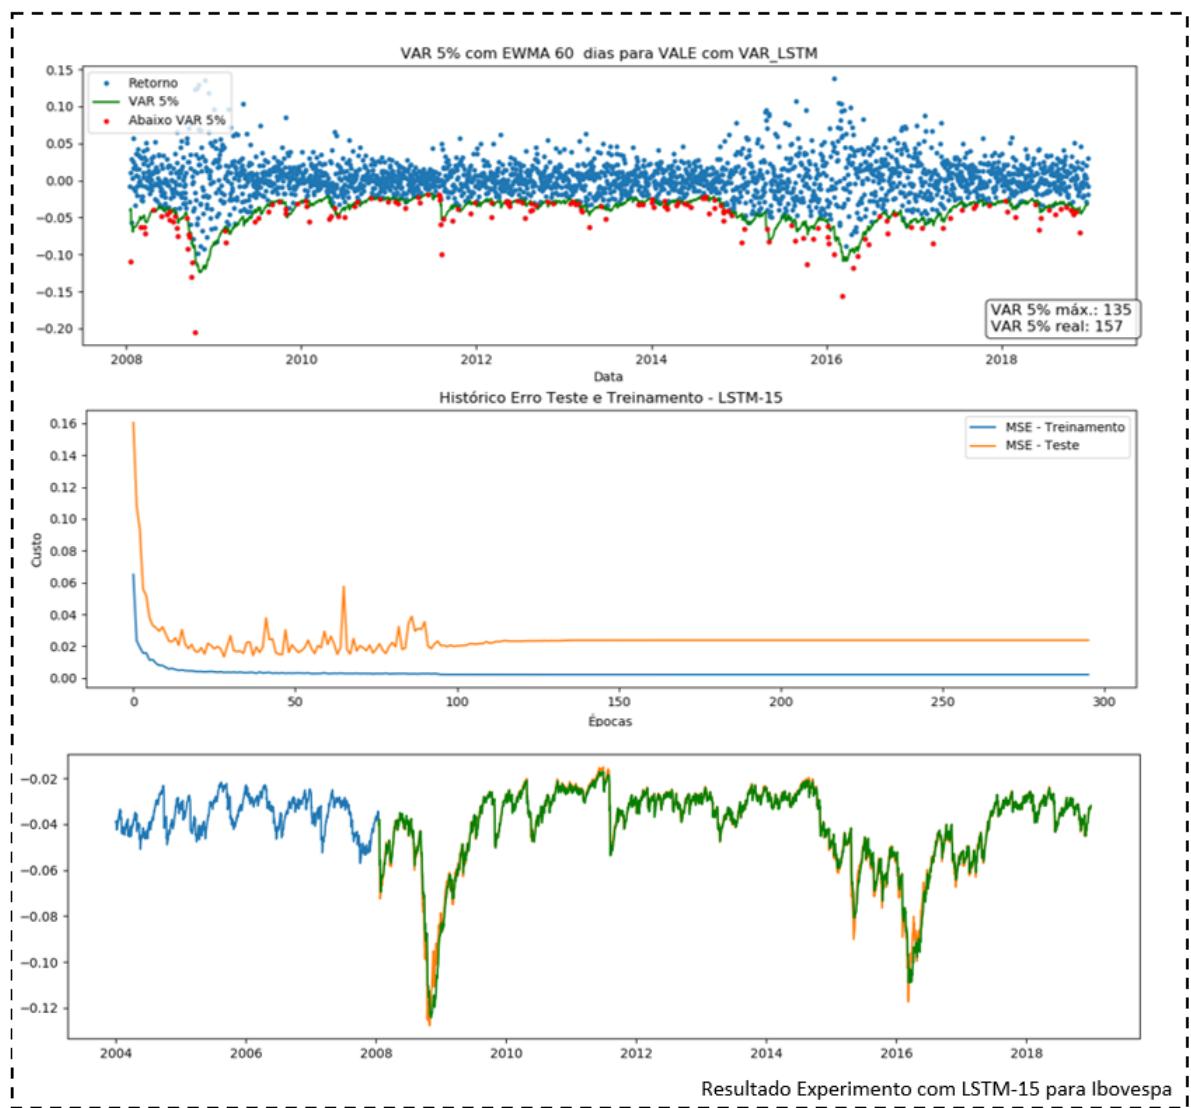
Figura 42 – VALE LSTM-11



Fonte: Elaborado pelo autor

A Figura 43 contém a apresentação do VaR para o modelo LSTM-15. Obtivemos um resultado de 157 exceções, com uma acurácia de 94,20% e erro de 0,00291285. A duração do treino e previsão foi de 13 minutos e 49 segundos.

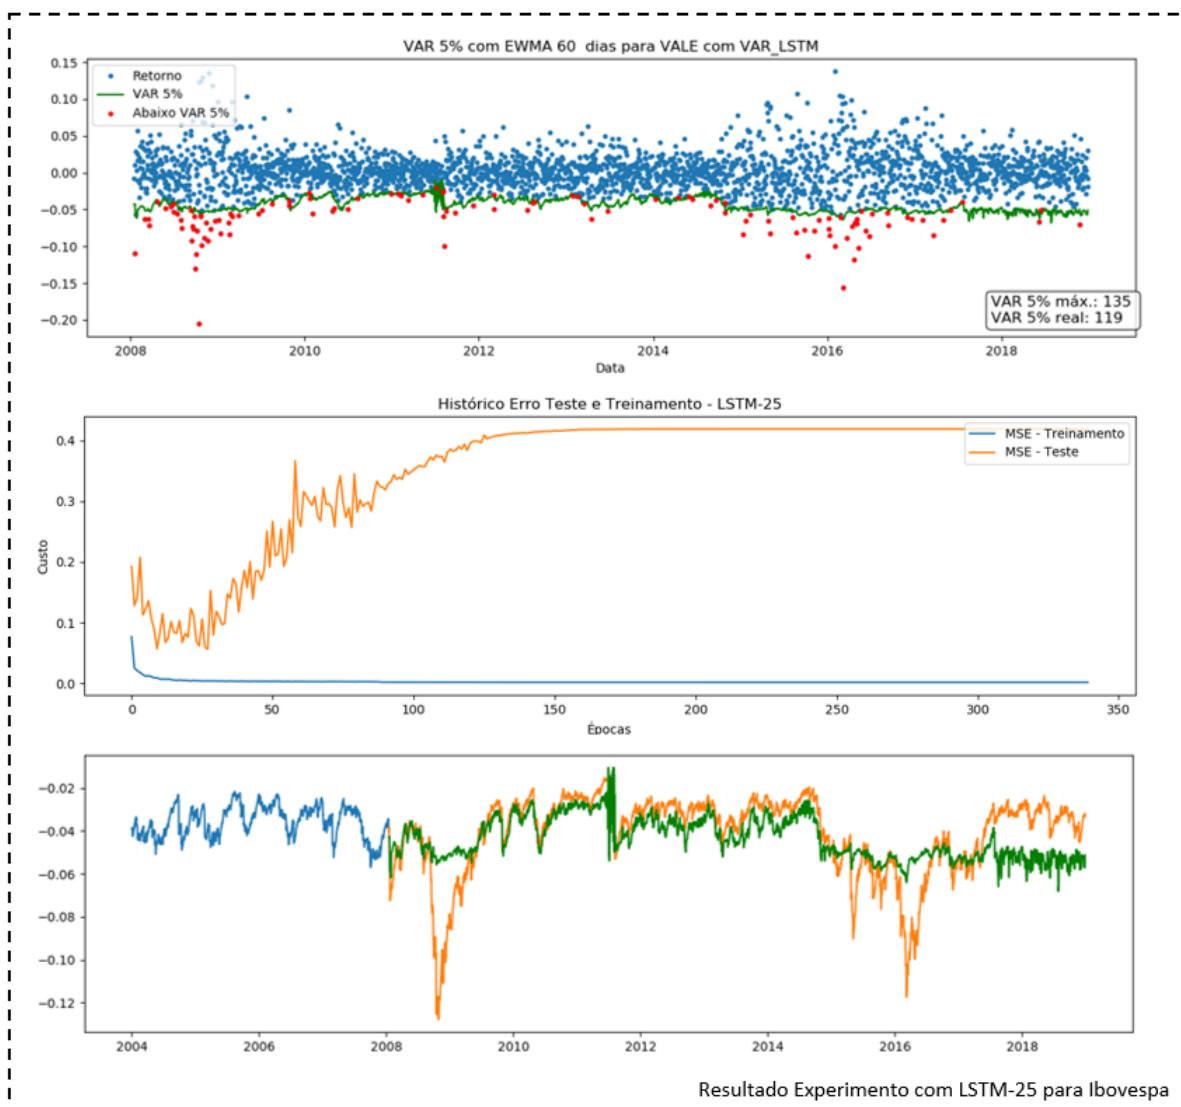
Figura 43 – VALE LSTM-15



Fonte: Elaborado pelo autor

A Figura 44 contém a apresentação do VaR para o modelo LSTM-25. Obtivemos um resultado de 119 exceções, com uma acurácia de 95,61%, com um erro razoável de 0,00280728, mas com um erro de testes muito alto 0,41917942 o que demonstra falta de adequação da base de testes. A duração do treino e previsão foi de 12 minutos e 59 segundos.

Figura 44 – VALE LSTM-25



Fonte: Elaborado pelo autor

A Tabela 33 contém os primeiros e últimos valores previstos para a série VALE com os modelos LSTM-15.

Tabela 33 – VaR LSTM-15 do VALE de 2008 à 2018

Data	Fechamento	Log Ret.	VaR FF-9
2008-01-17	30.31	-0.007232	-0,040079
2008-01-18	30.64	0.010829	-0,038926
2008-01-21	27.45	-0.109940	-0,037934
2008-01-22	28.27	0.029435	-0,056295
2008-01-23	26.72	-0.056389	-0,057897
...
2018-12-20	49.81	-0.004007	-0,033830
2018-12-21	50.86	0.020861	-0,032765
2018-12-26	50.44	-0.008292	-0,032912
2018-12-27	49.50	-0.018812	-0,032029
2018-12-28	51.00	0.029853	-0,031877

Fonte: Elaborado pelo autor

K REVISÃO SISTEMÁTICA DA LITERATURA

Nesse seção é apresentado o protocolo detalhado da revisão sistemática, a sua execução bem como a apresentação dos resultados encontrados.

K.1 Protocolo de Pesquisa

É nessa seção que o protocolo da revisão é detalhado. Cada subseção contém parte do protocolo de pesquisa.

K.1.1 Objetivo

O objetivo dessa revisão sistemática é: Identificar estudos que utilizaram redes neurais artificiais na previsão de volatilidade e Value-at-Risk para ativos negociados em bolsa de valores no mercado financeiro.

K.1.2 Questões de Pesquisa

A questão teve como objetivo direcionar a seleção dos estudos e os dados extraídos de cada um deles. Ao final da execução do protocolo, a questão deve ser respondida utilizando os estudos encontrados. A questão é:

- O uso de redes neurais artificiais podem gerar uma previsão de VaR e volatilidade mais eficiente para papéis negociados em bolsa de valores, como IBOVESPA e OMX30, frente às técnicas que utilizam EWMA e GARCH ?

Os seguintes critérios PICO (População, Intervenção, Controle e Resultados) foram considerados:

- **População:** Consideramos estudos que fazem previsão de volatilidade e Value-at-Risk utilizando redes neurais artificiais.
- **Intervenção:** Observamos, na pesquisa sistemática, os algorítimos de redes neurais utilizados e as métricas de comparação entre, modelos com redes neurais e modelos com métodos estatísticos.
- **Controle:** Devemos comparar os estudos com redes neurais artificias com métodos estatísticos como GARCH e VaR paramétrico. Esses modelos deverão ser avaliados e catalogados.
- **Resultados:** Esperamos identificar se o resultado para rede neural se mostrou mais ou menos eficaz do que os métodos com bases estatísticas.

K.1.3 Palavras-chave

As palavras-chave utilizadas na pesquisa procuraram abranger os estudos sobre volatilidade e Value-At-Risk que tenham sido estudados sob a ótica de algoritmos de redes neurais artificiais. Foram pesquisados estudos em *Português* e *Inglês*. Alguns termos em Inglês foram replicados na *string* de busca de termos em português, haja vista que autores poderiam utilizá-los ao invés de sua tradução.

- As palavras-chave em Inglês são:
"Neural Network", "ANN", "EWMA", "GARCH", "Value-at-Risk", "Value at Risk",
"Risk Management", "Risk", "Stock"
- As palavras-chave em Português são:
"Rede Neural", "Redes Neurais", "Neural Network", "GARCH", "Valor em Risco",
"Value-at-Risk", "Value at Risk", "Volatilidade", "Risco"

K.1.4 Fontes de Pesquisa

As fontes de pesquisa utilizadas para a busca deveriam atender os seguintes critérios:

- Artigos de bases eletrônicas indexadas via web.
- A base de pesquisa deve permitir a busca através de palavras-chave.
- Teses e Dissertações disponíveis em bases indexadas ou acessíveis via web de suas instituições de ensino.

Segundo os critérios de seleção de fontes de pesquisa, bases de dados de pesquisa foram selecionadas. Para o idioma em português optou-se por consultar o oasisbr. Artigos publicados na bases 1 a 4, de outros idiomas, necessariamente têm o seu resumo traduzido para o Inglês. Além disso, o oasisbr é uma portal de publicações científicas que, durante a confecção dessa dissertação, catalogava 886 instituições em todo território nacional brasileiro.

Tabela 34 – Fontes de pesquisa da revisão sistemática

Ordem	Portal de Pesquisa	Idioma
1	Scopus	Inglês
2	Science Direct	Inglês
3	ACM	Inglês
4	IEEE	Inglês
5	Web of Science	Inglês
6	oasisbr	Português

Fonte: Elaborado pelo autor

K.1.5 Critérios de Seleção

Para cada um dos estudos encontrados, foram aplicados critérios de inclusão e exclusão. Os critérios auxiliam a selecionar apenas estudos que, a critério do pesquisador, podem contribuir para o seu estudo. Por isso, os critérios devem estar alinhados ao objetivo e questões de pesquisa.

Tabela 35 – Critérios de inclusão e exclusão da revisão sistemática

Nº	Critério	Descrição
I1	(I)nclusão	Serão incluídos estudos que façam previsão de Value-at-Risk com redes neurais.
I2	(I)nclusão	Serão incluídos estudos que façam previsão de volatilidade com redes neurais.
I3	(I)nclusão	Serão incluídos estudos publicados à partir de 2008.
E1	(E)xclusão	Serão excluídos estudos que sejam capítulos de livros.
E2	(E)xclusão	Serão excluídos estudos que não prevejam de volatilidade ou VaR através de redes neurais.
E3	(E)xclusão	Serão excluídos estudos que não utilizem séries de ações como dados de pesquisa.
E4	(E)xclusão	Serão excluídos estudos que não comparem os resultados obtidos com modelos estatísticos.
E5	(E)xclusão	Serão excluídos estudos que tenham criado um modelo ou topologia durante o estudo.
E6	(E)xclusão	Serão excluídos estudos que não tenham feito experimento e apresentado os dados resultantes.
E7	(E)xclusão	Serão excluídos estudos duplicados.

Fonte: Elaborado pelo autor

K.1.6 Procedimento de Pesquisa

Foram confeccionadas strings de busca para pesquisas de artigos em Inglês. As strings foram submetidas aos portais de busca devidamente selecionados. As strings foram traduzidas para o português e submetidas aos portais definidos para esse idioma.

Os artigos retornados dos portais de buscas foram selecionados, catalogados e submetidos aos critérios de inclusão e exclusão. A aplicação dos critérios aconteceram em dois momentos. O primeiro filtro aconteceu através da leitura dos títulos e resumos dos estudos. O segundo filtro considerou a leitura completa do estudo. Por fim, os dados foram extraídos e tabulados.

K.1.7 Extração de dados

Após a leitura dos dados as seguintes informações foram extraídas. Cada um dos campos extraídos contribuíram para responder a pergunta da revisão sistemática. Em primeiro lugar foi identificado se o estudo tem como objetivo realizar a previsão de volatilidade ou Value-at-Risk. Em seguida, identificou-se qual foi o índice de ações utilizado na previsão de volatilidade.

O algoritmo utilizado foi o próximo item avaliado, eventuais características do algoritmo foram coletados, como quantidade de camadas de uma rede neural. Para validar a efetividade do algoritmo de rede neural, os estudos o comparam com modelos estatísticos conhecidos, por isso, foi feita a coleta dessa informação.

A métrica utilizada para comparação entre o modelo de rede neural e o modelo estatístico foi identificado e também foi coletado. Por fim, foi avaliado qual dos modelos se mostrou mais vantajoso e se há alguma ressalva a respeito.

Tabela 36 – Dados extraídos na revisão sistemática

Item	Dado coletado	PICO
Objetivo da Previsão	Volatilidade ou Value-at-Risk	População
Índice	Índice de ações de bolsa utilizado na previsão.	População
Algoritmo	Algoritmo estudo para realizar a previsão.	Intervenção
Método de efetividade	Métrica utilizada para comparar o algoritmo de rede neural e o estatístico.	Intervenção
Modelo Comparado	Modelo estatístico contra qual o algoritmo foi comparado.	Controle
Conclusão do Estudo	O modelo que se mostrou mais vantajoso.	Resultados

Fonte: Elaborado pelo autor

K.1.8 Sumarização

Os dados foram extraídos e tabulados. O resultado da revisão sistemática foi a consolidação das informações. É nesse momento que foram avaliados como os estudos se inter relacionam e como as pesquisas feitas poderiam contribuir para o estudo dessa dissertação. Por fim, os dados analisados foram transcritos para uma das seções deste estudo.

K.2 Execução do Protocolo de Pesquisa

K.2.1 Confecção de Strings de Consulta

Antes de iniciar a execução, foi necessário confeccionar as strings de consulta para cada um dos portais de pesquisa. Cada motor de pesquisa possui uma linguagem específica para a realização de suas consultas. Por isso, foi necessário o estudo de como cada motor de pesquisa trabalha e a linguagem utilizada. Alguns motores não permitem que a definição do período de busca seja feita na consulta. Nesses cenários, os estudos foram filtrados após a consulta ter sido realizada.

A seguir são apresentadas as strings submetidas a cada motor:

- Scopus - Inglês

TITLE-ABS-KEY((Neural Network OR ANN) AND ((EWMA OR GARCH) OR (Value-at-Risk OR Value at Risk))) AND Risk Management AND STOCK AND PUBYEAR > 2007

- ScienceDirect - Inglês

pub-date > 2007 and Title-Abstr-Key((Neural Network OR "ANN") AND (("EWMA"OR "GARCH") OR (Value-at-Risk OR Value at Risk))) AND Risk Management AND Stock

- ACM - Inglês

acmTitle:(("Neural Network" OR "ANN") AND ("Value at Risk"OR "Value-at-Risk"OR "EWMA"OR "GARCH")) OR recordAbstract: (("Neural Network"OR "ANN") AND ("Value at Risk"OR "Value-at-Risk"OR "EWMA"OR "GARCH"))

- IEEE - Inglês

("Abstract":"Neural Network"OR "Abstract":"ANN") AND ("Abstract":"Value at Risk"OR "Abstract":"Value-at-Risk"OR "Abstract":"EWMA"OR "Abstract":"GARCH") AND ("Abstract":"Risk") AND ("Abstract":"Stock")

- Web of Science - Inglês

TS= (("Neural Network"OR ANN) AND (EWMA OR GARCH OR "Value-at-Risk"OR "Value at Risk")) AND TS=("Risk Management"AND STOCK) and PY=(2007-2018)

- oasisbr - Português

Busca: (Resumo Português:"Rede Neural"OR "Redes Neurais") E (Resumo Português:"Valor em Risco"OR "Value-at-Risk"OR "Value at Risk"OR GARCH) E (Resumo Português:Volatilidade OR Risco)

Veja que para os portais ACM, IEEE e oasisbr a consulta não possui o filtro de ano. Para esses portais os dados foram filtrados após o retorno da *query*.

K.2.2 Seleção de Estudos Primários

Nessa etapa da pesquisa, as consultas foram executadas nos portais de pesquisas. Cada uma das strings definidas foram submetidas nos portais de pesquisa.

As consultas em inglês foram feitas três vezes e em três dias distintos: 10 de março de 2018, 18 de março de 2018 e 10 de novembro de 2018. Na consulta do dia 10 de março, os dados foram extraídos no formato BibTex, importados na ferramenta StArt, e erroneamente descartados. O procedimento foi repetido em 18 de março para que os arquivos BibTex pudessem ser guardados. A segunda consulta retornou 1 artigo que não havia sido retornado na primeira consulta.

Em 10 de novembro houve a adição da fonte Web of Science por solicitação da banca qualificadora. A consulta em português foi feita em uma única seção, no dia 29 de março de 2018.

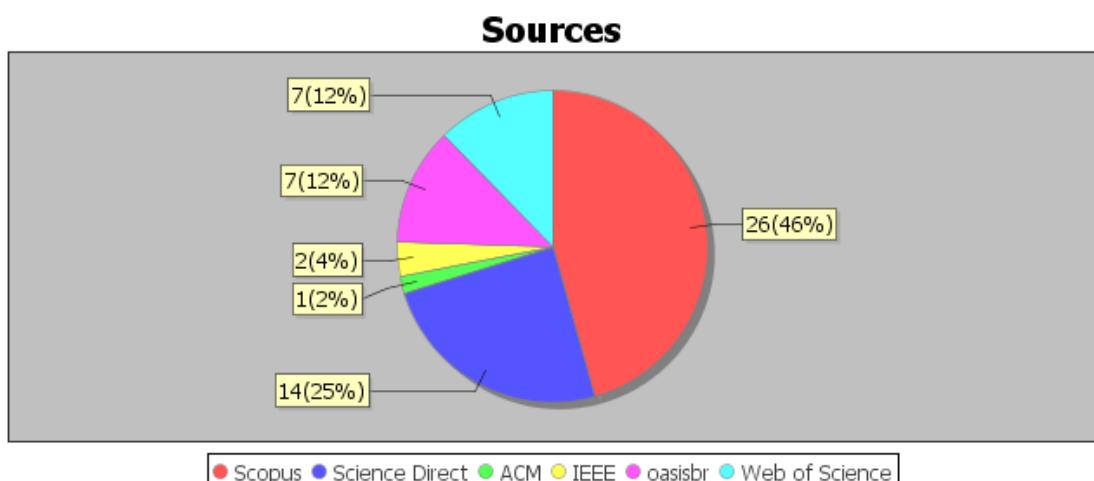
Tabela 37 – Quantidade de dados extraídos dos portais de pesquisa em inglês.

Portal de Pesquisa	10/03/2018	18/03/2018	29/03/2018	10/11/2018
Scopus	25	26	0	0
Science Direct	14	14	0	0
ACM	1	1	0	0
IEEE	2	2	0	0
oasisbr	0	0	7	0
Web of Science	0	0	0	7

Fonte: Elaborado pelo autor

Em seguida, é possível visualizar a quantidade total de estudos encontrados por fonte de pesquisa em forma gráfica.

Figura 45 – Gráfico com a quantidade de estudos encontrados.



Fonte: Extraído da ferramenta StArt.

O apêndice L, contém a tabela extraída da ferramenta StArt com todos os dados retornados das ferramentas de busca. No processo de tabulação dos estudos, alguns caracteres, como os que continham acentuação, não puderam ser identificados pela ferramenta no processo de importação da ferramenta StArt. Por isso alguns estudos tiveram, o título, nomes dos autores e resumo corrigidos manualmente através da leitura do dado original.

Com os estudos devidamente catalogados na ferramenta StArt, os critérios de inclusão e exclusão foram aplicados. A seleção seguiu o processo previamente estipulado no protocolo de pesquisa.

Na primeira iteração de avaliação apenas o título e o resumo foram lidos. Foram aplicados os critérios de exclusão E1, E2 e E3 além de avaliar se existiam estudos duplicados. Nessa iteração foram rejeitados 18 artigos. Na segunda iteração os artigos foram lidos integralmente. Os critérios de inclusão E1 e E2, além dos critérios de exclusão, E1, E2, E3, E4, E5 e E6 foram aplicados.

Tabela 38 – Iterações da seleção de artigos da revisão sistemática

Escopo	Aceitos	Rejeitados ou Duplicados	Critérios Aplicados
Inicial	57	0	-
Título e Resumo	39	18	E1, E2 e E3
1º Leitura Integral	28	29	I1, I2, E1, E2, E3, E4, E5, E6 e E7
2º Leitura Integral	11	46	I1, I2, E1, E2, E3, E4, E5, E6 e E7
3º Leitura Integral	9	48	I1, I2, E1, E2, E3, E4, E5, E6 e E7

Fonte: Elaborado pelo autor

A seguir uma tabela com toda a aplicação dos critérios de inclusão e exclusão para os artigos encontrados nas ferramentas de busca. Para simplificar a tabela e deixá-la mais curta, o ID retirado do StArt foi utilizado para referenciar o artigo. É possível encontrar o estudo consultando o apêndice L. Somente estudos aceitos irão compor as referências dessa dissertação.

Tabela 39 – Revisão Sistemática: Critérios de Inclusão e Exclusão aplicados

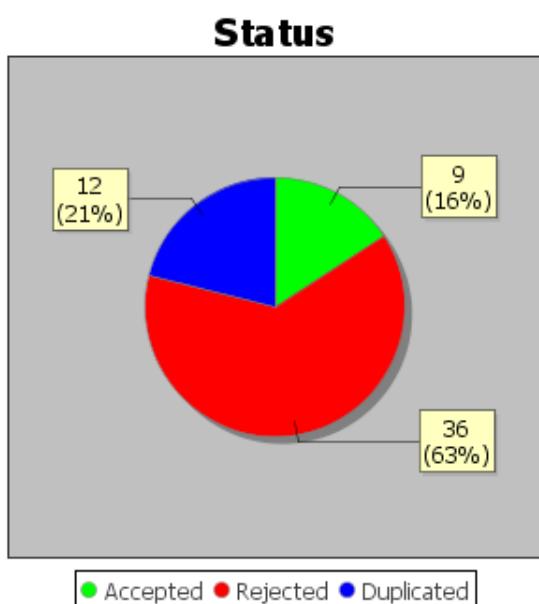
ID Estudos	Critério de Inclusão	Critério de Exclusão
118, 143, 1627 e 1628	I1 e I3	
131, 134, 144, 156 e 1622	I2 e I3	
157		E1
116, 117, 121, 126, 132, 135, 137, 139, 141, 148, 1623, 1626 e 3182		E2
122, 124, 125 e 1624		E2 e E3
119, 120, 123, 127, 140, 142, 152, 153, 154 e 155		E3
149		E4
130, 133, 145, 146 e 147		E5
129 e 138		E6
128, 136, 150, 151, 496, 1625, 3180, 3181, 3183, 3184, 3185 e 3186		E7

Fonte: Elaborado pelo autor

K.2.3 Extração dos Dados

O protocolo de pesquisa levou ao resultado de 57 estudos retornados pelas ferramentas de busca selecionadas.

Após a aplicação dos critérios de seleção, 9 estudos foram selecionados. Esses estudos são identificados como estudos primários. O ID da tabela a seguir, reflete o número gerado pela ferramenta StArt.

Figura 46 – Resultado da seleção dos artigos.

Fonte: Extraído da ferramenta StArt.

Tabela 40 – Estudos primários selecionados

ID	Título	Autor(es)
118	A Statistical Neural Network Approach for Value-at-Risk Analysis	(CHEN; LAI; YEN, 2009)
131	Volatility forecasting using a hybrid GJR-GARCH neural network model	(MONFARED; ENKE, 2014)
134	A new forecasting combination system for predicting volatility	(OROZCO; VELÁSQUEZ, 2013)
143	Application of dynamic financial time-series prediction on the interval artificial neural network approach with value-at-risk model	(LIN; CHEN, 2008)
144	Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models	(KIM; WON, 2018)
156	A hybrid modeling approach for forecasting the volatility of S&P 500 index return	(HAJIZADEH et al., 2012)
1622	Usando redes neurais para estimativa da volatilidade : redes neurais e modelo híbrido GARCH aumentado por redes neurais	(OLIVEIRA, 2010)
1627	Value at Risk no mercado financeiro internacional: avaliação da performance dos modelos nos países desenvolvidos e emergentes	(GAIO, 2015)
1628	Valor em risco de longo prazo: uma abordagem para modelos da Família Ach e redes neuronais	(MACIEL, 2010)

Fonte: Elaborado pelo autor

K.3 Apresentação da Revisão

K.3.1 Tabulação dos Dados

Nessa seção os dados extraídos foram tabulados a fim de responder à questão feita durante o início da pesquisa, devidamente documentadas no protocolo dessa revisão sistemática. Os dados foram apresentados conforme a questão principal e os critérios PICO definidos no protocolo de pesquisa.

Quais foram os modelos utilizados para calcular a previsão de volatilidade e Value-at-Risk para os estudos encontrados?

A revisão conseguiu extrair dados satisfatórios para compreender quais modelos foram utilizados para a previsão de volatilidade e Value-at-Risk e os seus resultados apresentados. Os modelos foram utilizados para identificar oportunidades de estudos abordados nessa dissertação.

A seguir são detalhados os resultados encontrados na extração após a leitura detalhada dos estudos primários.

Da população dos estudos

Dos oito estudos primários, quatro tem como objetivo prever a volatilidade dos ativos estudados contra também quatro que o objetivo é prever o *Value-at-Risk*. São eles:

Tabela 41 – Distribuição do tipo de previsão nos estudos primários.

Previsão	Estudos	Quantidade
Volatilidade	131, 134, 144, 156 e 1622	5
Value-at-Risk	118, 143, 1627 e 1628	4

Fonte: Elaborado pelo autor

Buscou-se estudos em ativos negociados em bolsas de valores.

Tabela 42 – Ativos utilizados nos estudos primários.

Ativos	Estudo	Quantidade
NASDAQ 100 e 10 índices NASDAQ de diferentes setores	131	11
DAX 30, S&P 500, FTSE 100, NIKKEI 225, CAC 40, IBOVESPA, RTS Index, BSE 100, Shanghai SE Composite, FTSE/JSE top 40	1627	9
PETR4, VALE5, GGBR4, ITAU4 e BMEF3	1628	5
S&P 500 e Petróleo Brent	1622	2
S&P 500	134 e 156	1
HSI - Hang Seng Index Stock	118	1
TTT: Taiwan Top 50	143	1
Kospi 200	144	1

Fonte: Elaborado pelo autor

Da intervenção nos estudos

Ainda seguindo o critério PICO, a intervenção é caracterizada pelos algoritmos utilizados e as métricas utilizadas para comparar o algoritmo de rede neural com os cálculos de previsão por métodos estatísticos. Como o foco foi buscar estudos com redes neurais, não foram encontrados estudos que comparassem o modelo de redes neurais com outras técnicas de aprendizado de máquina. Há uma grande concentração de rede neurais com múltiplas camadas e treinadas pelo algoritmo Backpropagation.

Tabela 43 – Algoritmos utilizados nos estudos primários.

Algoritmos	Estudo	Qtd
Feedforward Neural Network / MLP	118, 131, 134, 143, 144, 156, 1622, 1627, 1628	9
Recurrent Neural Network	144	1
Generalized Regression Neural Network	131	1
Radial Basis Function Neural Network	131	1

Fonte: Elaborado pelo autor

Com relação às métricas utilizadas. Elas diferem em sua essência se o objetivo do estudo é de volatilidade ou *Value-at-Risk*. Para fins de padronização, a tabela a seguir contém os termos em Inglês.

Tabela 44 – Métricas utilizadas nos estudos primários

Previsão	Métricas	Estudo
Value-at-Risk	Kupiecs Test, MSE, p-value e VaR Exceedance	118
Value-at-Risk	Kupiecs Test, MAE e MAPE	143
Value-at-Risk	Kupiecs Test	1627
Value-at-Risk	MSE	1628
Volatilidade	MSE	131
Volatilidade	MSE, MAD e Diebold and Mariano Test	134
Volatilidade	MSE, MAE, HMSE, HMAE e Diebold and Mariano Test	144
Volatilidade	RMSE, MAE, MFE e MAPE	156
Volatilidade	RMSE e MAPE	1622

Fonte: Elaborado pelo autor

Do controle nos estudos

Para avaliar a efetividade do modelo com rede neural, os estudos compararam contra modelos estatísticos. Essa comparação, como utiliza um método conhecido pelo mercado financeiro, pode ser facilmente entendido por esse público.

Nota-se que a maioria dos estudos encontrados compararam os resultado com o modelo GARCH.

Tabela 45 – Modelos estatísticos comparados nos estudos primários.

Métrica	Estudo	Quantidade
GARCH	118,134,143,144,1622, 1627,1628	7
EGARCH	144 e 156	2
GJR-GARCH	131	1
EWMA	144	1
Funções Cúpulas	1627	1
Modelo de Terceiros	1628	1

Fonte: Elaborado pelo autor

Do resultado encontrado

A tabela a seguir mostra o agrupamento dos resultados encontrados.

Os estudos 1622 e 1627 apresentaram resultados vantajosos para momentos de estabilidade ao utilizar redes neurais, para momentos de crise o modelo estatístico se mostrou mais satisfatório. Já o estudo 131 recomenda o uso de modelos estatísticos para momentos de estabilidade haja vista a complexidade dos modelos de redes neurais.

Nota-se que modelos com redes neurais são em sua maioria mais vantajosos dos que os modelos estatísticos. Por outro lado, ainda existem oportunidades de estudo haja vista a dificuldade de previsão em momentos de mudanças abruptas de comportamento como os ocasionados em momentos de crise.

Tabela 46 – Modelo mais vantajoso.

Modelo	Estudos	Vantagem
Rede Neural	131,134,143,144,156,1628	6
Ambos Viáveis	118,1622,1627	3

Fonte: Elaborado pelo autor

L ARTIGOS DA REVISÃO SISTEMÁTICA

Esse apêndice contém a listagem de todos os artigos encontrados na revisão sistemática para eventual posterior consulta. Os dados foram extraídos da ferramenta StArt após os procedimentos descritos na seção. K.2.2.

Nas próximas páginas foram apresentadas, em formato de tabela, o resultado bruto tabulado das pesquisas feitas nos portais.

Os itens apresentados em cada um dos artigos são:

1. ID, gerado pela ferramenta StArt
2. Título, carregado do arquivo BibTex e ajustado manualmente, se houveram caracteres inválidos.
3. Autor, carregado do arquivo BibTex e ajustado manualmente, se houveram caracteres inválidos.
4. Ano, carregado do arquivo BibTex
5. Score, gerado pela ferramenta StArt

Tabela 47 – Resultado bruto da pesquisa sistemática no portal Scopus

Primeira página da tabela com o resultado da pesquisa Scopus				
ID	Título	Autor	Ano	Score
119	Volatility of main metals forecasted by a hybrid ANN-GARCH model with regressors	Kristjanpoller R, W. and Hernández P, E.	2017	53
120	Modeling and predicting historical volatility in exchange rate markets	Lahmiri, S.	2017	28
123	Forecasting volatility of oil price using an artificial neural network-GARCH model	Kristjanpoller, W. and Minutolo, M.C.	2016	34
126	Tail risk assessment using support vector machine	Radović, O. and Stanković, J. and Stanković, J.	2015	27
128	Modelling commodity value at risk with Psi Sigma neural networks using open–high–low–close data	Sermpinis, G. and Laws, J. and Dunis, C.L.	2015	29
129	(G)ARCH-RBF modelling of conditional volatility in finance	Falát, L. and Marček, D.	2015	20
130	An ensemble system based on hybrid EGARCH-ANN with different distributional assumptions to predict s&P 500 intraday volatility	Lahmiri, S. and Boukadoum, M.	2015	29
132	Modeling markov switching ARMA-GARCH neural networks models and an application to forecasting stock returns	Bildirici, M. and Ersin, Ö.	2014	74
133	Evolving hybrid neural fuzzy network for realized volatility forecasting with jumps	Rosa, R. and Maciel, L. and Gomide, F. and Ballini, R.	2014	34
134	A new forecasting combination system for predicting volatility [Un nuevo sistema de combinación de pronósticos para la predicción de la volatilidad]	Orozco, J.M. and Velásquez, J.D.	2013	12
136	Ensemble forecasting of Value at Risk via Multi Resolution Analysis based methodology in metals markets	He, K. and Lai, K.K. and Yen, J.	2012	28
138	Measuring of value at risk (VAR) on emerging stock markets by neural networks method	Chen, C.-T. and Hsieh, C.-S.	2010	36

Continuação da tabela com o resultado da pesquisa Scopus

ID	Título	Autor	Ano	Score
139	Forecasting volatility with support vector machine-based GARCH model	Chen, S. and Härdle, W.K. and Jeong, K.	2010	69
140	Modelling commodity value at risk with higher order neural networks	Dunis, C.L. and Laws, J. and Sermpinis, G.	2010	28
142	TSK fuzzy inference system based GARCH model for forecasting exchange rate volatility	Geng, L. and Ma, J.	2008	39
143	Application of dynamic financial time-series prediction on the interval artificial neural network approach with value-at-risk model	Lin, H.-Y. and Chen, A.-P.	2008	45
121	The time traveller's CAPM	French, J.	2017	28
122	Forecasting of China's regional carbon market price based on multi-frequency combined model	Zhang, C. and Yang, X.	2016	12
124	Revisiting the Effects of Forecasting Method Selection and Information Sharing under Volatile Demand in SCM Applications	Pan, Y. and Pavur, R. and Pohlen, T.	2016	8
125	Capturing implied volatility with neural nets as a basis for options pricing and delta hedging	Mostafa, F. and Dillon, T. and Chang, E.	2016	19
127	Computational intelligence approach to capturing the implied volatility	Mostafa, F. and Tharam, T.D. and Chang, E.	2015	22
135	Nonlinearity in Forecasting of High-Frequency Stock Returns	Reboredo, J.C. and Matías, J.M. and Garcia-Rubio, R.	2012	10
137	Robust decision support systems with matrix forecasts and shared layer perceptrons for finance and other applications	Von Mettenheim, H.-J. and Breitner, M.H.	2010	15
141	A neural network approach to option pricing	Mostafa, F. and Dillon, T.	2008	28
131	Volatility forecasting using a hybrid GJR-GARCH neural network model	Monfared, S.A. and Enke, D.	2014	56

Continuação da tabela com o resultado da pesquisa Scopus				
ID	Título	Autor	Ano	Score
496	Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models	Kim, H.Y. and Won, C.H.	2018	45

Tabela 48 – Resultado bruto da pesquisa sistemática no portal ScienceDirect

Primeira página da tabela com o resultado da pesquisa ScienceDirect				
ID	Título	Autor	Ano	Score
144	Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models	Ha Young Kim, Chang Hyun Won	2018	43
145	An evolutionary hybrid Fuzzy Computationally Efficient EGARCH model for volatility prediction	Rajashree Dash, P.K. Dash	2016	39
146	Forecasting financial time series volatility using Particle Swarm Optimization trained Quantile Regression Neural Network	Dadabada Pradeepkumar, Vadlamani Ravi	2017	38
147	Quantile autoregression neural network model with applications to evaluating value at risk	Qifa Xu, Xi Liu, Cuixia Jiang, Keming Yu	2016	17
148	Using Neural Networks to Forecast Volatility for an Asset Allocation Strategy Based on the Target Volatility	Youngmin Kim, David Enke	2016	27
149	Volatility Forecast Based on the Hybrid Artificial Neural Network and GARCH-type Models	Xunfa Lu, Danfeng Que, Guangxi Cao	2016	33
151	Volatility Forecasting Using a Hybrid GJR-GARCH Neural Network Model	Soheil Almasi Monfared, David Enke	2014	47

Continuação da tabela com o resultado da pesquisa ScienceDirect				
ID	Título	Autor	Ano	Score
152	Data analytics enhanced component volatility model	Yuan Yao, Jia Zhai, Yi Cao, Xuemei Ding, Junxiu Liu, Yuling Luo	2017	23
154	Application of Neural Network Models in Modelling Economic Time Series with Non-constant Volatility	Lukas Falat, Zuzana Stanikova, Maria Durisova, Beata Holkova, Tatiana Potkanova	2015	32
155	Estimating VaR in crude oil market: A novel multi-scale non-linear ensemble approach incorporating wavelet analysis and neural network	Kaijian He, Chi Xie, Shou Chen, Kin Keung Lai	2009	27
156	A hybrid modeling approach for forecasting the volatility of S&P 500 index return	E. Hajizadeh, A. Seifi, M.H. Fazel Zarandi, I.B. Turksen	2012	41
157	Chapter 2 - A Primer on Risk Mathematics	Morton Glantz, Robert Kissell	2014	5
150	Modeling and predicting historical volatility in exchange rate markets	Salim Lahmiri	2017	28
153	Ensemble forecasting of Value at Risk via Multi Resolution Analysis based methodology in metals markets	Kaijian He, Kin Keung Lai, Jerome Yen	2012	26

Tabela 49 – Resultado bruto da pesquisa sistemática no portal ACM

Primeira página da tabela com o resultado da pesquisa ACM				
ID	Título	Autor	Ano	Score
116	Estimate of Stochastic Model Parameter of Exchange Rate Using Artificial Intelligence	Mostafa, El Hachloufi and Hamza, Faris and Mohammed, El Haddad	2017	4

Tabela 50 – Resultado bruto da pesquisa sistemática no portal IEEE

Primeira página da tabela com o resultado da pesquisa IEEE				
ID	Título	Autor	Ano	Score
118	A Statistical Neural Network Approach for Value-at-Risk Analysis	X. Chen and K. K. Lai and J. Yen	2009	40
117	The research of margin setting model based on improved BP neural network technology	J. Liu and D. h. Zhu	2010	24

Tabela 51 – Resultado bruto da pesquisa sistemática no portal Web of Science

Primeira página da tabela com o resultado da pesquisa Web of Science				
ID	Título	Autor	Ano	Score
3180	Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models	Ha Young Kim and Chang Hyun Won	2018	55
3181	Modeling and predicting historical volatility in exchange rate markets	Salim Lahmiri	2017	36
3182	Evolving Fuzzy-GARCH Approach for Financial Volatility Modeling and Forecasting	Leandro Maciel, Fernando Gomide e Rosangela Ballini	2016	44
3183	An Ensemble System Based on Hybrid EGARCH-ANN with Different Distributional Assumptions to Predict S&P 500 Intraday Volatility	S. Lahmiri and M. Boukadoum,	2015	37
3184	Volatility Forecasting using a Hybrid GJR-GARCH Neural Network Model	Soheil Almasi Monfared and David Enke	2014	25
3185	Nonlinearity in Forecasting of High-Frequency Stock Returns	Juan C. Reboredo and Jose M. Matias and Raquel Garcia-Rubio	2012	14

Continuação da tabela com o resultado da pesquisa Web of Science				
ID	Título	Autor	Ano	Score
3186	Ensemble forecasting of Value at Risk via Multi Resolution Analysisbased methodology in metals markets	Kaijian He and Kin Keung Lai and Jerome Yen	2012	34

Tabela 52 – Resultado bruto da pesquisa sistemática no portal oasisbr

Primeira página da tabela com o resultado da pesquisa oasisbr				
ID	Título	Autor	Ano	Score
1622	Usando redes neurais para estimativação da volatilidade : redes neurais e modelo híbrido GARCH aumentado por redes neurais	André Barbosa Oliveira e Flávio Augusto Ziegelmann	2010	44
1623	Previsão de séries temporais financeiras por meio de redes neurais dinâmicas e processos de transformação de dados: uma abordagem empírico-comparativa	Alexandre Fructuoso da Costa	2012	33
1624	Sistemas inteligentes aplicados à análise de riscos ambientes	Francisco Sales de Albuquerque Filho	2012	9
1625	Desempenho do value-at-risk nos países emergentes e desenvolvidos	Luiz Eduardo Gaio	2016	25
1626	Aplicação de métodos computacionais multidisciplinares de engenharia para otimização de carteiras de investimento	Marcelo Rosario da Barrosa	2013	9
1627	Value at Risk no mercado financeiro internacional: avaliação da performance dos modelos nos países desenvolvidos e emergentes	Luiz Eduardo Gaio	2015	52
1628	Valor em risco de longo prazo: uma abordagem para modelos da Família Ach e redes neuronais	Leandro Santos Maciel	2010	13